



北京大学

硕士研究生学位论文

题目： 基于多智能体强化学习的
无人机-卫星协同任务调度方法研究

姓 名： 丁建瑞
学 号： 2301213348
院 系： 电子学院
专 业： 通信与信息系统
研究方向： 卫星与无线通信系统
导 师： 冯梅萍 教授级高级工程师

☒ 学术学位 ☐ 专业学位

2026 年 6 月

版权声明

任何收存和保管本论文各种版本的单位和个人，未经本论文作者同意，不得将本论文转借他人，亦不得随意复制、抄录、拍照或以任何方式传播。否则，引起有碍作者著作权之问题，将可能承担法律责任。

摘要

随着低轨卫星通信、无人机通信和边缘计算技术的发展，无人机-卫星协同网络为地面用户任务接入、空中转发和空间侧处理提供了新的服务方式。该类网络中网络拓扑、链路质量和可用计算资源随时间变化，任务在不同层级节点之间传输和处理，调度决策需要同时考虑通信、计算、队列状态和无人机运动安全等因素，对网络的综合调度能力提出新的挑战。如何在动态网络环境下实现多无人机之间的协同调度，是提升任务处理效率和维持系统稳定运行的关键问题。

针对上述问题，本文首先建立无人机-卫星协同任务调度模型。该模型由地面用户、无人机和低轨卫星三类节点组成，描述地面用户任务到达、空地接入、无人机缓存转发、星机回传以及卫星侧计算处理过程。在此基础上，本文进一步刻画无人机运动约束、卫星可见性约束、接入带宽约束和多级任务队列演化关系，并将调度问题表述为多无人机协同决策问题，为后续算法设计提供统一的问题描述。

为解决上述调度问题，本文提出一种结构化多智能体强化学习方法。该方法采用集中式训练、分布式执行框架，把无人机自身状态、候选用户、可见卫星以及邻近无人机等信息抽象为结构化观测量，并通过分阶段 Actor-Critic 网络，实现对无人机运动控制、卫星选择和带宽分配等调度动作的生成。其中，运动控制和卫星选择按时隙更新，接入关联和带宽分配按调度周期更新，以适应不同动作对任务流动过程的影响尺度。在网络中设计运动安全修正机制和安全辅助监督信号，引导策略输出更接近安全可执行结果，降低无人机运动中的碰撞风险；构造队列感知奖励，并结合更稳定的 Critic 价值估计训练方式，使策略训练更关注任务上传、回传和卫星侧处理之间的衔接，刻画任务队列的长期演化；针对候选用户和可见卫星数量随时间变化的情况，引入有效性信息来约束动作生成过程，减少无效动作输出并保持调度动作与可行约束的一致性。

本文进一步构建无人机-卫星协同任务调度环境，完成从训练过程、任务调度性能、运动安全和算法组件作用等方面的仿真评估。实验结果表明，在动态任务到达、卫星可见关系变化等相同条件下，所提方法能够提高任务处理比例，降低地面用户和无人机侧队列积压，并减少任务丢弃。相比李雅普诺夫队列方法等传统规则调度方法，所提方法表现出更好的综合调度能力。同时，分阶段动作设计有助于协调不同动作头的作用，安全辅助监督能够降低运动控制策略对安全修正层的依赖，说明结构化多智能体强化学习方法适用于本文所研究的无人机-卫星协同任务调度问题。

关键词：无人机-卫星协同；任务调度；多智能体强化学习；队列优化；安全约束

Research on UAV-Satellite Collaborative Task Scheduling Based on Multi-Agent Reinforcement Learning

Ding Jianrui (Communication and Information System)

Directed by Prof. Feng Meiping

ABSTRACT

With the development of low Earth orbit satellite communication, unmanned aerial vehicle communication, and edge computing, UAV-satellite collaborative networks offer a new way to support task access for ground users, airborne forwarding, and space-side processing. In such networks, the topology, link quality, and available computational resources vary over time. Tasks are transmitted and processed among nodes at different layers, so scheduling decisions have to consider communication conditions, computing capability, queue states, and UAV motion safety at the same time. This makes integrated scheduling more demanding. Coordinated scheduling among multiple UAVs in a dynamic network is therefore important for improving task processing efficiency and maintaining stable system operation.

To address this problem, this thesis first builds a UAV-satellite collaborative task scheduling model. The model contains three types of nodes: ground users, UAVs, and low Earth orbit satellites. It describes task arrivals at ground users, air-to-ground access, UAV caching and forwarding, UAV-to-satellite backhaul, and satellite-side computation. The model also characterizes UAV motion constraints, satellite visibility constraints, access bandwidth constraints, and the evolution of multi-level task queues. Based on these elements, the scheduling problem is formulated as a multi-UAV cooperative decision-making problem, which gives a unified problem description for the algorithm design.

Based on the above formulation, this thesis proposes a structured multi-agent reinforcement learning method. The method follows the centralized training and decentralized execution framework. It represents the UAV state, candidate users, visible satellites, and neighboring UAVs as structured observations, and uses a staged Actor-Critic network to generate scheduling actions, including UAV motion control, satellite selection, and bandwidth allocation. Mo-

tion control and satellite selection are updated at each time slot, whereas access association and bandwidth allocation are updated by scheduling period, so that different action types can match their different influence scales on task flow. A motion safety correction mechanism and a safety auxiliary supervision signal are introduced to guide the policy toward safer executable actions and reduce collision risks during UAV movement. A queue-aware reward is designed together with a more stable Critic value-estimation procedure, making policy training focus on the connection among task uploading, backhaul, and satellite-side processing, so that the long-term evolution of task queues is reflected in the learning process. Since the numbers of candidate users and visible satellites change over time, validity information is further used to constrain action generation, reduce invalid actions, and keep the generated scheduling actions consistent with feasibility constraints.

A simulation environment is then built for the considered UAV-satellite scheduling scenario. The method is evaluated in terms of training process, task scheduling performance, motion safety, and algorithm components. The experimental results show that, under the same dynamic task arrivals and satellite visibility changes, the proposed method increases the task processing ratio, reduces queue backlog at the ground user and UAV sides, and decreases task dropping. Compared with traditional rule-based scheduling methods, including the Lyapunov queue-based method, it shows better overall scheduling capability. The results also indicate that the staged action design helps coordinate different action heads, and that safety auxiliary supervision reduces the motion policy's reliance on the safety correction layer. These observations support the applicability of structured multi-agent reinforcement learning to the UAV-satellite collaborative task scheduling problem studied in this thesis.

KEYWORDS: UAV-satellite collaboration; task scheduling; multi-agent reinforcement learning; queue optimization; safety constraints

目录

缩略语表	IX
第一章 引言	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 无人机-卫星协同网络研究	3
1.2.2 边缘计算任务调度与队列优化研究	4
1.2.3 多智能体强化学习在协同调度中的应用	6
1.3 本文主要研究内容与贡献	7
1.4 论文组织结构	8
第二章 无人机-卫星协同任务调度场景建模与问题描述	11
2.1 引言	11
2.2 无人机-卫星协同任务调度场景	11
2.2.1 网络组成与节点角色	12
2.2.2 任务流转与调度流程	13
2.3 通信、计算与队列模型	13
2.3.1 地面用户到无人机接入模型	15
2.3.2 无人机到卫星回传模型	17
2.3.3 卫星计算与多级队列演化	19
2.4 运动、可见性与安全约束	21
2.4.1 无人机运动约束	21
2.4.2 卫星可见性与连接约束	22
2.4.3 无人机安全距离约束	22
2.5 协同任务调度问题形式化	23
2.5.1 状态空间与观测信息	23
2.5.2 决策变量与动作空间	24
2.5.3 优化目标与约束条件	25
2.5.4 多智能体决策建模	26
2.6 本章小结	27
第三章 基于结构化多智能体强化学习的无人机-卫星协同任务调度算法设计	29

3.1	引言	29
3.2	结构化多智能体强化学习调度框架	30
3.2.1	集中式训练与分布式执行框架	30
3.2.2	单时隙协同调度流程	32
3.3	面向异构实体的结构化观测编码	34
3.3.1	局部观测信息构成	35
3.3.2	候选实体编码与掩码表示	37
3.3.3	Actor-Critic 网络结构	39
3.4	连续-离散混合动作空间设计	42
3.4.1	无人机运动控制动作	42
3.4.2	卫星回传选择动作	43
3.4.3	接入带宽分配动作	44
3.5	约束感知动作处理机制	45
3.5.1	动作掩码机制	45
3.5.2	连续动作边界处理	46
3.5.3	安全约束修正机制	47
3.6	队列感知策略优化方法	50
3.6.1	队列感知奖励构造	51
3.6.2	安全修正辅助监督	52
3.6.3	MAPPO 策略优化目标	53
3.6.4	集中式训练与分布式执行机制	56
3.7	本章小结	57
第四章	无人机-卫星协同任务调度算法仿真实验与性能分析	59
4.1	引言	59
4.2	仿真实验设置	60
4.2.1	仿真场景与网络参数	60
4.2.2	任务到达与队列参数	61
4.2.3	通信、计算与运动参数	62
4.2.4	训练参数设置	62
4.3	对比方法与评价指标	65
4.3.1	对比方法设置	65
4.3.2	评价指标定义	67
4.4	算法收敛性能分析	70

4.5 任务调度性能对比	72
4.5.1 任务处理与丢弃性能	72
4.5.2 多级队列积压性能	73
4.5.3 接入与回传吞吐性能	75
4.6 运动安全与约束处理效果分析	77
4.7 消融实验分析	78
4.7.1 动作头消融实验设置	79
4.7.2 动作头消融结果分析	79
4.7.3 安全辅助监督消融分析	80
4.8 本章小结	82
第五章 总结与展望	83
5.1 全文工作总结	83
5.2 主要研究结论	84
5.3 未来研究方向	85
5.3.1 差异化业务与任务依赖建模	85
5.3.2 跨场景泛化与在线自适应部署	85
5.3.3 面向工程部署的安全约束与鲁棒决策	86
参考文献	87
致谢	91
北京大学学位论文原创性声明和使用授权说明	93

缩略语表

缩略语或术语	英文全称	中文含义
3GPP	3rd Generation Partnership Project	第三代合作伙伴计划
6G	Sixth Generation	第六代移动通信
Actor-Critic	Actor-Critic	演员-评论家结构
CPU	Central Processing Unit	中央处理器
CTDE	Centralized Training with Decentralized Execution	集中式训练、分布式执行
DCOOL	Dynamic Computation Offloading and Resource Allocation	动态计算卸载与资源分配方法
DDPG	Deep Deterministic Policy Gradient	深度确定性策略梯度
GAE	Generalized Advantage Estimation	广义优势估计
ITU-R	International Telecommunication Union Radiocommunication Sector	国际电信联盟无线电通信部门
LEO	Low Earth Orbit	低轨
LoS	Line of Sight	视距
MADDPG	Multi-Agent Deep Deterministic Policy Gradient	多智能体深度确定性策略梯度
MAPPO	Multi-Agent Proximal Policy Optimization	多智能体近端策略优化
MDP	Markov Decision Process	马尔可夫决策过程
MEC	Mobile Edge Computing	移动边缘计算
NLoS	Non-Line of Sight	非视距
P-DQN	Parameterized Deep Q-Network	参数化深度 Q 网络
PPO	Proximal Policy Optimization	近端策略优化
QP	Quadratic Programming	二次规划
RF	Radio Frequency	射频
SAGIN	Space-Air-Ground Integrated Network	空天地一体化网络
TD	Temporal Difference	时序差分
UAV	Unmanned Aerial Vehicle	无人机

第一章 引言

本章围绕无人机-卫星协同任务调度问题展开，介绍研究背景与意义，梳理无人机-卫星协同网络、边缘计算任务调度与多智能体强化学习相关研究，并概括本文主要研究内容、研究贡献和论文组织结构。

1.1 研究背景与意义

随着第六代移动通信（Sixth Generation, 6G）网络向全域覆盖、智能连接和泛在计算方向发展，仅依赖地面基础设施的网络形态难以满足偏远地区、海上区域、灾害现场和临时热点区域的持续服务需求^[1,2]。低轨（Low Earth Orbit, LEO）卫星具有覆盖范围广、部署不依赖地面基础设施等特点，无人机具有部署灵活、可快速接近任务区域和改善地面接入链路等优势^[2,3]。二者结合形成的无人机-卫星协同网络，能够在地面网络覆盖不足或受损时为地面用户提供任务接入、数据回传和远端处理能力，因此成为空天地协同网络（Space-Air-Ground Integrated Network, SAGIN）和边缘计算融合研究中的重要方向^[1,3]。近期关于 6G SAGIN 的综述进一步指出，空天地多层网络需要在通信、计算和缓存资源之间形成协同，才能支撑动态业务和广域服务需求^[4,5]。

然而，无人机-卫星协同网络中的任务调度已经超出单一链路选择或静态任务转发的范围。一方面，地面用户任务持续随机到达，如果无人机接入能力、卫星回传能力或卫星侧处理能力不足，任务会在地面用户队列、无人机队列和卫星队列中逐层积压，并在队列容量受限时产生任务丢弃^[3,6,7]。另一方面，无人机一旦改变位置，空地接入距离、可见卫星集合、星机回传链路以及无人机间安全距离都会随之变化，当前时隙的运动控制动作也会继续影响后续时隙中的通信服务能力和队列变化^[2,3]。因此，该问题不仅具有时变性，还具有跨时隙累积影响和多节点相互影响的特性。

已有研究已从博弈论、凸优化和强化学习等角度研究空天地协同网络中的任务卸载与资源分配问题^[3,7]。这类研究往往需要把卸载位置、通信资源、计算资源以及节点移动放在同一模型中进行描述，并根据链路状态和任务到达变化不断调整调度决策。传统优化或博弈方法能够给出清晰的目标函数和约束关系，但在多无人机、多用户和多卫星共同参与时，每个时隙重新建立并求解联合优化问题会带来较高在线计算开销，同时也对全局状态获取和系统模型精度提出较高要求。

多智能体强化学习为这类动态网络调度提供了一种数据驱动的建模途径。在集中式训练、分布式执行框架下，训练阶段可以借助较完整的状态信息评估多智能体协同

效果，执行阶段则由各智能体根据局部观测生成动作，从而更适合动态环境中的在线调度需求^[8-10]。已有近年研究也表明，多智能体强化学习已被用于低轨卫星边缘计算中的任务卸载和资源分配问题^[10]。但是，无人机-卫星协同任务调度仍具有异构实体相互影响、混合动作约束、队列反馈延迟和运动安全约束等特点。因此，本文结合场景中的网络结构、任务队列和动作约束，研究面向无人机-卫星协同任务调度的结构化多智能体强化学习方法。

基于上述背景，本文面向由地面用户、无人机和低轨卫星组成的三层协同网络，研究动态任务到达、多级队列演化、无人机运动和卫星回传共同作用下的协同任务调度问题。本文关注的核心不是单一链路速率最大化或单节点任务卸载，而是在多无人机协同执行过程中，联合决定无人机运动控制、地面用户接入资源分配和卫星回传选择，以提升任务处理效率、降低队列积压和任务丢弃，并满足无人机运动安全约束。该研究能够为地面网络覆盖不足、容量受限或需要空中补充服务条件下的任务调度方法设计提供参考，也为后续开展更复杂业务模型和工程部署研究奠定基础^[1,3,10]。




图 1.1 无人机-卫星协同任务调度场景示意图

1.2 国内外研究现状

围绕无人机-卫星协同任务调度问题，现有研究主要集中在无人机-卫星协同网络架构、边缘计算任务调度与队列优化、多智能体强化学习调度方法三个方面。其中，无人机-卫星协同网络研究为任务接入和回传提供网络基础；边缘计算任务调度与队列优化研究关注任务在多层节点之间的传输、排队和处理过程；多智能体强化学习研究则

为动态环境下的分布式协同决策提供算法工具。下面将从上述三个方面对相关研究进行梳理。

1.2.1 无人机-卫星协同网络研究

无人机-卫星协同网络是空天地协同网络的重要组成部分。低轨卫星能够提供广域覆盖和远距离回传能力，无人机能够通过灵活部署改善地面用户接入条件，二者结合有助于弥补单一地面网络、单一卫星网络或单一无人机网络在覆盖范围、链路质量和服务连续性方面的不足^[1-3]。近年来，面向 6G 的空天地协同网络研究逐渐从单纯通信连接扩展到通信、计算和服务协同，强调在卫星、空中平台和地面节点之间进行异构资源编排与任务服务协同^[1,11]。Cheng 等从 6G 服务需求出发梳理了 SAGIN 的服务化网络架构，指出空间层、空中层和地面层需要在覆盖、传输和计算服务上形成协同^[1]；Zhang 等进一步总结了无人机通信在 SAGIN 中的关键技术、应用场景和挑战，说明无人机在空天地协同网络中不仅承担接入或中继功能，还会参与任务服务和资源调度过程^[11]。Xiao 等从 6G 无线网络角度总结了 SAGIN 的网络特征和关键技术，强调空间、空中和地面网络在覆盖、频谱和计算资源方面需要联合设计^[4]；Shen 等则从计算技术角度梳理了 SAGIN 中云边端协同、网络计算和智能资源管理等问题，说明 SAGIN 已从连接扩展到通信计算融合服务^[5]。

在具体研究内容上，已有工作围绕无人机三维部署、空地接入覆盖、卫星回传和协同边缘计算等方向展开。例如，Guo 等针对 SAGIN 中多无人机三维部署问题，在无人机连接容量、无人机间连通性、地面用户服务质量和安全距离等约束下优化无人机位置，说明多无人机部署不仅需要关注用户覆盖范围，还需要同时考虑无人机网络连通性、负载均衡和鲁棒性^[12]。在无人机辅助低轨卫星边缘计算方面，Zhang 等研究了无人机辅助 LEO 卫星边缘计算中的资源分配与卸载策略，将地面物联网设备的任务经由无人机转发至低轨卫星进行处理，并利用深度强化学习方法联合优化任务卸载和资源分配^[3]。Hao 等面向 LEO 卫星移动边缘计算（Mobile Edge Computing, MEC）网络联合优化通信、计算和缓存资源，说明星载边缘计算中的多维资源配置会同时影响任务传输、计算处理和内容服务能力^[13]。Liu 等在卫星、无人机集群和地面设备组成的三层 SAGIN 边缘计算网络中，建立计算卸载模型并从博弈论角度设计分布式卸载算法，用于降低多层边缘节点之间的卸载开销^[7]。这些研究表明，无人机-卫星协同网络已经从单纯的覆盖增强和链路连通逐步扩展到任务服务、资源调度和边缘计算协同，但现有工作往往侧重部署优化、任务卸载或资源分配中的某一类问题，对无人机运动、接入带宽、卫星回传和多级队列演化之间的长期关联关系仍需要进一步研究。

总体来看，无人机-卫星协同网络研究已经较充分地说明了卫星广域覆盖和无人机

灵活部署的互补优势,并在网络架构、三维部署、连接保持和资源协同等方面取得了较多进展^[1,11,12]。但是,面向任务流持续到达的协同调度场景,仅从覆盖、连接或单次卸载角度建模仍难以刻画任务在地面用户、无人机和卫星之间的连续流转过程。尤其是在多无人机同时移动、多用户任务持续到达、可见卫星集合随时间变化的情况下,调度策略需要同时关注当前链路服务能力和后续队列演化。因此,本文在无人机-卫星协同网络框架下,进一步关注任务接入、无人机缓存、卫星回传和卫星处理之间的动态作用关系。

1.2.2 边缘计算任务调度与队列优化研究

边缘计算任务调度主要关注任务在端侧设备、边缘节点和远端计算节点之间的卸载、传输、排队和处理过程。在无人机和低轨卫星引入后,任务调度不再只是端侧设备与固定边缘服务器之间的卸载选择,还需要同时考虑空中节点移动、卫星可见窗口、回传链路变化和星载计算资源受限等因素。Zhang 等针对无人机辅助 LEO 卫星边缘计算场景,构建了地面物联网设备、无人机和低轨卫星组成的任务卸载架构,并将资源分配与卸载决策建模为约束优化问题和马尔可夫决策过程 (Markov Decision Process, MDP)^[3]。Liu 等进一步面向卫星、无人机集群和地面设备组成的 SAGIN 边缘计算网络,建立三层计算卸载模型,并从博弈论角度研究多节点计算资源受限条件下的任务卸载策略^[7]。这些研究说明,无人机-卫星协同边缘计算中的任务调度需要同时处理通信链路、计算资源和卸载位置选择,其问题规模会随着用户数量、空中节点数量和候选卫星数量增加而快速扩大。

在无人机辅助边缘计算中,无人机运动轨迹和资源分配通常需要与任务卸载共同设计。Hao 等在多无人机协同边缘计算中同时考虑任务优先级、任务卸载、资源分配和无人机轨迹设计,说明多无人机场景中的任务服务能力与无人机运动过程密切相关^[14]。Ju 等构建多无人机辅助 MEC 系统,利用多智能体深度强化学习联合优化任务卸载和无人机路径,用于改善系统负载均衡和任务服务效果^[15]。Wang 等进一步在无人机移动边缘计算场景中考虑飞行动力学和时变通信环境,联合优化无人机动态轨迹、任务卸载和资源分配^[16]。这些研究表明,无人机运动状态会直接影响空地链路质量和边缘计算服务能力,因此在无人机-卫星协同任务调度中不能将无人机位置简单视为静态参数。

针对低轨卫星边缘计算的动态性,近期研究开始进一步关注卫星高速运动、可见窗口和混合动作空间对任务调度的影响。Yang 等在 LEO 卫星边缘网络中研究计算卸载与资源分配问题,将卸载决策和资源分配统一表示为离散-连续混合动作,并采用参数化深度 Q 网络 (Parameterized Deep Q-Network, P-DQN) 方法处理时变网络条件下的

长期任务满足率优化问题^[17]。Magliarisi 等提出面向卫星边缘计算的轨道感知任务调度 (orbit-aware task scheduling) 方法, 在任务调度中显式考虑卫星轨道运动、卫星可见窗口、资源约束和任务截止时间, 说明卫星运动状态会直接影响任务能否在可见窗口内完成处理^[18]。Qu 等面向卫星边缘计算中的端到端任务, 联合优化计算卸载、路由选择和多维资源分配, 说明卫星网络中的任务处理往往需要跨越多个传输和计算环节^[19]。Zhou 等研究卫星边缘计算网络中的移动性感知卸载问题, 将卫星运动对连接机会和任务卸载结果的影响纳入优化过程^[20]。Xie 等进一步考虑 LEO 卫星-地面融合网络中的系统状态延迟, 指出状态信息滞后会影响卸载与资源分配决策, 并通过延迟感知学习方法提高调度效果^[21]。Tang 等针对 LEO 卫星边缘计算中的随机卸载问题, 结合李雅普诺夫 (Lyapunov) 优化和学习方法处理动态任务到达和长期性能优化^[22]。上述研究与本文具有相近网络背景, 均关注低轨卫星边缘计算中的动态拓扑和时变服务关系, 但多数工作主要讨论终端到卫星或终端到无人机/卫星的卸载选择。对于多无人机场景中运动控制、接入带宽分配和卫星回传选择之间的联动关系, 现有模型仍有进一步细化空间。

在持续任务流场景中, 任务调度还需要关注任务到达、队列积压、服务能力变化和任务丢弃之间的长期关系。随机网络优化理论通常利用队列状态描述系统负载, 并通过李雅普诺夫漂移等工具分析长期队列稳定性和调度决策之间的关系^[6]。Kim 和 Kwak 在低轨卫星辅助 MEC 架构中提出 DCOOL 动态卸载与资源分配框架, 利用李雅普诺夫优化在 LEO 卫星高速运动条件下处理动态卸载、资源分配和队列稳定性约束^[23]。Hu 等基于李雅普诺夫优化构建卫星边缘计算动态任务卸载策略, 用于在任务动态到达条件下处理长期平均优化问题^[24]。Liao 等面向空天地一体化电力物联网提出队列感知任务卸载与资源分配方法, 将队列状态、短期调度决策和长期约束联系起来^[25]。He 等在无人机辅助车联网边缘计算中显式建模无人机和路侧单元任务队列, 并利用李雅普诺夫框架维护任务卸载过程中的队列稳定性^[26]。这类研究表明, 队列状态不仅是评价任务滞留程度的结果指标, 也可以直接参与调度策略设计, 用于刻画当前任务负载与后续服务能力之间的关系。

总体来看, 边缘计算任务调度研究已经从固定边缘服务器卸载逐步扩展到无人机、低轨卫星和空天地协同网络场景, 并在任务卸载、资源分配、动态卫星可见性和队列稳定性建模方面取得了较多进展。但是, 现有研究更多关注单次卸载代价、任务完成时延或星载资源分配, 对地面用户队列、无人机缓存队列和卫星处理队列之间的连续流转过程关注不足。在多无人机协同服务场景下, 无人机位置变化会影响地面接入能力和卫星回传选择, 接入与回传决策又会改变后续多级队列状态。因此, 本文在已有边缘计算任务调度和队列优化研究基础上, 进一步将任务接入、无人机缓存、卫星回

传、卫星处理和运动安全约束纳入统一的时隙级协同调度模型。

1.2.3 多智能体强化学习在协同调度中的应用

多智能体强化学习适用于多节点共同参与决策的场景，其基本思路是把系统中的多个决策主体表示为智能体，并让各智能体在与环境持续交互时学习面向长期回报的策略。在无人机-卫星协同任务调度问题中，多个空中节点和空间节点会共同占用通信、计算和回传资源，单个节点的调度动作会改变其他节点后续可获得的服务能力和任务状态。如果直接运用集中式优化方法统一计算所有节点动作，在线求解复杂度和全局状态获取开销都会较高；如果让各节点各自学习策略，训练过程又会受到其他节点策略更新的影响。在这种背景下，多智能体协同调度常采用集中式训练、分布式执行（Centralized Training with Decentralized Execution, CTDE）框架^[8]。其中，集中式训练表示训练阶段可以利用全局状态、多个智能体动作和团队奖励等信息进行策略学习；分布式执行表示策略训练完成后，每个智能体只依据自身局部观测生成动作，不需要在执行阶段获取完整全局状态。借助这一框架，算法在训练阶段能够利用多智能体协同过程中的全局信息，而在执行阶段仍保持各智能体独立决策的形式。Lowe 等提出的多智能体深度确定性策略梯度（Multi-Agent Deep Deterministic Policy Gradient, MADDPG）方法，通过集中式 Critic 和分布式 Actor 处理混合合作-竞争环境中的多智能体学习问题^[8]。Yu 等进一步系统评估了多智能体近端策略优化（Multi-Agent Proximal Policy Optimization, MAPPO）在合作多智能体任务中的效果，说明基于近端策略优化（Proximal Policy Optimization, PPO）的同策略（on-policy）更新方法在多智能体合作场景中具有较好的训练稳定性和工程适用性^[9]。这些方法为无人机、卫星和边缘计算等动态网络中的分布式协同决策提供了算法基础。

近年来，多智能体强化学习已经被用于低轨卫星边缘计算和空天地协同网络中的任务卸载与资源分配。Li 等面向 LEO 卫星边缘计算网络，将多颗配备 MEC 服务器的低轨卫星建模为智能体，采用 MADDPG 联合优化终端发射功率、卫星 CPU 频率、任务比特分配、卸载决策和带宽分配^[10]。Ji 等在数字孪生卫星边缘网络中采用协同多智能体深度强化学习进行计算卸载，说明卫星边缘场景中的多节点协同决策可以借助数字孪生状态和多智能体策略进行学习^[27]。Wu 等提出面向 LEO 卫星边缘计算系统的多智能体深度强化学习卸载方法，进一步说明多智能体学习已经被用于卫星边缘计算中的动态卸载决策^[28]。Huang 等研究 SAGIN 中高空无人机接入和 LEO 卫星回传匹配问题，将 LEO 卫星作为智能体，利用多智能体深度强化学习在 CTDE 框架下进行卫星-无人机匹配决策，用于提升空天地网络中的业务回传效果^[29]。Li 等还在 SAGIN 计算卸载与资源管理问题中采用深度强化学习方法，将卸载决策、频谱分配、计算资源和缓

存资源管理纳入统一优化过程,说明强化学习能够用于处理时变 SAGIN 中的高维资源管理问题^[30]。Huynh 等面向 SAGIN 资源分配问题构建多智能体强化学习框架,用于处理空天地多层异构网络中的分布式资源调度^[31]。Xu 等采用多智能体 DDPG 方法研究 SAGIN 中的异构资源分配,为 CTDE 和 MADDPG 思路在空天地网络资源管理中的应用提供了近期例子^[32]。Cheng 等将 MAPPO 用于无人机辅助 MEC 网络中的联合资源分配,说明 MAPPO 也已被用于无人机边缘计算场景中的多智能体资源调度^[33]。

总体来看,现有多智能体强化学习研究已经证明其在动态网络资源分配、低轨卫星边缘计算和空天地协同回传中的应用潜力。但是,已有工作多围绕任务卸载、资源分配或节点匹配等调度环节展开,对通信服务、计算处理、节点移动和任务队列共同作用下的连续调度过程关注仍不充分。同时,空天地协同网络中的调度动作类型较多,可行动作集合和系统状态会随时间变化,任务排队反馈又会跨时隙累积,因此策略网络结构、动作约束处理和奖励构造都会直接影响学习稳定性和调度效果。在约束动作空间方面,Ling 等研究了强化学习中的约束组合动作空间,利用知识编译提升可行动作采样效率,为调度问题中处理动作可行性约束提供了参考^[34]。在运动安全方面,Chen 等将安全强化学习用于多无人机无碰撞路径规划,并将控制屏障函数与多智能体深度强化学习结合,说明在连续运动动作中显式引入安全约束有助于降低碰撞风险^[35]。因此,本文在 CTDE 和 MAPPO 的基础上,结合无人机-卫星协同任务调度中的异构观测、混合动作约束和多级队列状态,设计结构化多智能体强化学习调度算法。

1.3 本文主要研究内容与贡献

针对无人机-卫星协同任务调度中存在的动态链路、时变卫星可见关系、多级任务队列和多智能体协同决策问题,本文面向由地面用户、无人机和低轨卫星组成的三层协同网络,研究任务从地面用户接入无人机、经无人机回传至低轨卫星并完成处理的调度过程。与侧重单次任务卸载或单类资源分配的研究不同,本文将无人机运动、地面接入、卫星回传和任务队列演化放在统一时隙模型中分析,并在此基础上设计结构化多智能体强化学习调度方法。本文主要研究内容如下:

第一,建立无人机-卫星协同任务调度系统模型。本文描述地面用户、无人机和低轨卫星三类节点的功能角色,构建地面用户到无人机的接入链路模型、无人机到低轨卫星的回传链路模型和卫星侧任务处理模型。在任务流动过程中,本文分别刻画地面用户队列、无人机队列和卫星队列的更新关系,并考虑任务到达、任务上传、任务回传、卫星处理和任务丢弃等过程。同时,本文给出无人机运动约束、卫星可见性约束、接入带宽约束和无人机安全距离约束,将协同任务调度问题形式化为多无人机协同决策问题。

第二，设计基于结构化多智能体强化学习的协同调度算法。针对无人机局部观测中包含自身状态、候选用户、可见卫星和邻近无人机等异构信息的特点，本文构建结构化观测表示方式，并采用参数共享的分阶段 Actor-Critic 网络生成调度动作。该方法围绕观测表示、网络结构和动作生成过程进行结构化设计，以匹配无人机-卫星协同任务调度中多类实体状态、多阶段调度动作和多种可行性约束并存的场景特征。针对调度动作同时包含连续控制和离散选择的情况，本文将运动控制、卫星回传选择和接入带宽分配表示为连续-离散混合动作空间，并由统一策略进行建模。在动作执行前，本文借助有效性信息、运动边界处理和安全修正机制对候选动作进行可行性处理；在策略优化中，本文构造队列感知奖励和安全辅助监督信号，并运用 MAPPO 对策略网络进行训练。

第三，开展无人机-卫星协同任务调度仿真实验。本文构建包含用户聚类分布、热点任务到达、低轨卫星时变可见关系和多级队列演化的仿真场景，并从任务处理比例、任务丢弃率、队列时间负载、链路吞吐和碰撞终止情况等方面评价算法性能。通过与基准规则、队列感知规则和李雅普诺夫队列方法进行比较，本文评估所提方法在动态任务到达和卫星可见关系变化条件下的综合调度效果。同时，本文开展动作头消融实验和安全辅助监督对比实验，进一步观察不同动作阶段和安全辅助机制对训练稳定性与调度效果的影响。

本文的主要贡献可以概括为以下两个方面。

一是建立面向无人机-卫星协同任务调度的系统模型。该模型把地面用户、无人机和低轨卫星纳入同一任务流转过程，描述任务在空地接入、星机回传、卫星处理和多级队列之间的动态变化，并同时考虑无人机运动、卫星可见性、接入带宽和安全距离等约束。该建模方式为分析无人机-卫星协同网络中的长期任务调度问题提供了基础。

二是提出结构化多智能体强化学习调度方法。该方法围绕异构局部观测、混合动作空间和时变可行动作集合设计策略网络与动作处理流程，并结合队列感知奖励和安全辅助监督，使多无人机策略能够在动态任务到达和卫星可见关系变化条件下学习协同调度行为。与固定规则或单一局部指标驱动的方法相比，该方法能够更系统地处理任务流动、资源分配和运动安全之间的关系。

1.4 论文组织结构

本文共分为五章，各章内容安排如下。

第一章为引言。本章介绍无人机-卫星协同任务调度的研究背景与意义，梳理无人机-卫星协同网络、边缘计算任务调度与队列优化、多智能体强化学习协同调度等相关研究，并说明本文主要研究内容与贡献。




图 1.2 本文研究内容与技术路线图

第二章为无人机-卫星协同任务调度系统建模。本章描述地面用户、无人机和低轨卫星组成的三层协同网络，建立空地接入链路、星机回传链路、卫星计算处理和多级队列演化模型，给出无人机运动、卫星可见性、带宽分配和安全距离等约束，并将协同任务调度问题形式化为多无人机协同决策问题。

第三章为基于结构化多智能体强化学习的无人机-卫星协同任务调度算法设计。本章在第二章系统模型基础上，设计集中式训练、分布式执行框架下的结构化多智能体强化学习方法，包括结构化观测编码、分阶段 Actor-Critic 网络、连续-离散混合动作空间、约束感知动作处理机制、队列感知奖励和安全辅助监督等内容。

第四章为无人机-卫星协同任务调度算法仿真实验与性能分析。本章给出仿真实验设置、对比方法和评价指标，分析所提算法的训练过程、任务调度性能、运动安全表现和消融实验结果，验证结构化多智能体强化学习方法在动态任务调度场景中的综合表现。

第五章为总结与展望。本章总结全文研究工作和主要结论，并从差异化业务建模、跨场景泛化部署以及安全鲁棒决策等方面讨论后续研究方向。

第二章 无人机-卫星协同任务调度场景建模与问题描述

2.1 引言

无人机-卫星协同任务调度问题需要同时刻画网络拓扑、通信链路、任务流转和多智能体决策过程。在该场景中，地面用户持续产生计算任务，无人机负责移动接入、任务缓存和卫星回传调度，低轨卫星则为无人机提供广域回传链路和后续任务处理能力。由于无人机位置、用户接入关系、卫星可见集合和多级任务队列均随时间变化，系统模型需要能够描述任务在“地面用户-无人机-卫星”路径上的动态流动过程，并为后续调度算法提供清晰的状态、动作和约束定义。

本章围绕上述无人机-卫星协同任务调度场景开展系统建模。场景建模部分先说明地面用户、无人机和低轨卫星三类节点的作用，再描述任务产生、接入上传、无人机缓存、卫星回传和卫星处理之间的流转关系；通信、计算与队列模型部分给出地面用户到无人机的接入链路、无人机到卫星的回传链路、卫星侧计算处理能力以及三层任务队列更新过程；问题形式化部分把无人机运动控制、接入带宽分配和卫星回传选择纳入同一多无人机协同调度问题，明确系统状态、局部观测、动作变量、约束条件和优化目标，为第三章算法设计提供模型基础。

本章其余内容安排如下。第 2.2 节介绍无人机-卫星协同任务调度场景，包括网络组成、节点角色和任务流转过程；第 2.3 节建立通信、计算与队列模型，描述接入链路、回传链路、卫星计算和多级队列演化；第 2.4 节给出多无人机协同调度问题形式化描述，定义状态、观测、动作变量、约束条件和优化目标；第 2.5 节对本章内容进行总结。

2.2 无人机-卫星协同任务调度场景

本文研究的调度场景由地面用户、无人机和低轨卫星组成。地面用户分布在任务区域内，并持续产生需要处理的计算任务；无人机在固定高度附近进行移动接入和中继转发，根据用户分布、队列状态和链路条件调整服务方式；低轨卫星为无人机提供广域回传链路和后续计算处理能力。与静态地面网络相比，该场景中的无人机位置、用户接入关系、卫星可见集合和多级任务队列都会随时间变化，因此调度过程需要同时考虑无人机运动、接入带宽分配和卫星回传选择^[2,3]。




图 2.1 无人机-卫星协同任务调度场景示意图

2.2.1 网络组成与节点角色

本文将协同任务调度场景抽象为地面用户层、空中无人机层和空间卫星层组成的三层网络结构。地面用户层由任务产生节点构成，主要负责产生待处理计算任务并通过接入链路上传数据；空中无人机层由多架无人机组成，主要承担移动接入、任务缓存、接入资源分配和卫星回传调度功能；空间卫星层由低轨卫星组成，主要为无人机提供回传链路和任务处理能力。三层节点之间形成“地面用户-无人机-卫星”的任务传输路径，其中无人机位于地面用户和卫星之间，是连接接入侧与空间侧的关键调度节点。

设地面用户集合为 $\mathcal{K} = \{1, 2, \dots, K\}$ ，其中 K 表示地面用户数量。用户 k 在时隙 t 的水平位置记为 $\mathbf{p}_k^g(t)$ 。设无人机集合为 $\mathcal{U} = \{1, 2, \dots, U\}$ ，其中 U 表示无人机数量。无人机 u 在时隙 t 的水平位置和速度分别记为 $\mathbf{p}_u^u(t)$ 和 $\mathbf{v}_u(t)$ 。本文假设无人机在固定高度附近飞行，因此其主要运动状态可由水平位置和速度描述。设低轨卫星集合为 $\mathcal{L} = \{1, 2, \dots, L\}$ ，其中 L 表示系统可用卫星数量。卫星 ℓ 在时隙 t 的位置记为 $\mathbf{p}_\ell^s(t)$ 。

在该系统中，无人机是主要决策主体。每架无人机根据自身位置、候选用户、可见卫星、邻近无人机和队列状态等局部信息，决定当前时隙的运动控制和卫星回传选择，并在接入带宽调度周期起点确定接入带宽分配。由于多架无人机共享任务区域和卫星回传资源，单个无人机的决策会影响其他无人机的可服务用户、可用链路和系统队列状态，因此该场景具有典型的多智能体协同决策特征。

2.2.2 任务流转与调度流程

本文采用离散时隙模型描述无人机-卫星协同任务调度过程。设系统运行时间划分为 T 个等长时隙，时隙集合记为 $\mathcal{T} = \{0, 1, \dots, T-1\}$ ，单个时隙长度为 τ_0 。在每个时隙内，地面用户根据业务需求产生待处理计算任务。设用户 k 在时隙 t 的任务到达量为 $A_k(t)$ ，单位为 bit，用于表示该时隙新增的待上传数据量。由于不同用户的业务需求和空间位置存在差异，任务到达过程呈现随机性和时变性，系统需要持续根据当前任务负载和网络状态调整调度决策。

在任务流转过程中，系统分别在地面用户侧、无人机侧和卫星侧维护任务队列。设用户 k 在时隙 t 的任务队列长度为 $Q_k^g(t)$ ，无人机 u 的任务队列长度为 $Q_u^a(t)$ ，卫星 ℓ 的任务队列长度为 $Q_\ell^s(t)$ 。其中，地面用户队列用于缓存已经到达但尚未成功上传至无人机的任务数据；无人机队列用于缓存已经完成接入但尚未成功回传至卫星的任务数据；卫星队列用于缓存已经由无人机回传但尚未完成处理的任務数据。因此，任务从产生到完成处理通常需要依次经历“地面用户队列-无人机队列-卫星队列”三个阶段。该流转路径反映了接入链路、回传链路和卫星计算能力之间的串联系统关系，其中任一阶段服务能力不足都可能导致上游队列积压或任务丢弃。

在每个时隙内，无人机需要围绕上述任务流转过程完成协同调度。对于无人机 u ，其在时隙 t 的调度动作可由运动控制动作 $\mathbf{a}_u(t)$ 、接入带宽分配动作 $\beta_u(t)$ 和卫星选择动作 $\mathbf{z}_u(t)$ 共同描述。其中， $\mathbf{a}_u(t)$ 用于调整无人机运动状态，从而影响下一时隙的用户接入关系和链路质量； $\beta_u(t)$ 用于描述无人机对候选地面用户的接入带宽分配，决定地面用户队列向无人机队列转移的任务量； $\mathbf{z}_u(t)$ 用于描述无人机在可见卫星集合中的回传选择，决定无人机队列向卫星队列转移的任务量。上述决策并非相互独立：无人机运动会同时影响用户接入和卫星可见性，接入带宽分配会改变用户侧任务积压，卫星选择会影响无人机侧任务出队能力。因此，本文将该过程视为面向动态队列演化的协同任务调度过程。

当任一层队列长度超过其容量上限时，超出部分任务将被丢弃。因此，系统性能不仅取决于单个时隙内的接入速率或回传速率，还取决于任务能否在地面用户、无人机和卫星之间保持稳定流动。队列积压、任务丢弃和最终处理量共同反映了协同调度策略对系统服务能力的影响，也构成后续模型建立和实验评价的重要依据。

2.3 通信、计算与队列模型

在明确无人机-卫星协同任务调度场景后，本节进一步建立通信、计算与队列演化模型，用于刻画任务在不同网络层级之间的传输和处理过程。在地面用户侧，接入链路模型用于描述用户任务上传至无人机的服务能力；在无人机侧，回传链路模型用于




图 2.2 单时隙任务流转与多级队列演化示意图

描述无人机缓存任务转发至低轨卫星的服务能力；在卫星侧，计算模型用于描述卫星队列中任务完成处理的服务能力。这三类模型共同决定任务在“地面用户-无人机-卫星”路径上的流动速率，也为后续优化目标和评价指标定义提供基础。




图 2.3 接入与回传链路几何示意图

图 2.3 给出了接入链路和回传链路的主要几何关系。对于地面用户到无人机的接入链路，链路距离和仰角共同影响空地传播条件。仰角 $\phi_{k,u}(t)$ 越大，地面遮挡对链路传播的影响通常越弱，链路处于 LoS 状态的概率越高；仰角较小时，链路更容易受到建筑物或地物遮挡，NLoS 传播的影响更加明显。因此，本文采用概率 LoS/NLoS 模型描述接入链路传播状态，并由 LoS 和 NLoS 两种条件下的路径损耗加权得到平均路径损耗。

2.3.1 地面用户到无人机接入模型

地面用户到无人机的接入链路用于描述用户侧任务上传至无人机的过程。用户 k 与无人机 u 之间的水平距离定义为

$$d_{k,u}^{g,u}(t) = \|\mathbf{p}_k^g(t) - \mathbf{p}_u^u(t)\|_2. \quad (2.1)$$

接入关联关系在接入带宽调度周期起点确定，并在同一调度周期内保持不变。记时隙 t 对应的接入带宽调度周期起点为

$$\tau_{bw}(t) = K_{bw} \left\lfloor \frac{t}{K_{bw}} \right\rfloor. \quad (2.2)$$

在本文模型中，用户 k 默认关联到周期起点处距离最近的无人机，其关联无人机可表示为

$$\alpha_k(t) = \arg \min_{u \in \mathcal{U}} d_{k,u}^{g,u}(\tau_{bw}(t)). \quad (2.3)$$

进一步地，为控制单架无人机的观测维度和带宽分配维度，无人机 u 在接入带宽调度周期起点只考虑距离自身最近的至多 K_c 个地面用户，并在周期内沿用该候选用户集合，记为 $\widetilde{\mathcal{K}}_u(t)$ 。因此，无人机 u 的有效接入用户集合可表示为

$$\mathcal{K}_u^{\text{acc}}(t) = \left\{ k \mid k \in \widetilde{\mathcal{K}}_u(t), \alpha_k(t) = u \right\}. \quad (2.4)$$

只有属于 $\mathcal{K}_u^{\text{acc}}(t)$ 的用户，才会在当前接入带宽调度周期内参与无人机 u 的接入带宽分配。同时，接入链路增益和上传速率仍按照当前时隙的用户-无人机几何关系计算。

考虑无人机固定飞行高度为 H ，用户 k 与无人机 u 之间的三维距离为

$$r_{k,u}^{g,u}(t) = \sqrt{\left(d_{k,u}^{g,u}(t)\right)^2 + H^2}. \quad (2.5)$$

对应的仰角为

$$\phi_{k,u}(t) = \arcsin\left(\frac{H}{r_{k,u}^{g,u}(t)}\right). \quad (2.6)$$

在上述几何关系基础上，本文采用概率视距模型描述 LoS 与 NLoS 链路状态^[36]。设链路为 LoS 的概率为

$$P_{k,u}^{\text{LoS}}(t) = \frac{1}{1 + a \exp\left[-b\left(\phi_{k,u}^\circ(t) - a\right)\right]}, \quad (2.7)$$

其中 a 和 b 为环境相关参数， $\phi_{k,u}^\circ(t)$ 表示以角度制表示的仰角。设载波频率为 f_c ，参考频率为 $f_0 = 1 \text{ GHz}$ ，自由空间路径损耗常数为 C_0 ，则 LoS 和 NLoS 条件下的路径损

耗分别为

$$L_{k,u}^{\text{LoS}}(t) = C_0 + 20 \log_{10} \left(\frac{f_c}{f_0} \right) + 20 \log_{10} \left(r_{k,u}^{\text{g},u}(t) \right) + \xi_{\text{LoS}}, \quad (2.8)$$

$$L_{k,u}^{\text{NLoS}}(t) = C_0 + 20 \log_{10} \left(\frac{f_c}{f_0} \right) + 20 \log_{10} \left(r_{k,u}^{\text{g},u}(t) \right) + \xi_{\text{NLoS}}, \quad (2.9)$$

其中 ξ_{LoS} 和 ξ_{NLoS} 分别表示 LoS 和 NLoS 条件下的附加损耗。因此，接入链路的平均大尺度路径损耗可表示为

$$L_{k,u}^{\text{g},u}(t) = P_{k,u}^{\text{LoS}}(t) L_{k,u}^{\text{LoS}}(t) + \left(1 - P_{k,u}^{\text{LoS}}(t) \right) L_{k,u}^{\text{NLoS}}(t), \quad (2.10)$$

对应的大尺度链路增益为

$$\bar{h}_{k,u}^{\text{g},u}(t) = 10^{-L_{k,u}^{\text{g},u}(t)/10}. \quad (2.11)$$

在离散时隙调度模型中，一个调度动作对应时隙内的平均服务能力。因此，本文对接入链路的小尺度 Rician 衰落采用遍历谱效率方式处理，而不是将单次瞬时衰落采样直接作为接入速率^[37]。设 G^R 为均值归一化的 Rician 功率增益，Rician 因子为 K_R 。对于给定平均信噪比 γ ，定义 Rician 遍历谱效率为

$$\mathcal{C}_R(\gamma, K_R) = \mathbb{E}_{G^R} [\log_2 (1 + \gamma G^R)]. \quad (2.12)$$

该处理方式既保留了小尺度 Rician 衰落对平均接入能力的影响，又避免了单次瞬时信道采样对时隙级调度评价造成过强随机扰动。

设无人机 u 可用于地面接入的总带宽为 $B^{\text{g},u}$ 。 $\beta_u(t)$ 表示无人机 u 在时隙 t 实际执行的接入带宽比例。该比例在接入带宽调度周期起点生成，并在周期内后续时隙沿用周期起点处的结果。对于有效接入用户 $k \in \mathcal{K}_u^{\text{acc}}(t)$ ，记归一化后的带宽比例为 $\beta_{k,u}(t)$ ，其满足

$$\beta_{k,u}(t) \geq 0, \quad \sum_{k \in \mathcal{K}_u^{\text{acc}}(t)} \beta_{k,u}(t) \leq 1. \quad (2.13)$$

用户 k 从无人机 u 获得的接入带宽为

$$B_{k,u}^{\text{g},u}(t) = \beta_{k,u}(t) B^{\text{g},u}. \quad (2.14)$$

由于多架无人机可能在同一区域内同时接收地面用户上传任务，关联到其他无人机的地面用户会对无人机 u 的接收端产生同频干扰。设用户 j 关联到无人机 $\alpha_j(t)$ ，且其带宽分配比例为 $\beta_{j,\alpha_j(t)}(t)$ ，则无人机 u 接收端受到的接入干扰功率可表示为

$$I_u^{\text{g},u}(t) = \sum_{\substack{j \in \mathcal{K} \\ \alpha_j(t) \neq u}} P_j^{\text{g}} \beta_{j,\alpha_j(t)}(t) \bar{h}_{j,u}^{\text{g},u}(t). \quad (2.15)$$

同一无人机服务的用户通过接入带宽分配进行区分，因此不计入上述跨无人机接入干扰项。

设地面用户发射功率为 P^g ，噪声功率谱密度为 N_0 。对于获得非零接入带宽的用户，用户 k 到无人机 u 的平均接入信干噪比可表示为

$$\gamma_{k,u}^{g,u}(t) = \frac{P^g \bar{h}_{k,u}^{g,u}(t)}{N_0 B_{k,u}^{g,u}(t) + \beta_{k,u}(t) I_u^{g,u}(t)}. \quad (2.16)$$

结合前述 Rician 遍历谱效率，用户 k 到无人机 u 的接入速率为

$$R_{k,u}^{g,u}(t) = B_{k,u}^{g,u}(t) \mathcal{C}_R \left(\gamma_{k,u}^{g,u}(t), K_R \right). \quad (2.17)$$

对于 $k \notin \mathcal{K}_u^{\text{acc}}(t)$ 的用户，令 $\beta_{k,u}(t) = 0$ ，其对应接入速率为零。

由于用户侧任务队列长度有限，实际上传任务量同时受到接入速率和队列积压的限制。设用户 k 在时隙 t 经无人机 u 成功上传的任务量为 $D_{k,u}^{g,u}(t)$ ，则有

$$D_{k,u}^{g,u}(t) = \min \left\{ Q_k^g(t) + A_k(t), R_{k,u}^{g,u}(t) \tau_0 \right\}, \quad k \in \mathcal{K}_u^{\text{acc}}(t). \quad (2.18)$$

对于未被无人机 u 有效接入的用户，令 $D_{k,u}^{g,u}(t) = 0$ 。由此，用户 k 在时隙 t 的总上传任务量可表示为

$$D_k^{g,u}(t) = \sum_{u \in \mathcal{U}} D_{k,u}^{g,u}(t). \quad (2.19)$$

2.3.2 无人机到卫星回传模型

无人机到卫星的回传链路用于描述无人机队列中的任务向低轨卫星转发的过程。在时隙 t ，无人机 u 的三维位置记为 $\mathbf{p}_u^{u,3D}(t)$ ，卫星 ℓ 的三维位置记为 $\mathbf{p}_\ell^s(t)$ 。二者之间的距离为

$$d_{u,\ell}^{u,s}(t) = \left\| \mathbf{p}_\ell^s(t) - \mathbf{p}_u^{u,3D}(t) \right\|_2. \quad (2.20)$$

设 $\mathbf{e}_u^{\text{up}}$ 表示无人机所在位置的本地竖直向上单位向量，则无人机 u 观测卫星 ℓ 的仰角可表示为

$$\theta_{u,\ell}(t) = \arcsin \left(\frac{\left(\mathbf{p}_\ell^s(t) - \mathbf{p}_u^{u,3D}(t) \right)^T \mathbf{e}_u^{\text{up}}}{d_{u,\ell}^{u,s}(t)} \right). \quad (2.21)$$

当 $\theta_{u,\ell}(t)$ 不小于最小仰角门限 $\theta_{\min}$ 时，认为卫星 ℓ 对无人机 u 可见。因此，无人机 u 在时隙 t 的可见卫星集合可表示为

$$\mathcal{L}_u^{\text{vis}}(t) = \left\{ \ell \in \mathcal{L} \mid \theta_{u,\ell}(t) \geq \theta_{\min} \right\}. \quad (2.22)$$

本文将卫星选择建模为离散动作。在可见卫星集合基础上，无人机需要进一步确

定当前时隙的回传目标。设 $z_{u,\ell}(t) \in \{0, 1\}$ 表示无人机 u 是否在时隙 t 选择卫星 ℓ 进行回传，当 $z_{u,\ell}(t) = 1$ 时表示选中该卫星，否则表示未选中。由于无人机的射频链路数量和并行连接能力有限，单架无人机在同一时隙内最多选择 N_{RF} 颗卫星，因此有

$$\sum_{\ell \in \mathcal{L}} z_{u,\ell}(t) \leq N_{\text{RF}}. \quad (2.23)$$

同时，卫星选择必须满足可见性约束：

$$z_{u,\ell}(t) = 0, \quad \ell \notin \mathcal{L}_u^{\text{vis}}(t). \quad (2.24)$$

记无人机 u 在时隙 t 的实际回传卫星集合为

$$\mathcal{L}_u^{\text{sel}}(t) = \{\ell \in \mathcal{L}_u^{\text{vis}}(t) \mid z_{u,\ell}(t) = 1\}. \quad (2.25)$$

对于被选中的卫星回传链路，设无人机发射端和卫星接收端的等效天线增益分别为 G^u 和 G^s 。考虑自由空间传播、大气损耗和雨衰损耗后^[38–40]，无人机 u 到卫星 ℓ 的回传链路增益可表示为

$$h_{u,\ell}^{u,s}(t) = \frac{G^u G^s}{\left(d_{u,\ell}^{u,s}(t)\right)^2} 10^{-\frac{L_{u,\ell}^{\text{atm}}(t) + L_{u,\ell}^{\text{rain}}(t)}{10}}. \quad (2.26)$$

其中， $L_{u,\ell}^{\text{atm}}(t)$ 表示大气损耗，主要随卫星仰角 $\theta_{u,\ell}(t)$ 变化； $L_{u,\ell}^{\text{rain}}(t)$ 表示雨衰损耗，与载波频率、仰角、降雨强度和传播路径长度有关。

设每颗卫星可用于接收无人机回传的总带宽为 $B^{u,s}$ 。当多架无人机同时选择同一颗卫星时，该卫星回传带宽在连接无人机之间共享。记选择卫星 ℓ 的无人机数量为

$$n_\ell(t) = \sum_{u \in \mathcal{U}} z_{u,\ell}(t), \quad (2.27)$$

则无人机 u 从卫星 ℓ 获得的回传带宽为

$$B_{u,\ell}^{u,s}(t) = \frac{B^{u,s}}{\max\{n_\ell(t), 1\}} z_{u,\ell}(t). \quad (2.28)$$

低轨卫星高速运动会导致回传链路存在多普勒频移^[38]。设补偿后的残余多普勒频移为 $\tilde{\nu}_{u,\ell}(t)$ ，子载波间隔为 Δf ，多普勒引起的有效信噪比衰减系数为

$$\eta_{u,\ell}^D(t) = \text{sinc}^2\left(\frac{\tilde{\nu}_{u,\ell}(t)}{\Delta f}\right). \quad (2.29)$$

当 $|\tilde{\nu}_{u,\ell}(t)| > \nu_{\text{max}}$ 时，该链路在当前时隙视为不可用。设无人机回传发射功率为 P^u 。对

于获得非零回传带宽的选中链路，无人机 u 到卫星 ℓ 的回传信噪比为

$$\gamma_{u,\ell}^{u,s}(t) = \frac{P^u h_{u,\ell}^{u,s}(t)}{N_0 B_{u,\ell}^{u,s}(t)} \eta_{u,\ell}^D(t). \quad (2.30)$$

对应的回传速率为

$$R_{u,\ell}^{u,s}(t) = B_{u,\ell}^{u,s}(t) \log_2 \left(1 + \gamma_{u,\ell}^{u,s}(t) \right). \quad (2.31)$$

无人机实际回传任务量受到无人机侧可用任务量和回传链路总服务能力的共同限制。无人机 u 在时隙 t 可用于回传的任务量由其已有队列和接入侧新上传任务共同构成：

$$Q_u^{\text{avail}}(t) = Q_u^u(t) + \sum_{k \in \mathcal{K}} D_{k,u}^{g,u}(t). \quad (2.32)$$

无人机 u 在当前时隙的总回传速率为

$$R_u^{u,s}(t) = \sum_{\ell \in \mathcal{L}} R_{u,\ell}^{u,s}(t). \quad (2.33)$$

因此，无人机 u 的实际总回传任务量为

$$D_u^{u,s}(t) = \min \left\{ Q_u^{\text{avail}}(t), R_u^{u,s}(t) \tau_0 \right\}. \quad (2.34)$$

当 $R_u^{u,s}(t) > 0$ 时，实际回传任务量按照各卫星链路速率占比分配：

$$D_{u,\ell}^{u,s}(t) = \frac{R_{u,\ell}^{u,s}(t)}{R_u^{u,s}(t)} D_u^{u,s}(t). \quad (2.35)$$

若 $R_u^{u,s}(t) = 0$ ，则 $D_{u,\ell}^{u,s}(t) = 0$ 。

2.3.3 卫星计算与多级队列演化

卫星侧接收无人机回传任务后，需要将任务放入卫星队列并进行计算处理。设卫星 ℓ 的计算频率为 f_ℓ^s ，单位为 cycles/s，每 bit 任务所需 CPU 周期数为 κ 。在一个长度为 τ_0 的时隙内，卫星 ℓ 的最大计算处理能力可表示为

$$C_\ell^s(t) = \frac{f_\ell^s \tau_0}{\kappa}. \quad (2.36)$$

设卫星 ℓ 在时隙 t 实际处理完成的任务量为 $D_\ell^{\text{proc}}(t)$ 。该处理量受到卫星计算能力、已有卫星队列以及当前时隙回传到达任务量的共同限制，因此有

$$D_\ell^{\text{proc}}(t) = \min \left\{ Q_\ell^s(t) + \sum_{u \in \mathcal{U}} D_{u,\ell}^{u,s}(t), C_\ell^s(t) \right\}. \quad (2.37)$$

设地面用户队列容量上限为 $Q_{\max}^g$ 。在时隙 t ，用户 k 的队列接收新到达任务 $A_k(t)$ ，并根据接入链路实际上传任务量 $D_k^{g,u}(t)$ 完成出队。因此，服务后的临时队列长度可表示为

$$\tilde{Q}_k^g(t+1) = [Q_k^g(t) + A_k(t) - D_k^{g,u}(t)]^+, \quad (2.38)$$

其中 $[x]^+ = \max\{x, 0\}$ 。若临时队列长度超过容量上限，则超出部分被丢弃。地面用户侧丢弃任务量为

$$D_k^{\text{drop},g}(t) = [\tilde{Q}_k^g(t+1) - Q_{\max}^g]^+. \quad (2.39)$$

因此，用户队列更新为

$$Q_k^g(t+1) = \min\{\tilde{Q}_k^g(t+1), Q_{\max}^g\}. \quad (2.40)$$

设无人机队列容量上限为 $Q_{\max}^u$ 。无人机 u 在时隙 t 接收来自其关联用户的上传任务，其接入侧流入任务量为

$$D_u^{\text{in}}(t) = \sum_{k \in \mathcal{K}} D_{k,u}^{g,u}(t). \quad (2.41)$$

同时，无人机通过回传链路向卫星转发任务，其总回传任务量为 $D_u^{u,s}(t)$ 。因此，回传服务后的临时无人机队列长度为

$$\tilde{Q}_u^u(t+1) = [Q_u^u(t) + D_u^{\text{in}}(t) - D_u^{u,s}(t)]^+. \quad (2.42)$$

无人机侧丢弃任务量为

$$D_u^{\text{drop},u}(t) = [\tilde{Q}_u^u(t+1) - Q_{\max}^u]^+. \quad (2.43)$$

因此，无人机队列更新为

$$Q_u^u(t+1) = \min\{\tilde{Q}_u^u(t+1), Q_{\max}^u\}. \quad (2.44)$$

设卫星队列容量上限为 $Q_{\max}^s$ 。卫星 ℓ 在时隙 t 接收来自各无人机的回传任务，其回传侧流入任务量为

$$D_{\ell}^{\text{in}}(t) = \sum_{u \in \mathcal{U}} D_{u,\ell}^{u,s}(t). \quad (2.45)$$

卫星完成计算处理后，临时卫星队列长度为

$$\tilde{Q}_{\ell}^s(t+1) = [Q_{\ell}^s(t) + D_{\ell}^{\text{in}}(t) - D_{\ell}^{\text{proc}}(t)]^+. \quad (2.46)$$

卫星侧丢弃任务量为

$$D_{\ell}^{\text{drop},s}(t) = [\tilde{Q}_{\ell}^s(t+1) - Q_{\max}^s]^+. \quad (2.47)$$

因此，卫星队列更新为

$$Q_{\ell}^s(t+1) = \min \left\{ \tilde{Q}_{\ell}^s(t+1), Q_{\max}^s \right\}. \quad (2.48)$$

由上述队列更新过程可见，系统的任务处理能力取决于接入、回传和卫星计算三个环节之间的匹配关系。当接入链路服务能力高于回传链路服务能力时，无人机侧队列容易积压；当回传链路服务能力高于卫星计算处理能力时，卫星侧队列可能持续增长；当地面用户侧接入服务能力不足时，用户侧队列会不断累积。当任一层队列超过容量上限时，系统会产生任务丢弃。因此，协同调度策略不仅需要提高单个链路的瞬时传输速率，还需要在地面用户、无人机和卫星之间保持任务流动平衡。本文后续将从任务吞吐、队列积压、任务丢弃和最终处理能力等方面评价调度策略的效果。

2.4 运动、可见性与安全约束

在前述通信、计算与队列模型中，任务流动能力主要由接入链路、回传链路和卫星计算能力决定。但在无人机-卫星协同任务调度场景中，调度动作还需要满足运动学、卫星可见性和安全性等物理约束。无人机运动控制受到速度、加速度和服务区域边界限制；卫星回传选择受到可见性、连接数量和多普勒门限限制；多无人机协同过程中还需要把安全间隔纳入约束，以避免无人机距离过近。上述限制共同收缩智能体可以选择的动作范围，并构成第三章动作可行性处理与动作修正机制的建模基础。

2.4.1 无人机运动约束

无人机运动状态直接影响地面用户关联关系、接入链路质量以及卫星可见集合。本文假设无人机在固定高度附近飞行，并在水平平面内进行运动控制。设无人机 u 在时隙 t 的水平位置和速度分别为 $\mathbf{p}_u^h(t)$ 和 $\mathbf{v}_u(t)$ ，其运动控制动作为加速度 $\mathbf{a}_u(t)$ 。在时隙长度为 τ_0 的离散时间模型下，无人机运动状态更新为

$$\mathbf{v}_u(t+1) = \mathbf{v}_u(t) + \mathbf{a}_u(t)\tau_0, \quad (2.49)$$

$$\mathbf{p}_u^h(t+1) = \mathbf{p}_u^h(t) + \mathbf{v}_u(t+1)\tau_0. \quad (2.50)$$

无人机运动控制需要满足最大速度和最大加速度约束。设最大速度为 $v_{\max}$ ，最大加速度为 $a_{\max}$ ，则有

$$\|\mathbf{v}_u(t)\|_2 \leq v_{\max}, \quad (2.51)$$

$$\|\mathbf{a}_u(t)\|_2 \leq a_{\max}. \quad (2.52)$$

同时，无人机需要在给定任务区域内飞行。设任务区域为 Ω ，则无人机位置需要满足

$$\mathbf{p}_u^u(t) \in \Omega, \quad \forall u \in \mathcal{U}. \quad (2.53)$$

在实际执行过程中，若策略输出动作导致速度、加速度或位置超出可行范围，系统需要对动作或状态进行裁剪、投影或边界修正，以保证无人机运动满足物理约束。

2.4.2 卫星可见性与连接约束

卫星回传选择受到可见性、连接数量和链路可用性的共同限制。根据第 2.3.2 节定义的可见卫星集合 $\mathcal{L}_u^{\text{vis}}(t)$ ，无人机只能从当前可见卫星中选择回传目标。因此，对于任意 $\ell \notin \mathcal{L}_u^{\text{vis}}(t)$ ，卫星选择变量必须满足

$$z_{u,\ell}(t) = 0. \quad (2.54)$$

同时，受射频链路数量限制，单架无人机在同一时隙内最多连接 N_{RF} 颗卫星：

$$\sum_{\ell \in \mathcal{L}} z_{u,\ell}(t) \leq N_{\text{RF}}. \quad (2.55)$$

除几何可见性外，低轨卫星高速运动带来的残余多普勒频移也会影响回传链路可用性。第 2.3.2 节已将残余多普勒频移造成的信噪比衰减纳入回传速率模型；进一步地，当 $|\tilde{v}_{u,\ell}(t)| > v_{\text{max}}$ 时，该链路在当前时隙视为不可用。因此，实际可选卫星集合可表示为

$$\mathcal{L}_u^{\text{feas}}(t) = \{\ell \in \mathcal{L}_u^{\text{vis}}(t) \mid |\tilde{v}_{u,\ell}(t)| \leq v_{\text{max}}\}. \quad (2.56)$$

对于任意 $\ell \notin \mathcal{L}_u^{\text{feas}}(t)$ ，均有 $z_{u,\ell}(t) = 0$ 。上述约束是第三章离散动作可行性处理机制的重要依据。

2.4.3 无人机安全距离约束

多无人机协同飞行时需要避免无人机之间距离过近导致碰撞风险。设无人机间最小安全距离为 d_{safe} ，则任意两架不同无人机 u 和 v 在时隙 t 应满足

$$\|\mathbf{p}_u^u(t) - \mathbf{p}_v^v(t)\|_2 \geq d_{\text{safe}}, \quad u \neq v. \quad (2.57)$$

若策略输出的运动动作可能导致下一时隙无人机间距离低于安全阈值，系统需要优先进行安全修正或将该动作判定为不满足安全约束。该约束使无人机在提升接入吞吐和回传能力的同时，必须保持空间协同的安全性。

2.5 协同任务调度问题形式化

基于前述通信、计算、队列演化和物理约束模型，本节将无人机-卫星协同任务调度问题进一步形式化为多智能体序贯决策问题。在该问题中，每架无人机作为一个智能体，需要在局部观测条件下协调运动控制、接入带宽分配和卫星回传选择，其中运动控制和卫星回传选择按时隙决策，接入带宽分配按调度周期决策。由于无人机之间共享任务区域、地面用户和卫星回传资源，单个智能体动作会影响其他智能体的链路状态、队列状态和后续可行动作集合。因此，该问题具有部分可观测、多智能体相互影响和连续-离散混合动作空间等特点。

2.5.1 状态空间与观测信息

在时隙 t ，系统全局状态需要同时刻画节点自身状态和节点间关系状态。从节点自身状态看，地面用户状态包括用户位置、任务到达和用户侧队列长度；无人机状态包括无人机位置、速度、无人机侧队列长度和运动约束状态；卫星状态包括卫星位置、卫星队列长度和计算处理能力。从节点间关系看，系统状态还包括地面用户与无人机之间的接入关联关系、接入链路状态和候选用户有效性信息，无人机与卫星之间的可见性关系、回传链路状态和可选卫星有效性信息，以及无人机之间的相对位置和安全距离关系。因此，本文将全局状态抽象表示为

$$s(t) = (s^g(t), s^u(t), s^s(t), e^{g,u}(t), e^{u,s}(t), e^{u,u}(t)), \quad (2.58)$$

其中， $s^g(t)$ 、 $s^u(t)$ 和 $s^s(t)$ 分别表示地面用户、无人机和卫星的节点状态； $e^{g,u}(t)$ 表示地面用户与无人机之间的接入关系和链路状态； $e^{u,s}(t)$ 表示无人机与卫星之间的可见性和回传链路状态； $e^{u,u}(t)$ 表示无人机之间的邻近关系和安全约束状态。

在分布式执行阶段，单架无人机通常无法直接获得完整全局状态，而是基于自身可观测范围内的信息进行决策。记无人机 u 在时隙 t 的局部观测为 $o_u(t)$ ，其可抽象表示为

$$o_u(t) = (o_u^{\text{self}}(t), o_u^g(t), o_u^s(t), o_u^{\text{nbr}}(t), m_u^g(t), m_u^s(t)). \quad (2.59)$$

其中， $o_u^{\text{self}}(t)$ 表示无人机自身位置、速度和队列等状态； $o_u^g(t)$ 表示候选地面用户的位置、队列和接入链路信息； $o_u^s(t)$ 表示可见卫星的位置、队列和回传链路信息； $o_u^{\text{nbr}}(t)$ 表示邻近无人机的相对位置和安全距离信息。 $m_u^g(t)$ 和 $m_u^s(t)$ 分别表示候选用户和可选卫星的有效性信息。本文将此类用于标识候选实体是否存在、动作是否可行的二值信息称为掩码。其中，带宽掩码用于标识当前接入带宽调度周期内可参与带宽分配的候选用户，卫星掩码用于标识当前时隙可参与回传选择的候选卫星。由于候选用户数量和可见卫星数量会随无人机位置和卫星运动状态变化，掩码信息为后续动作空间定义和

约束处理提供依据。

2.5.2 决策变量与动作空间

在离散时隙 t 中，无人机智能体需要围绕运动控制、接入带宽分配和卫星回传选择进行协同决策。其中，运动控制和卫星回传选择按时隙更新；接入关联和接入带宽分配按长度为 K_{bw} 的调度周期更新。记当前时隙对应的接入带宽调度周期起点为

$$\tau_{bw}(t) = K_{bw} \left\lfloor \frac{t}{K_{bw}} \right\rfloor. \quad (2.60)$$

在周期起点，接入关系由用户和无人机之间的位置关系确定，并生成新的接入带宽比例；在周期内后续时隙，沿用周期起点处的接入关系和带宽比例。因此，无人机 u 在时隙 t 的执行动作可表示为

$$\mathbf{a}_u^{\text{act}}(t) = (\mathbf{a}_u(t), \boldsymbol{\beta}_u(t), \mathbf{z}_u(t)), \quad (2.61)$$

其中， $\mathbf{a}_u(t)$ 表示连续运动控制动作， $\boldsymbol{\beta}_u(t)$ 表示时隙 t 实际执行的接入带宽比例， $\mathbf{z}_u(t)$ 表示卫星选择动作。这里的 $\boldsymbol{\beta}_u(t)$ 可能来自周期起点处的新决策，也可能来自同一周期内的复用结果。全体无人机的联合动作记为

$$\mathbf{a}^{\text{act}}(t) = (\mathbf{a}_1^{\text{act}}(t), \mathbf{a}_2^{\text{act}}(t), \dots, \mathbf{a}_U^{\text{act}}(t)). \quad (2.62)$$

其中，运动控制动作 $\mathbf{a}_u(t)$ 为连续二维加速度向量，需要满足第 2.4.1 节给出的加速度、速度和边界约束。带宽分配动作 $\boldsymbol{\beta}_u(t)$ 为连续比例向量，仅对时隙 t 实际执行的有效接入用户集合 $\mathcal{K}_u^{\text{acc}}(t)$ 生效。该集合在接入带宽调度周期起点由用户和无人机之间的位置关系确定，并在周期内保持不变。带宽比例满足非负性和总带宽约束：

$$\beta_{k,u}(t) \geq 0, \quad \sum_{k \in \mathcal{K}_u^{\text{acc}}(t)} \beta_{k,u}(t) \leq 1. \quad (2.63)$$

卫星选择动作 $\mathbf{z}_u(t)$ 为离散选择向量，需要满足可见性、多普勒门限和连接数量约束：

$$z_{u,\ell}(t) \in \{0, 1\}, \quad z_{u,\ell}(t) = 0, \ell \notin \mathcal{L}_u^{\text{feas}}(t), \quad (2.64)$$

$$\sum_{\ell \in \mathcal{L}} z_{u,\ell}(t) \leq N_{\text{RF}}. \quad (2.65)$$

由此可见，本文动作空间同时包含连续控制变量、连续资源分配变量和离散组合选择变量，具有典型的混合动作空间特征。

2.5.3 优化目标与约束条件

本文研究的协同任务调度问题是在动态任务到达、无人机运动受限和卫星可见性时变的条件下，联合优化无人机运动控制、地面接入带宽分配和卫星回传选择，使任务尽可能沿地面用户、无人机和卫星计算节点逐级流转，并降低系统中的队列时间负载和任务丢弃。

为统一刻画不同层队列中任务造成的时间占用压力，本文引入队列时间负载^[6]。设 $c_k^g(t)$ 、 $c_u^u(t)$ 和 $c_\ell^s(t)$ 分别表示地面用户队列、无人机队列和卫星队列中单位任务对应的后续服务时间代价。其中，卫星队列中的任务主要等待卫星计算处理；无人机队列中的任务还需要经过回传链路和卫星计算节点；地面用户队列中的任务则需要依次经过接入链路、回传链路和卫星计算节点。因此，上游队列中的任务对应的时间代价应包含其后续传输和处理阶段的综合影响。在具体计算时， $c_\ell^s(t)$ 可由卫星计算服务能力确定， $c_u^u(t)$ 可由回传服务能力和所选卫星的后续处理代价共同确定， $c_k^g(t)$ 可由接入服务能力和关联无人机的后续处理代价共同确定。

系统在时隙 t 队列更新后的队列时间负载定义为

$$W(t+1) = \sum_{k \in \mathcal{K}} c_k^g(t) Q_k^g(t+1) + \sum_{u \in \mathcal{U}} c_u^u(t) Q_u^u(t+1) + \sum_{\ell \in \mathcal{L}} c_\ell^s(t) Q_\ell^s(t+1). \quad (2.66)$$

若本时隙三层队列中的任务丢弃量分别为 $D_k^{\text{drop},g}(t)$ 、 $D_u^{\text{drop},u}(t)$ 和 $D_\ell^{\text{drop},s}(t)$ ，则丢弃任务对应的时间负载损失为

$$\Phi(t) = \sum_{k \in \mathcal{K}} c_k^g(t) D_k^{\text{drop},g}(t) + \sum_{u \in \mathcal{U}} c_u^u(t) D_u^{\text{drop},u}(t) + \sum_{\ell \in \mathcal{L}} c_\ell^s(t) D_\ell^{\text{drop},s}(t). \quad (2.67)$$

因此，本文的协同任务调度问题可表示为

$$\min_{\pi} \mathbb{E}_{\pi} \left[\frac{1}{T} \sum_{t=0}^{T-1} (W(t+1) + \Phi(t)) \right], \quad (2.68)$$

其中 π 表示多无人机协同调度策略。该目标强调在整个调度时域内降低系统待处理任务形成的平均队列时间负载，并对因队列容量受限造成的任务丢弃进行惩罚。

上述优化问题需要满足接入带宽、卫星回传、队列容量、无人机运动和安全距离等约束。接入带宽分配满足

$$\sum_{k \in \mathcal{K}_u^{\text{acc}}(t)} \beta_{k,u}(t) \leq 1, \quad \beta_{k,u}(t) \geq 0, \quad \forall u \in \mathcal{U}. \quad (2.69)$$

卫星回传选择满足

$$z_{u,\ell}(t) \in \{0, 1\}, \quad z_{u,\ell}(t) = 0, \ell \notin \mathcal{L}_u^{\text{feas}}(t), \quad \sum_{\ell \in \mathcal{L}} z_{u,\ell}(t) \leq N_{\text{RF}}. \quad (2.70)$$

队列容量满足

$$0 \leq Q_k^g(t) \leq Q_{\max}^g, \quad 0 \leq Q_u^u(t) \leq Q_{\max}^u, \quad 0 \leq Q_\ell^s(t) \leq Q_{\max}^s. \quad (2.71)$$

无人机运动满足

$$\|\mathbf{v}_u(t)\|_2 \leq v_{\max}, \quad \|\mathbf{a}_u(t)\|_2 \leq a_{\max}, \quad \mathbf{p}_u^u(t) \in \Omega. \quad (2.72)$$

无人机之间需要满足安全距离约束

$$\|\mathbf{p}_u^u(t) - \mathbf{p}_v^u(t)\|_2 \geq d_{\text{safe}}, \quad \forall u, v \in \mathcal{U}, u \neq v. \quad (2.73)$$

其中, Ω 表示无人机允许飞行区域, $\mathcal{L}_u^{\text{feas}}(t)$ 表示满足可见性、多普勒门限和链路可用条件的卫星集合。若某一联合动作不满足上述硬约束, 则该动作不属于可行调度动作集合; 在实际求解时, 可通过动作掩码、动作裁剪或安全修正保证策略输出满足可行性要求。

2.5.4 多智能体决策建模

在上述状态空间、动作空间和优化目标的基础上, 本文将无人机-卫星协同任务调度问题建模为多智能体部分可观测马尔可夫决策过程。该类模型常用于刻画多智能体在不完全信息条件下的协同序贯决策问题^[41]。其中, 每架无人机作为一个智能体, 在每个离散时隙根据自身局部观测选择运动控制和卫星回传动作; 对于接入带宽分配, 仅在接入带宽调度周期起点根据局部观测生成新的带宽比例, 周期内后续时隙沿用该周期起点处的接入关系和带宽比例; 环境根据所有无人机的联合动作完成无人机运动更新、链路服务计算、任务流转和队列演化, 并转移到下一系统状态。由于单架无人机只能获得局部网络状态, 且其决策会通过用户接入、卫星回传竞争和安全距离约束影响其他无人机的可行决策空间, 因此该问题具有典型的多智能体协同决策特征。

形式化地, 该问题可表示为 $\mathcal{M} = \langle \mathcal{U}, \mathcal{S}, \{\mathcal{O}_u\}_{u \in \mathcal{U}}, \{\mathcal{A}_u\}_{u \in \mathcal{U}}, \mathbf{P}, \mathbf{C} \rangle$ 。其中, $\mathcal{U}$ 为智能体集合, $\mathcal{S}$ 为全局状态空间, $\mathcal{O}_u$ 为无人机 u 的局部观测空间, $\mathcal{A}_u$ 为无人机 u 的动作空间。 $P(s(t+1) | s(t), \mathbf{a}^{\text{act}}(t))$ 表示在联合动作 $\mathbf{a}^{\text{act}}(t) = \{\mathbf{a}_u^{\text{act}}(t)\}_{u \in \mathcal{U}}$ 作用下的状态转移概率。 $\mathbf{C}(t) = \mathbf{W}(t+1) + \Phi(t)$ 表示当前时隙对应的系统调度代价, 用于刻画队列更新后的队列时间负载和任务丢弃造成的时间负载损失。

由于该模型同时包含连续运动控制、连续带宽分配和离散卫星选择, 且状态转移

受到无线信道、卫星可见性、任务到达和多层队列共同影响，直接采用集中式优化方法求解较为困难。因此，本文在第三章中进一步采用集中式训练、分布式执行的多智能体强化学习方法：训练阶段利用全局状态和联合动作学习协同调度策略，执行阶段每架无人机仅依据自身局部观测独立生成动作，从而适应动态网络环境下的分布式调度需求^[8]。

2.6 本章小结

本章围绕无人机-卫星协同任务调度问题建立系统模型，并完成问题形式化。在网络场景方面，本章描述由地面用户、无人机和低轨卫星组成的三层协同结构，明确无人机在地面接入、任务缓存和卫星回传中的调度作用。在任务传输与处理方面，本章分别建立地面用户到无人机的接入模型、无人机到卫星的回传模型以及卫星计算和多级队列演化模型，刻画任务从产生、上传、回传到处理的流转过程。在约束建模方面，本章说明无人机运动、卫星可见性、回传连接和安全距离等条件对动作可行范围的限制。随后，本章结合状态空间、动作空间以及由队列时间负载和任务丢弃造成的时间负载损失构成的优化目标，把协同任务调度问题形式化为多智能体部分可观测马尔可夫决策过程。

第三章 基于结构化多智能体强化学习的无人机-卫星协同任务调度算法设计

3.1 引言

在第二章系统建模基础上,本章设计面向无人机-卫星协同任务调度的结构化多智能体强化学习算法。在该场景中,低轨卫星提供随时间变化的回传链路和任务处理能力,多架无人机作为主要决策主体,需要根据自身局部观测进行运动控制、卫星回传选择和接入带宽分配。由于无人机位置、用户关联关系、卫星可见集合和多级任务队列都会随时隙变化,某一时隙的局部动作还会继续影响后续链路状态和队列演化,因此算法设计需要同时考虑动态性、时序关联性和多智能体协同性。

该调度场景难以直接通过传统优化方法进行在线求解。运动控制和带宽分配属于连续决策,卫星回传选择属于离散决策,三类动作共同构成连续-离散混合动作空间;卫星可见性、候选用户集合和安全距离等约束随系统状态变化,使可行动作集合具有时变性。此外,多架无人机共享用户服务区域和卫星回传资源,单个无人机的决策会影响其他无人机的接入机会、回传链路和队列状态,进一步增加了集中求解的复杂度。

针对上述特点,本文采用集中式训练、分布式执行框架下的多智能体强化学习方法进行求解^[8]。训练阶段利用全局状态估计团队价值,以缓解多智能体学习过程中的非平稳性;执行阶段每架无人机仅依据自身局部观测独立输出动作,以满足分布式调度需求。在具体算法上,本文以 **MAPPO** 为基础^[9],将无人机协同调度问题中的观测结构、动作结构和约束结构显式融入策略网络和动作处理流程。

本章其余内容安排如下。第 3.2 节给出结构化多智能体强化学习调度框架,说明集中式训练与分布式执行机制和单时隙协同调度流程;第 3.3 节设计面向异构实体的结构化观测编码方法,包括局部观测信息构成、候选实体编码、掩码表示和 Actor-Critic 网络结构;第 3.4 节定义连续-离散混合动作空间,分别描述无人机运动控制、卫星回传选择和接入带宽分配动作;第 3.5 节给出约束感知动作处理机制,包括动作掩码、连续动作边界处理和安全约束修正;第 3.6 节构造队列感知策略优化方法,说明队列感知奖励、安全修正辅助监督、**MAPPO** 策略优化目标以及集中式训练与分布式执行过程;第 3.7 节对本章内容进行总结。

3.2 结构化多智能体强化学习调度框架

本节说明结构化多智能体强化学习调度算法的总体框架。本文从观测表示、网络结构和动作生成过程三个层面设计结构化多智能体强化学习方法。在观测表示方面，无人机自身状态、候选地面用户、可见卫星和邻近无人机分别对应不同物理实体，其特征维度、数量变化方式和可行性约束并不相同，因此需要分别组织和编码。在网络结构方面，Actor-Critic 网络按照运动控制、卫星选择和接入带宽分配三个调度阶段构造。三类动作的变量类型、约束形式和回报影响强度不同，分阶段结构分别处理不同动作的策略分布、价值估计和更新样本，降低不同动作更新之间的相互干扰。在动作生成方面，策略输出在进入环境状态更新前结合卫星可见性、带宽分配约束、运动边界和安全距离约束进行处理，得到满足当前时隙条件的可执行调度动作。该框架以第二章定义的局部观测、联合动作和系统调度代价为基础，把每架无人机建模为一个智能体，并采用集中式训练、分布式执行方式学习协同调度策略。在时隙级调度过程中，无人机策略根据自身观测生成运动控制、卫星回传选择和接入带宽分配相关动作。其中，运动控制和卫星回传选择按时隙更新；接入关联和接入带宽分配按接入带宽调度周期更新。环境根据各无人机形成的联合执行动作更新无人机位置、链路状态、任务流转和多级队列，并依据队列变化和任务丢弃计算当前时隙奖励信号。本节分别说明集中式训练与分布式执行框架和单时隙协同调度流程。

3.2.1 集中式训练与分布式执行框架

在多无人机协同调度场景中，单架无人机的动作不仅影响自身服务能力，也会通过用户关联关系、卫星回传竞争和安全距离约束影响其他无人机的可行决策空间。若各无人机完全独立学习策略，则难以准确评估局部动作对全局队列流动和共享资源利用的长期影响；若在执行阶段依赖集中控制器直接给出所有无人机动作，则会增加在线通信和部署复杂度。基于上述考虑，本文采用集中式训练、分布式执行框架。在本文方法中，集中式训练阶段利用全局状态、各无人机局部观测、阶段动作和团队奖励等信息更新共享 Actor 和集中式 Critic；分布式执行阶段，每架无人机仅依据自身局部观测生成运动控制、卫星回传选择和接入带宽分配相关动作。这样，训练过程可以利用多无人机协同调度中的全局信息，执行过程则保持无人机本地决策形式。

在上述集中式训练、分布式执行框架下，本文采用 MAPPO 作为策略优化基础。本文选择 MAPPO，主要考虑到所研究的调度动作同时包含连续运动控制、离散卫星选择和连续接入带宽分配。三类动作的变量类型、约束形式和概率分布不同，需要在统一训练框架下分别建模其动作生成过程。MAPPO 基于随机策略进行策略优化，能够分别为不同动作阶段构造相应的动作分布，并通过 PPO 裁剪目标限制单次策略更新幅度，适




图 3.1 结构化多智能体强化学习调度框架图

合与本文的分阶段 Actor-Critic 结构结合。

与 MADDPG 等确定性策略梯度方法相比, MAPPO 在本文场景中更便于处理离散卫星选择和动作有效性约束。MADDPG 通常面向连续动作空间, 当动作中包含卫星子集选择、候选集合掩码和接入带宽单纯形约束时, 需要额外引入离散动作近似、混合动作编码或动作后处理机制。这些处理会增加动作表示和价值估计的复杂度。相比之下, MAPPO 可以在不同动作阶段分别定义策略分布, 使连续动作、离散选择和带宽比例分配在同一策略优化框架下进行训练。

MAPPO 的不足在于样本利用率相对有限。由于其策略更新主要依赖当前策略采样得到的轨迹, 每批样本通常只用于有限轮次更新; 同时, PPO 裁剪目标需要计算新旧策略在同一动作上的概率比值, 因此在混合动作和分阶段动作设置下, 需要分别维护各阶段动作的概率信息。本文在后续策略优化部分给出相应的阶段概率建模和更新方式。

MAPPO 采用 Actor-Critic 结构, 其中 Actor 用于表示无人机的调度策略, Critic 用于在训练阶段评估当前联合策略的价值。具体到本文问题, Actor 网络以无人机 u 的局部观测 $o_u(t)$ 为输入, 输出该无人机的混合动作分布:

$$\mathbf{a}_u^{\text{act}}(t) \sim \pi_{\theta}(\cdot | o_u(t)). \quad (3.1)$$

其中 θ 表示共享 Actor 网络参数。该动作进一步由运动控制、卫星回传选择和接入带宽分配三部分组成。Critic 网络则利用全局状态 $s(t)$ 或其结构化表示估计团队价值函数:

$$V_{\varphi}(s(t)), \quad (3.2)$$

其中 φ 表示 Critic 网络参数。Critic 的估计结果用于计算优势函数并指导 Actor 更新, 而在分布式执行阶段不参与动作生成。

通过上述设计, 训练阶段的 Critic 能够从全局视角评价多无人机联合动作对任务流转、队列积压和任务丢弃的长期影响; 执行阶段的 Actor 则保持分布式形式, 使每架无人机仅依赖自身观测即可生成调度动作。该框架与第二章的问题形式化相对应: 全局状态和联合动作服务于训练阶段的价值估计, 局部观测和单智能体动作服务于执行阶段的分布式决策。

3.2.2 单时隙协同调度流程

在时隙级调度过程中, 系统状态仍以单个离散时隙为单位进行更新。每个时隙内, 无人机位置、链路状态、任务到达、任务服务量和多级队列都会发生变化, 因此环境状态转移和奖励计算均按照单时隙执行。与此同时, 不同类型动作对应的调度周期并不完全相同。运动控制直接影响无人机下一时隙的位置和速度, 卫星回传选择需要适

应卫星可见关系和回传链路状态变化，二者均在每个时隙重新生成。接入关联和接入带宽分配主要决定地面用户任务进入无人机队列的过程。如果接入关联和带宽比例在相邻时隙内频繁变化，单次带宽决策对后续队列演化的影响持续时间较短，不利于策略稳定学习接入资源分配与任务流动之间的关系。因此，本文将接入关联和接入带宽分配设置为多时隙调度动作，每 K_{bw} 个时隙重新确定一次；在同一接入带宽调度周期内，周期起点处确定的接入关系和带宽比例保持不变。本文实验中取 $K_{bw} = 5$ 。

需要说明的是，上述设置并不改变环境状态更新的基本时隙粒度。调度周期内保持不变的是接入关系和带宽比例，而无人机位置、空地链路速率、任务到达、上传服务量以及各层队列状态仍按照当前时隙重新计算。这样可以在保留动态链路和队列演化过程的同时，使接入带宽动作在多个连续时隙内产生作用。

在时隙 t ，无人机 u 的策略输入为局部观测 $o_u(t)$ 。根据第二章的局部观测定义，无人机 u 的观测可表示为

$$o_u(t) = (\mathbf{x}_u^{\text{self}}(t), \mathbf{X}_u^g(t), \mathbf{m}_u^g(t), \mathbf{m}_u^{\text{bw}}(t), \mathbf{X}_u^s(t), \mathbf{m}_u^s(t), \mathbf{m}_u^{\text{sat}}(t), \mathbf{X}_u^{\text{nbr}}(t), \mathbf{m}_u^{\text{nbr}}(t)). \quad (3.3)$$

其中， $\mathbf{x}_u^{\text{self}}(t)$ 表示无人机自身状态； $\mathbf{X}_u^g(t)$ 表示候选地面用户特征， $\mathbf{m}_u^g(t)$ 表示候选用户槽位掩码， $\mathbf{m}_u^{\text{bw}}(t)$ 表示可参与接入带宽分配的用户掩码； $\mathbf{X}_u^s(t)$ 表示候选卫星特征， $\mathbf{m}_u^s(t)$ 表示候选卫星槽位掩码， $\mathbf{m}_u^{\text{sat}}(t)$ 表示满足可见性和链路可用条件的卫星选择掩码； $\mathbf{X}_u^{\text{nbr}}(t)$ 和 $\mathbf{m}_u^{\text{nbr}}(t)$ 表示邻近无人机特征及其槽位掩码。

在时隙 t ，Actor 首先根据局部观测 $o_u(t)$ 生成运动控制动作，并在更新后的运动状态基础上生成卫星回传选择动作。对于接入关联和接入带宽分配，还需要进一步判断当前时隙是否为接入带宽调度周期的起点。若 t 为周期起点，则根据当前地面用户和无人机之间的位置关系确定接入关联，并由带宽分配头生成新的带宽比例；若 t 不属于周期起点，则沿用上一周期起点处确定的接入关系和带宽比例。通过这种方式，运动控制和卫星回传选择保持逐时隙响应能力，接入带宽分配则在多个连续时隙内保持稳定作用。

上述动作组织顺序与系统状态变化的因果关系相一致：无人机运动会改变地面用户相对位置、卫星可见集合和邻机安全关系；在更新后的几何关系基础上，卫星回传选择进一步确定无人机队列向卫星侧转发任务的出口；周期起点处的接入带宽分配则结合候选用户状态和当前回传能力，决定后续若干时隙内地面用户任务向无人机队列的流入比例。通过将动作生成过程组织为上述阶段，可以使不同动作头分别面向清晰的物理决策对象，并减少动作之间的语义混淆。

具体而言，运动控制头在每个时隙输出连续加速度动作 $\mathbf{a}_u(t)$ ；卫星选择头在卫星选择掩码 $\mathbf{m}_u^{\text{sat}}(t)$ 约束下逐时隙生成卫星选择动作 $\mathbf{z}_u(t)$ 。接入带宽分配头仅在接入带宽

调度周期起点生成新的带宽比例。记当前时隙 t 对应的接入带宽调度周期起点为

$$\tau_{\text{bw}}(t) = K_{\text{bw}} \left\lfloor \frac{t}{K_{\text{bw}}} \right\rfloor. \quad (3.4)$$

当 $t = \tau_{\text{bw}}(t)$ 时，首先根据当前地面用户和无人机之间的位置关系确定接入关联，并得到接入有效性信息；随后，带宽分配头基于无人机自身表示、候选用户表示、接入有效性信息以及回传侧上下文，生成新的接入带宽比例 $\beta_u(\tau_{\text{bw}})$ 。当 $t > \tau_{\text{bw}}(t)$ 时，沿用周期起点处的接入关系和带宽比例，即

$$\beta_u(t) = \beta_u(\tau_{\text{bw}}(t)). \quad (3.5)$$

沿用第二章的动作变量记号，无人机 u 在时隙 t 的完整执行动作可表示为

$$\mathbf{a}_u^{\text{act}}(t) = (\mathbf{a}_u(t), \beta_u(t), \mathbf{z}_u(t)). \quad (3.6)$$

所有无人机完成动作生成后，环境形成联合动作

$$\mathbf{a}^{\text{act}}(t) = (\mathbf{a}_1^{\text{act}}(t), \mathbf{a}_2^{\text{act}}(t), \dots, \mathbf{a}_U^{\text{act}}(t)). \quad (3.7)$$

所有无人机形成联合执行动作后，环境首先根据运动控制动作更新无人机位置和速度，并据此重新计算当前时隙的空地链路和星机链路状态。对于接入侧，若当前时隙不属于接入带宽调度周期起点，仍沿用周期起点处的接入关系和带宽比例；但实际接入速率和上传服务量仍由当前时隙的用户位置、无人机位置、信道状态、干扰条件和用户队列共同决定。随后，环境根据逐时隙生成的卫星回传选择计算无人机到卫星的回传服务量，并结合卫星计算能力完成卫星侧任务处理。最后，按照第二章给出的队列演化公式更新三层任务队列，得到 $Q_k^g(t+1)$ 、 $Q_u^n(t+1)$ 和 $Q_\ell^s(t+1)$ ，并根据任务流动、队列变化和任务丢弃计算当前时隙奖励 $r(t)$ 。由此，单个时隙内的调度过程完成从局部观测到联合执行动作、再到系统状态转移和奖励计算的映射。

3.3 面向异构实体的结构化观测编码

第二章从系统建模角度给出了无人机局部观测包含的节点状态和链路信息。本节从策略网络输入角度进一步整理这些信息，将自身状态、候选用户、可见卫星和邻近无人机分别表示为不同类型的特征向量，并通过有效性信息刻画候选实体是否存在以及动作是否可执行。这样的结构化编码能够保留不同实体的物理含义，使策略网络在候选用户数量、卫星可见集合和邻居无人机数量随时间变化时仍保持稳定输入形式。

本文为每架无人机构造相同类型的局部观测字段，包括无人机自身状态、候选地面用户信息、可见卫星信息和邻近无人机信息等。这些观测字段在不同无人机之间采




图 3.2 单时隙协同调度流程图

用相同的组织方式，使共享 Actor 能够对不同无人机的局部观测进行统一编码。与此同时，各无人机的位置、候选用户集合、可见卫星集合和邻近无人机状态并不相同，同一类观测字段中的实体数量、有效位置和特征取值都会随无人机和时隙变化。也就是说，参数共享依赖于观测字段和编码方式的一致性，而不是要求不同无人机具有相同的观测取值。

多架无人机处于同一任务区域，共同受到任务到达、卫星相对运动和共享回传资源变化的影响，并通过用户接入、卫星回传和安全距离约束产生相互作用。这些因素使不同无人机的局部观测之间通常存在一定相关性。本文方法并不要求不同无人机观测之间保持强相关。在训练阶段，集中式 Critic 通过全局状态和团队奖励评价多无人机联合决策；在执行阶段，各无人机仍根据自身局部观测生成动作。因此，观测相关性可以在训练阶段为价值估计提供信息，但分布式执行过程不依赖其他无人机的同步观测输入。

3.3.1 局部观测信息构成

在分布式执行阶段，每架无人机只能依据自身可获得的局部信息生成动作。因此，局部观测需要覆盖影响当前决策过程的主要因素，包括无人机自身运行状态、候选地面用户状态、可见卫星状态以及邻近无人机状态。对于无人机 u ，其局部观测记为 $o_u(t)$ 。该观测既反映无人机自身的运动和队列情况，也反映接入、回传和安全约束相关的外部环境信息，是 Actor 网络进行运动控制、卫星回传选择以及接入带宽分配相关决策的输入。

自身状态用于描述无人机在当前时隙的运行条件和任务压力。对于无人机 u ，其自身状态特征记为 $\mathbf{x}_u^{\text{self}}(t)$ ，主要由位置、速度、队列状态以及服务连接统计量组成，可表示为

$$\mathbf{x}_u^{\text{self}}(t) = [\mathbf{p}_u^u(t), \mathbf{v}_u(t), Q_u^u(t), \mathbf{c}_u(t)], \quad (3.8)$$

其中， $\mathbf{c}_u(t)$ 表示与当前服务用户数量、关联分布和回传连接状态相关的统计特征。位置和速度决定无人机运动控制的可行范围，并影响接入链路和回传链路的几何关系；队列状态反映无人机侧待转发任务的积压程度；服务连接统计量则为策略判断当前无人机的负载状态和资源使用情况提供补充。

在此基础上，无人机 u 在时隙 t 的局部观测可写为

$$o_u(t) = (\mathbf{x}_u^{\text{self}}(t), \mathbf{X}_u^g(t), \mathbf{X}_u^s(t), \mathbf{X}_u^{\text{nbr}}(t)), \quad (3.9)$$

其中， $\mathbf{X}_u^g(t)$ 、 $\mathbf{X}_u^s(t)$ 和 $\mathbf{X}_u^{\text{nbr}}(t)$ 分别表示无人机 u 观测到的候选地面用户特征集合、可见卫星特征集合和邻近无人机特征集合。三类外部实体对应接入、回传和安全约束三个决策相关环节，后续结构化编码将分别对其进行处理。

候选地面用户特征集合 $\mathbf{X}_u^g(t)$ 用于描述无人机 u 在当前时隙可观测的地面用户状态。设候选用户 k 对应的状态特征向量为 $\mathbf{x}_{u,k}^g(t)$ ，则有

$$\mathbf{X}_u^g(t) = \left\{ \mathbf{x}_{u,k}^g(t) \mid k \in \widetilde{\mathcal{K}}_u(t) \right\}. \quad (3.10)$$

其中， $\widetilde{\mathcal{K}}_u(t)$ 表示第二章定义的无人机 u 在时隙 t 的候选用户集合。候选用户 k 的状态特征向量可写为

$$\mathbf{x}_{u,k}^g(t) = [\Delta \mathbf{p}_{u,k}^g(t), \mathbf{q}_k^g(t), \eta_{u,k}^{g,u}(t), l_{u,k}^{\text{prev}}(t)], \quad (3.11)$$

其中， $\Delta \mathbf{p}_{u,k}^g(t)$ 表示用户 k 相对无人机 u 的位置， $\mathbf{q}_k^g(t)$ 表示用户任务队列相关状态， $\eta_{u,k}^{g,u}(t)$ 表示接入链路质量， $l_{u,k}^{\text{prev}}(t)$ 表示历史关联状态。这些信息共同反映用户接入的空间条件、任务需求和链路传输能力，为接入带宽分配和用户服务优先级判断提供依据。

可见卫星特征集合 $\mathbf{X}_u^s(t)$ 用于描述无人机 u 在当前时隙观测到的卫星状态。设卫星 ℓ 对应的状态特征向量为 $\mathbf{x}_{u,\ell}^s(t)$ ，则有

$$\mathbf{X}_u^s(t) = \left\{ \mathbf{x}_{u,\ell}^s(t) \mid \ell \in \mathcal{L}_u^{\text{vis}}(t) \right\}. \quad (3.12)$$

其中， $\mathcal{L}_u^{\text{vis}}(t)$ 表示无人机 u 在时隙 t 的可见卫星集合。卫星 ℓ 的状态特征向量可写为

$$\mathbf{x}_{u,\ell}^s(t) = [\Delta \mathbf{p}_{u,\ell}^s(t), \Delta \mathbf{v}_{u,\ell}^s(t), v_{u,\ell}(t), \eta_{u,\ell}^{u,s}(t), \mathbf{q}_\ell^s(t), \boldsymbol{\rho}_\ell^s(t)], \quad (3.13)$$

其中， $\Delta \mathbf{p}_{u,\ell}^s(t)$ 和 $\Delta \mathbf{v}_{u,\ell}^s(t)$ 分别表示卫星 ℓ 相对无人机 u 的位置和速度， $v_{u,\ell}(t)$ 表示多普勒相关信息， $\eta_{u,\ell}^{u,s}(t)$ 表示回传链路质量， $\mathbf{q}_\ell^s(t)$ 表示卫星任务队列相关状态， $\boldsymbol{\rho}_\ell^s(t)$ 表示

卫星负载相关统计量。这些信息反映卫星回传链路的传输条件和卫星侧处理压力，为无人机选择回传卫星提供依据。

邻近无人机特征集合 $\mathbf{X}_u^{\text{nbr}}(t)$ 用于描述无人机 u 周围其他无人机的相对运动状态。设邻近无人机 u' 对应的状态特征向量为 $\mathbf{x}_{u,u'}^{\text{nbr}}(t)$ ，则有

$$\mathbf{X}_u^{\text{nbr}}(t) = \left\{ \mathbf{x}_{u,u'}^{\text{nbr}}(t) \mid u' \in \mathcal{U}_u^{\text{nbr}}(t) \right\}. \quad (3.14)$$

其中， $\mathcal{U}_u^{\text{nbr}}(t)$ 表示无人机 u 在时隙 t 的邻近无人机集合。邻近无人机 u' 的状态特征向量可写为

$$\mathbf{x}_{u,u'}^{\text{nbr}}(t) = \left[\Delta \mathbf{p}_{u,u'}^u(t), \Delta \mathbf{v}_{u,u'}(t) \right], \quad (3.15)$$

其中， $\Delta \mathbf{p}_{u,u'}^u(t)$ 和 $\Delta \mathbf{v}_{u,u'}(t)$ 表示邻近无人机 u' 相对无人机 u 的位置和速度，用于刻画多无人机之间的空间关系和潜在安全风险。该类信息虽然不直接决定任务上传或卫星回传速率，但会影响运动控制动作的可行性以及后续安全约束处理。

需要注意的是， $\mathbf{X}_u^g(t)$ 、 $\mathbf{X}_u^s(t)$ 和 $\mathbf{X}_u^{\text{nbr}}(t)$ 的元素数量会随用户分布、卫星可见窗口和无人机相对位置变化而变化。若直接将不同实体的特征简单展平输入网络，不仅会引入大量填充项，也难以保持用户、卫星和邻近无人机之间的实体语义差异。因此，本文在后续网络设计中采用结构化编码方式分别处理不同实体集合，并通过有效性信息标识候选实体是否存在以及对对应动作是否可行。

3.3.2 候选实体编码与掩码表示

由上一小节可知，无人机局部观测同时包含自身状态和多类外部实体集合。其中，自身状态维度相对固定，而候选地面用户、可见卫星和邻近无人机的数量会随系统状态变化而变化。若直接按照固定顺序拼接所有候选实体特征，策略网络容易受到实体排列顺序和填充项的影响，也难以区分不同类型实体在调度决策中的作用。为此，本文采用结构化观测编码方式，分别对自身状态、候选地面用户集合、可见卫星集合和邻近无人机集合进行编码，并在编码过程中保留不同实体类型对应的语义信息。

在上述特征定义基础上，结构化编码将不同类型输入分别映射到隐空间。自身状态特征 $\mathbf{x}_u^{\text{self}}(t)$ 通过多层感知机得到自身状态嵌入：

$$\mathbf{e}_u^{\text{self}}(t) = f_{\text{self}}(\mathbf{x}_u^{\text{self}}(t)). \quad (3.16)$$

对于候选地面用户、可见卫星和邻近无人机集合，同一类型实体共享编码器参数。以候选地面用户为例，用户 k 的实体嵌入可表示为

$$\mathbf{e}_{u,k}^g(t) = f_g(\mathbf{x}_{u,k}^g(t)), \quad k \in \widetilde{\mathcal{K}}_u(t). \quad (3.17)$$

可见卫星和邻近无人机也采用类似方式得到 $\mathbf{e}_{u,\ell}^s(t)$ 和 $\mathbf{e}_{u,u'}^{\text{nbr}}(t)$ 。这种共享编码方式能够减少网络参数规模，并使策略在候选实体数量变化时复用相同的特征提取方式。

经过实体编码后，本文同时保留候选实体的逐元素嵌入表示和集合上下文表示。对于候选地面用户集合，逐用户嵌入集合记为

$$\mathbf{E}_u^g(t) = \left\{ \mathbf{e}_{u,k}^g(t) \mid k \in \widetilde{\mathcal{K}}_u(t) \right\}. \quad (3.18)$$

类似地，可得到逐卫星嵌入集合 $\mathbf{E}_u^s(t)$ 和邻近无人机嵌入集合 $\mathbf{E}_u^{\text{nbr}}(t)$ 。逐元素嵌入保留了每个候选用户和每颗可见卫星的独立状态。在后续动作生成过程中，接入带宽分配头和卫星选择头需要分别对候选用户和可见卫星产生逐元素输出，因此逐用户嵌入和逐卫星嵌入将与自身状态嵌入、集合上下文等信息共同用于相应动作头的计算。

为了向策略提供候选集合的整体状态信息，本文对逐实体嵌入进行掩码聚合，得到固定维度的集合上下文表示^[42]。例如，候选地面用户上下文可表示为

$$\mathbf{h}_u^g(t) = \text{Agg}_g(\mathbf{E}_u^g(t), \mathbf{m}_u^g(t)). \quad (3.19)$$

卫星上下文 $\mathbf{h}_u^s(t)$ 和邻近无人机上下文 $\mathbf{h}_u^{\text{nbr}}(t)$ 可按相同方式得到。其中， $\mathbf{m}_u^g(t)$ 表示候选用户有效性信息，用于排除填充实体或当前不可用实体。集合上下文主要用于描述候选集合的整体状态，逐元素嵌入则为逐用户或逐卫星动作生成保留实体级信息。

为便于批量训练和神经网络计算，候选实体集合在实现时整理为固定最大长度的张量；其真实有效元素数量仍随无人机和时隙变化。对于不足最大长度的位置，使用填充实体补齐，并通过有效性信息将填充实体与真实候选实体区分开来。候选用户有效性信息记为 $\mathbf{m}_u^g(t)$ ，可见卫星有效性信息记为 $\mathbf{m}_u^s(t)$ ，邻近无人机有效性信息记为 $\mathbf{m}_u^{\text{nbr}}(t)$ 。本文将这类用于标识候选实体是否有效的二值向量称为实体掩码。

除实体是否存在外，部分动作还受到物理链路和调度规则约束。因此，本文进一步引入动作掩码来标识当前时隙可执行的动作元素。其中， $\mathbf{m}_u^{\text{sat}}(t)$ 表示卫星选择动作掩码，用于屏蔽不可见、链路不可用或不满足选择条件的卫星； $\mathbf{m}_u^{\text{bw}}(t)$ 表示接入带宽分配动作掩码，用于标识当前可参与带宽分配的候选用户。实体掩码主要服务于观测编码和集合聚合，动作掩码则作用于动作生成阶段，二者共同保证策略网络在变长候选集合和动态可行动作空间下保持稳定输入输出形式。

经过上述处理，无人机 u 的策略输入可由自身状态嵌入、逐实体嵌入集合、集合上下文表示以及掩码信息共同构成。其中，自身状态嵌入 $\mathbf{e}_u^{\text{self}}(t)$ 和集合上下文 $\mathbf{h}_u^g(t)$ 、 $\mathbf{h}_u^s(t)$ 、 $\mathbf{h}_u^{\text{nbr}}(t)$ 为各动作头提供整体状态条件；逐用户嵌入集合 $\mathbf{E}_u^g(t)$ 和逐卫星嵌入集合 $\mathbf{E}_u^s(t)$ 则保留逐元素决策所需的候选实体信息；实体掩码和动作掩码用于在编码、聚合和动作生成过程中屏蔽无效实体或不可执行动作。这种表示方式使策略网络既能够利用候选集合的整体状态，也能够针对具体用户和具体卫星生成细粒度调度动作。




图 3.3 结构化观测编码与掩码表示图

在上述结构化输入表示基础上，本文采用参数共享的 Actor 结构。不同无人机使用同一组 Actor 网络参数 θ ，并以各自的结构化局部观测作为输入生成动作。由于自身状态、候选用户、可见卫星和邻近无人机等信息均被整理为统一格式，共享 Actor 能够处理不同无人机在不同时隙下的局部决策问题。参数共享减少了网络参数规模，同时使不同无人机采集到的经验能够共同用于同一策略的更新。

3.3.3 Actor-Critic 网络结构

在结构化观测编码的基础上，本文构建与分阶段调度流程相匹配的 Actor-Critic 网络。Actor 网络按照运动控制、卫星回传选择和接入带宽分配的阶段顺序组织动作生成过程：运动控制头和卫星选择头在每个时隙生成对应动作，接入带宽分配头仅在接入带宽调度周期起点生成新的带宽比例，周期内后续时隙沿用周期起点处的接入关系和带宽比例。该阶段划分使运动阶段提供几何状态基础，卫星选择阶段确定回传侧条件，带宽分配阶段在周期起点结合候选用户状态、接入有效性信息和回传侧上下文确定接入资源划分。Critic 网络在集中式训练阶段采用对应的分阶段价值估计结构，对不同阶段的策略状态进行评估，为 MAPPO 的优势函数计算和策略更新提供价值基准。通过在 Actor 和 Critic 中同时保留阶段结构，网络能够匹配无人机-卫星协同调度中的连续-离散混合决策过程，以及接入带宽动作的多时隙执行特点。

Actor 网络在分布式执行阶段以无人机 u 的结构化局部表示为输入，并按阶段生成动作。运动控制阶段使用自身状态嵌入、候选用户上下文、可见卫星上下文和邻近无人机上下文构造运动阶段表示：

$$\eta_u^{\text{move}}(t) = \phi_{\text{move}}(e_u^{\text{self}}(t), h_u^g(t), h_u^s(t), h_u^{\text{nbr}}(t)). \quad (3.20)$$

在该表示基础上，运动控制头输出连续运动动作，用于确定无人机在当前时隙内的位置调整。该阶段不需要对单个用户或单颗卫星产生逐元素输出，而是通过集合上下文




图 3.4 分阶段 Actor-Critic 网络结构图

综合考虑接入需求、回传条件和邻近无人机安全关系，为后续卫星选择和带宽分配提供几何状态基础。

卫星回传选择阶段在运动控制之后执行。此时无人机与卫星之间的相对位置、可见性和链路状态已经随运动动作更新，因此卫星选择头需要基于新的阶段状态生成回传决策。记当前回传阶段的需求特征和角色特征分别为 $\mathbf{d}_u^{\text{sat}}(t)$ 和 $\mathbf{r}_u^{\text{sat}}(t)$ ，卫星选择阶段构造阶段上下文表示：

$$\eta_u^{\text{sat}}(t) = \phi_{\text{sat}}(\mathbf{e}_u^{\text{self}}(t), \mathbf{d}_u^{\text{sat}}(t), \mathbf{r}_u^{\text{sat}}(t)). \quad (3.21)$$

在此基础上，网络结合阶段上下文和逐卫星嵌入 $\mathbf{e}_{u,\ell}^s(t)$ ，对每一个可行候选卫星子集 $\mathcal{B}$ 生成选择得分：

$$R_u^{\text{sat}}(\mathcal{B}, t) = \psi_{\text{sat}}(\eta_u^{\text{sat}}(t), \{\mathbf{e}_{u,\ell}^s(t) \mid \ell \in \mathcal{B}\}). \quad (3.22)$$

该得分用于刻画当前状态下选择子集 $\mathcal{B}$ 作为回传卫星集合的策略倾向。在采样或确定性执行时，网络利用卫星可见性和有效性掩码屏蔽不可行子集，从而得到满足链路可用约束的回传卫星集合。

接入带宽分配阶段在卫星回传选择之后执行。此时无人机的回传卫星集合已经确定，已选卫星信息为带宽分配提供回传侧条件，逐用户嵌入则保留用户队列、接入链路和近期服务状态等差异化信息。设 $\mathcal{X}_u^{\text{acc}}(t)$ 表示无人机 u 在时隙 t 实际执行的有效接入用户集合。该集合由接入带宽调度周期起点处的用户-无人机位置关系确定，并在周期内保持一致。接入带宽分配头仅在周期起点生成新的带宽比例；周期内后续时隙沿

用该周期起点处的带宽比例。 $m_{u,k}^{\text{bw}}(t)$ 表示对应的带宽动作掩码。网络先由自身状态嵌入和已选卫星嵌入形成回传侧上下文：

$$\mathbf{c}_u^{\text{bw}}(t) = \phi_{\text{bw}}^{\text{ctx}} \left(\mathbf{e}_u^{\text{self}}(t), \{ \mathbf{e}_{u,\ell}^{\text{s}}(t) \mid \ell \in \mathcal{L}_u^{\text{sel}}(t) \} \right), \quad (3.23)$$

其中 $\mathcal{L}_u^{\text{sel}}(t)$ 为卫星选择阶段得到的回传卫星集合。带宽分配头将该上下文与逐用户嵌入 $\mathbf{e}_{u,k}^{\text{g}}(t)$ 融合，构造用户 k 的带宽决策表示：

$$\boldsymbol{\eta}_{u,k}^{\text{bw}}(t) = \phi_{\text{bw}}^{\text{user}} \left(\mathbf{c}_u^{\text{bw}}(t), \mathbf{e}_{u,k}^{\text{g}}(t) \right). \quad (3.24)$$

在有效用户集合内，网络进一步根据各用户的带宽决策表示生成分配得分，并经过掩码归一化得到带宽分配均值 $\bar{\beta}_u(t)$ 。训练阶段基于该均值构造带掩码的连续动作分布进行采样，执行阶段则输出满足非负性和总和约束的带宽比例。

Critic 网络只在集中式训练阶段使用。与 **Actor** 依赖单架无人机的局部观测不同，**Critic** 以全局结构化状态为输入，同时利用无人机节点、地面用户节点、卫星节点以及三类节点之间的关系信息，提取系统级上下文表示。为了刻画单时隙内不同决策阶段的信息差异，本文将 **Critic** 的输入状态写为 $s^{\text{move}}(t)$ 、 $s^{\text{sat}}(t)$ 和 $s^{\text{bw}}(t)$ ，分别对应运动控制、卫星回传选择和接入带宽分配阶段。

在运动控制阶段，当前时隙尚未产生新的前缀动作， $s^{\text{move}}(t)$ 主要包含当前队列、节点位置、链路状态以及上一时隙的服务结果。其中上一时隙的带宽分配、卫星选择、任务流入流出和丢弃等信息记为历史信息，用于反映系统最近的服务状态，但不表示当前时隙已经执行的动作。在卫星回传选择阶段，运动控制动作已经确定， $s^{\text{sat}}(t)$ 在上述历史信息基础上进一步包含运动后的几何关系、地面用户接入关系和带宽有效用户集合等当前前缀信息。在接入带宽分配阶段，卫星回传选择也已经确定， $s^{\text{bw}}(t)$ 进一步包含已选卫星集合、卫星负载、回传链路容量，以及在当前卫星选择结果下重新计算得到的用户侧、无人机侧和卫星侧工作负载信息。

因此，阶段价值函数可表示为

$$V_{\phi}^q(s^q(t)), \quad q \in \{\text{move}, \text{sat}, \text{bw}\}, \quad (3.25)$$

其中 q 表示当前决策阶段， ϕ 表示 **Critic** 网络参数。这种设计将上一时隙历史信息与当前时隙已确定的阶段信息区分开，使 **Critic** 能够依据不同阶段的可用信息评估后续团队回报，并为对应动作头的优势函数计算提供价值基准。

综上，**Actor** 和 **Critic** 均采用与单时隙调度顺序一致的阶段化结构。**Actor** 在执行阶段根据局部结构化观测生成运动控制、卫星回传选择和接入带宽分配相关动作。其中，运动控制和卫星回传选择按时隙生成，接入带宽分配仅在接入带宽调度周期起点生成新的带宽比例，并在周期内后续时隙沿用该比例；**Critic** 在训练阶段根据相应阶段的全

局结构化状态提供价值估计。这种结构把无人机运动、卫星回传选择和接入带宽分配纳入同一策略框架，同时保留各阶段不同的信息可用范围和约束条件。下一节将进一步给出混合动作空间的具体定义。

3.4 连续-离散混合动作空间设计

在完成结构化观测编码和 Actor-Critic 网络设计后，还需要进一步明确策略网络输出的动作形式。本文的执行动作由无人机运动控制、卫星回传选择和接入带宽分配三部分组成。其中，运动控制和卫星回传选择在每个时隙生成；接入带宽分配在接入带宽调度周期起点生成，并在周期内后续时隙作为当前生效的比例动作继续执行。下文从动作类型和执行约束角度分别描述三类动作。这三类动作分别对应不同的决策对象和约束条件：运动控制作用于无人机位置和速度，属于连续控制动作；卫星回传选择作用于可行卫星集合，属于带可行性约束的离散子集选择动作；接入带宽分配作用于当前可服务用户集合，属于满足非负性和总和约束的连续比例分配动作。因此，本节分别对三类动作空间进行定义，并说明其与前述阶段化策略结构之间的对应关系。

3.4.1 无人机运动控制动作

无人机运动控制动作采用二维连续加速度表示。设无人机 u 在时隙 t 的策略输出为

$$\mathbf{a}_u^{\text{move}}(t) = [a_{u,x}^{\text{move}}(t), a_{u,y}^{\text{move}}(t)]^T, \quad \mathbf{a}_u^{\text{move}}(t) \in \mathcal{A}^{\text{move}}. \quad (3.26)$$

$$\mathcal{A}^{\text{move}} = \{\mathbf{a} \in \mathbb{R}^2 \mid \|\mathbf{a}\|_2 \leq 1\}. \quad (3.27)$$

该动作经过尺度映射得到物理加速度指令

$$\tilde{\mathbf{a}}_u(t) = a_{\max} \mathbf{a}_u^{\text{move}}(t), \quad (3.28)$$

其中 $a_{\max}$ 为无人机最大加速度，因而有 $\|\tilde{\mathbf{a}}_u(t)\|_2 \leq a_{\max}$ 。考虑到服务区域边界和无人机间安全距离等硬约束，实际执行加速度记为 $\hat{\mathbf{a}}_u(t)$ 。在不触发安全修正时，有 $\hat{\mathbf{a}}_u(t) = \tilde{\mathbf{a}}_u(t)$ ；若动作可能导致越界或距离过近，则由动作处理层对其进行投影或修正。

设单个时隙长度为 τ_0 ，无人机速度约束集合为

$$\mathcal{V} = \{\mathbf{v} \in \mathbb{R}^2 \mid \|\mathbf{v}\|_2 \leq v_{\max}\}, \quad (3.29)$$

任务区域为 Ω 。在给定实际执行加速度 $\hat{\mathbf{a}}_u(t)$ 后，无人机速度和位置按下式更新：

$$\mathbf{v}_u(t+1) = \Pi_{\mathcal{V}}(\mathbf{v}_u(t) + \hat{\mathbf{a}}_u(t)\tau_0), \quad (3.30)$$

$$\mathbf{p}_u^u(t+1) = \Pi_{\Omega}(\mathbf{p}_u^u(t) + \mathbf{v}_u(t+1)\tau_0), \quad (3.31)$$

其中 $\Pi_{\mathcal{V}}(\cdot)$ 和 $\Pi_{\Omega}(\cdot)$ 分别表示速度约束和服务区域约束下的投影操作。运动动作改变无人机与地面用户、邻近无人机和可见卫星之间的相对几何关系，因此会进一步影响候选用户集合、星地链路条件以及后续接入带宽分配和卫星回传选择。

3.4.2 卫星回传选择动作

卫星回传选择动作描述无人机在当前可行卫星集合中选择回传目标的过程。根据第二章的定义， $\mathcal{L}_u^{\text{feas}}(t)$ 表示同时满足可见性、多普勒门限和链路可用条件的卫星集合。设 $m_{u,\ell}^{\text{sat}}(t) \in \{0, 1\}$ 表示卫星 ℓ 是否属于该集合：当 $\ell \in \mathcal{L}_u^{\text{feas}}(t)$ 时，有 $m_{u,\ell}^{\text{sat}}(t) = 1$ ；否则有 $m_{u,\ell}^{\text{sat}}(t) = 0$ 。无人机的卫星回传选择动作为

$$\mathcal{L}_u^{\text{sel}}(t) \subseteq \mathcal{L}_u^{\text{feas}}(t), \quad (3.32)$$

其中 $\mathcal{L}_u^{\text{sel}}(t)$ 表示无人机 u 在当前时隙选中的回传卫星集合。

为便于策略输出和环境执行，本文将卫星回传选择表示为多热向量。设 $z_{u,\ell}(t) \in \{0, 1\}$ 表示无人机 u 在时隙 t 是否选择卫星 ℓ 进行回传，则选中卫星集合可表示为

$$\mathcal{L}_u^{\text{sel}}(t) = \{\ell \in \mathcal{L} \mid z_{u,\ell}(t) = 1\}. \quad (3.33)$$

由于单架无人机在一个时隙内可同时建立的卫星回传链路数量有限，卫星选择动作需要满足

$$\sum_{\ell=1}^L z_{u,\ell}(t) \leq N_{\text{RF}}, \quad z_{u,\ell}(t) \leq m_{u,\ell}^{\text{sat}}(t), \quad \forall \ell \in \mathcal{L}, \quad (3.34)$$

其中 N_{RF} 表示第二章定义的单架无人机在一个时隙内最多可选择的回传卫星数量。第二个约束表示只有属于可行卫星集合的卫星才能被选中。当当前时隙可行卫星数量小于 N_{RF} 时，无人机只能在可行卫星集合内进行选择。

在策略生成阶段，卫星选择头根据候选卫星的结构化嵌入构造合法子集得分。设无人机 u 在时隙 t 的合法卫星子集集合为

$$\Omega_u^s(t) = \left\{ \mathcal{B} \subseteq \mathcal{L} \mid 0 \leq |\mathcal{B}| \leq N_{\text{RF}}, m_{u,\ell}^{\text{sat}}(t) = 1, \forall \ell \in \mathcal{B} \right\}. \quad (3.35)$$

对于任意合法子集 $\mathcal{B} \in \Omega_u^s(t)$ ，策略网络输出其子集得分 $R_u^{\text{sat}}(\mathcal{B}, t)$ ，并在合法子集集合上构造分类分布：

$$\pi_{\theta}^s(\mathcal{L}_u^{\text{sel}}(t) = \mathcal{B} \mid o_u(t)) = \frac{\exp(R_u^{\text{sat}}(\mathcal{B}, t))}{\sum_{\mathcal{B}' \in \Omega_u^s(t)} \exp(R_u^{\text{sat}}(\mathcal{B}', t))}. \quad (3.36)$$

采样或确定性执行得到选中子集后，再将其转换为多热向量 $\{z_{u,\ell}(t)\}_{\ell=1}^L$ 供环境执行。

3.4.3 接入带宽分配动作

接入带宽分配动作描述无人机在有效接入用户之间划分空地接入资源的过程，其结果直接影响地面用户队列的出队量和无人机队列的流入量。由于接入资源分配对队列演化的影响通常需要经过多个连续时隙才能体现，本文在带宽分配动作中引入接入带宽调度周期。设接入带宽调度周期为 K_{bw} ，当前时隙 t 对应的周期起点为 $\tau_{bw}(t)$ 。当 $t = \tau_{bw}(t)$ 时，根据用户和无人机之间的位置关系确定有效接入用户集合，并由带宽分配头生成新的比例向量；当 $t > \tau_{bw}(t)$ 时，继续使用周期起点处的有效接入用户集合和带宽比例。因此，本节中的 $\beta_u(t)$ 表示时隙 t 实际执行的带宽比例，它可能来自当前周期起点的新决策，也可能来自周期内的复用结果。

设 $m_{u,k}^{bw}(t) \in \{0, 1\}$ 表示用户 k 在时隙 t 是否属于无人机 u 的实际带宽分配对象。该掩码由接入带宽调度周期起点处的用户候选关系和接入关联结果确定，并在周期内保持一致。具体地，若用户 k 在 $\tau_{bw}(t)$ 时位于无人机 u 的候选用户集合中，且根据该时刻的用户-无人机位置关系关联到无人机 u ，则有 $m_{u,k}^{bw}(t) = 1$ ；否则有 $m_{u,k}^{bw}(t) = 0$ 。无人机 u 的接入带宽分配动作为

$$\beta_u(t) = [\beta_{1,u}(t), \beta_{2,u}(t), \dots, \beta_{K,u}(t)]^T, \quad (3.37)$$

其中 $\beta_{k,u}(t)$ 表示无人机 u 分配给用户 k 的接入带宽比例。

带宽分配动作需要满足有效用户集合上的非负性和总和约束。对于任意无人机 u ，有

$$\beta_{k,u}(t) \geq 0, \quad \forall k \in \mathcal{K}, \quad (3.38)$$

$$\beta_{k,u}(t) = 0, \quad \text{if } m_{u,k}^{bw}(t) = 0, \quad (3.39)$$

$$\sum_{k=1}^K \beta_{k,u}(t) = 1, \quad \text{if } \sum_{k=1}^K m_{u,k}^{bw}(t) > 0. \quad (3.40)$$

当无人机 u 在当前时隙不存在有效带宽分配对象时，对应的带宽分配向量置为零向量。

在策略生成阶段，带宽分配头仅在 $t = \tau_{bw}(t)$ 的时隙被调用。此时网络基于带宽阶段上下文表示与逐用户结构化嵌入，为每个实际带宽分配对象生成正的分佈参数 $\alpha_{k,u}^{bw}(t) > 0$ 。采样得到的带宽比例在当前接入带宽调度周期内执行。若 $t > \tau_{bw}(t)$ ，则不重新构造带宽动作分佈，也不产生新的带宽动作对数概率，训练时仅将周期起点样本作为带宽动作的策略更新样本。由于接入带宽动作是有效用户集合上的连续比例分配，策略输出需要同时满足非负性和总和约束。同时，在基于策略梯度的训练过程中，还需要计算所执行连续动作对应的对数概率。Dirichlet 分佈直接定义在概率单纯形上^[43]，能够描述多个有效用户之间的随机比例分配，并提供策略优化所需的概率密度。因此，本

文采用掩码化 Dirichlet 分布生成接入带宽动作。

当 $t = \tau_{\text{bw}}(t)$ 且存在至少一个实际带宽分配对象时，周期起点处的带宽动作可表示为

$$\beta_u(\tau_{\text{bw}}(t)) \sim \text{Dirichlet} \left(\{ \alpha_{k,u}^{\text{bw}}(\tau_{\text{bw}}(t)) \mid m_{u,k}^{\text{bw}}(t) = 1 \} \right). \quad (3.41)$$

采样得到的比例被填回对应用户位置，无效用户位置保持为零，并在当前接入带宽调度周期内作为 $\beta_u(t)$ 执行。当不存在有效用户时，周期内带宽分配向量按零向量执行。

接入带宽比例决定用户到无人机链路中的资源占用份额。对于周期起点时隙， $\beta_u(t)$ 由带宽分配头生成；对于周期内后续时隙， $\beta_u(t)$ 由周期起点处的带宽动作复用得到。与此同时，空地链路速率仍根据当前时隙的用户位置、无人机位置、信道状态和干扰条件重新计算。因此，用户 k 在时隙 t 通过无人机 u 实际上传的任务量可表示为

$$D_{k,u}^{\text{g},u}(t) = \min \left\{ Q_k^{\text{g}}(t) + A_k(t), R_{k,u}^{\text{g},u}(t) \tau_0 \right\}. \quad (3.42)$$

其中 $Q_k^{\text{g}}(t)$ 为用户队列长度， $A_k(t)$ 为当前时隙新增任务量， $R_{k,u}^{\text{g},u}(t)$ 为由接入带宽比例和链路条件共同决定的接入速率。因此，带宽动作直接影响地面用户队列的出队量和无人机队列的流入量。当用户队列积压较大或链路条件较好时，策略可以提高其带宽比例以增加接入吞吐；当卫星回传能力不足时，策略也需要避免过度接入导致无人机侧队列持续增长。

3.5 约束感知动作处理机制

前述三类动作虽然由策略网络统一生成，但在环境执行前仍需结合各自的可行性约束进行处理。卫星回传选择动作需要满足可见性、多普勒门限、链路有效性和选择数量约束；接入带宽分配动作需要满足有效用户掩码、非负性和总和约束；无人机运动控制动作需要满足最大加速度、最大速度、任务区域边界和无人机间安全距离等约束。若直接将未处理的策略输出交由环境执行，可能产生不可行卫星选择、无效用户带宽分配、越界运动或无人机距离过近等无效动作，从而降低采样效率并影响策略更新稳定性。因此，本文在策略输出和环境状态更新之间引入约束感知动作处理机制，通过掩码、归一化、边界投影和安全修正等操作，对不可执行动作和明显不合理动作进行过滤或修正，使最终执行动作尽可能与各项约束保持一致。

3.5.1 动作掩码机制

动作掩码用于在策略生成和环境执行阶段排除当前时隙或当前调度周期内不可用的候选对象^[44]。对于卫星回传选择，根据前述可行卫星集合生成卫星选择动作掩码 $m_{u,\ell}^{\text{sat}}(t)$ ，策略仅在由该掩码确定的合法卫星子集集合 $\Omega_u^{\text{s}}(t)$ 上构造动作分布。对于接入




图 3.5 约束感知动作处理与安全修正图

带宽分配，在接入带宽调度周期起点，根据无人机 u 的候选用户列表以及该时刻的用户-无人机接入关联结果生成带宽掩码 $m_{u,k}^{bw}(t)$ 。周期内后续时隙沿用该掩码，不重新生成带宽动作分布。只有在周期起点属于候选用户列表且关联到无人机 u 的用户，才参与该周期内的带宽分配；其余用户位置在策略输出和环境执行中均被置为无效。

训练和执行阶段均使用相同的掩码口径。在卫星选择中，不合法子集不参与分类分布的构造；在带宽分配中，无效用户不参与 Dirichlet 参数构造和比例分配。这使策略优化时计算的动作概率与实际执行动作保持相同的可行动作范围，避免训练阶段学习到执行阶段无法采用的动作。

3.5.2 连续动作边界处理

连续动作边界处理主要用于无人机运动控制动作。设策略网络为无人机 u 输出的归一化运动动作记为 $\mathbf{a}_u^{move}(t) \in \mathcal{A}^{move}$ ，其中两个维度分别对应水平平面内的两个加速度方向，且满足 $\|\mathbf{a}_u^{move}(t)\|_2 \leq 1$ 。环境将其映射为候选加速度

$$\tilde{\mathbf{a}}_u(t) = a_{max} \mathbf{a}_u^{move}(t), \quad (3.43)$$

其中 a_{max} 表示无人机最大加速度，因此候选加速度满足 $\|\tilde{\mathbf{a}}_u(t)\|_2 \leq a_{max}$ 。候选加速度用于更新无人机速度和位置，但在执行前仍需结合最大速度约束和任务区域边界约束进行处理。因此，本文区分策略输出动作 $\mathbf{a}_u^{move}(t)$ 、候选加速度 $\tilde{\mathbf{a}}_u(t)$ 和最终用于状态更新的实际加速度 $\hat{\mathbf{a}}_u(t)$ 。

在得到实际执行加速度后，根据离散运动方程计算候选速度。若候选速度的二范数不超过最大速度 v_{max} ，则直接采用该速度；若候选速度超过最大速度约束，则将其

投影到速度约束集合 $\mathcal{V}$ 内。因此，速度更新可表示为

$$\mathbf{v}_u(t+1) = \Pi_{\mathcal{V}}(\mathbf{v}_u(t) + \hat{\mathbf{a}}_u(t)\tau_0), \quad (3.44)$$

其中 $\Pi_{\mathcal{V}}(\cdot)$ 表示到速度可行集合 $\mathcal{V}$ 的投影。该处理避免单个时隙内过大的加速度指令导致无人机速度超过物理上限。

在速度约束处理之后，根据更新后的速度计算候选位置。若候选位置位于任务区域 Ω 内，则将其作为下一时隙位置；若候选位置超出任务区域边界，动作处理层按照区域边界对候选位置进行投影，使更新后位置保持在允许飞行区域内。位置更新表示为

$$\mathbf{p}_u^u(t+1) = \Pi_{\Omega}(\mathbf{p}_u^u(t) + \mathbf{v}_u(t+1)\tau_0), \quad (3.45)$$

其中 $\Pi_{\Omega}(\cdot)$ 表示任务区域约束下的位置投影。上述处理对应最大速度约束和任务区域边界约束，无人机间安全距离约束将在下一小节进一步讨论。

3.5.3 安全约束修正机制

除最大加速度、最大速度和任务区域边界外，多无人机场景还需要考虑无人机之间的安全距离约束。加速度投影、速度投影和区域边界处理主要面向单架无人机自身的运动可行性，能够限制无人机加速度、速度和位置不超出物理约束范围，但它们不能单独保证多架无人机在相对运动过程中始终保持安全间隔。例如，两架无人机即使当前满足最小安全距离要求，如果相对速度较大且运动方向相向，下一时隙仍可能出现距离过近甚至碰撞。因此，在完成单机运动约束处理后，还需要根据无人机之间的相对位置和相对速度，对候选运动动作进行安全修正。

设动作处理层在时隙 t 为无人机 u 生成的候选加速度为 $\tilde{\mathbf{a}}_u(t)$ ，安全修正层输出的最终执行加速度为 $\hat{\mathbf{a}}_u(t)$ 。其中， $\tilde{\mathbf{a}}_u(t)$ 表示由策略输出映射得到的候选加速度， $\hat{\mathbf{a}}_u(t)$ 表示进一步考虑多无人机安全距离约束后的实际执行动作。安全修正层需要在最大加速度和最大速度等单机运动约束下，根据无人机之间的相对位置和相对速度调整 $\tilde{\mathbf{a}}_u(t)$ ，使修正后的联合运动结果尽可能满足安全距离要求，同时减小 $\hat{\mathbf{a}}_u(t)$ 与 $\tilde{\mathbf{a}}_u(t)$ 之间的偏差。

直接约束下一时隙无人机间距离可以避免一步预测内的距离违反，但该约束没有显式考虑两架无人机在下一时隙之后是否仍具备足够的制动空间。因此，本文从无人机对的相对运动出发描述安全约束。对于任意无人机对 (u, v) ，定义其相对位置和相对速度分别为

$$\mathbf{r}_{u,v}(t) = \mathbf{p}_u^u(t) - \mathbf{p}_v^v(t), \quad \mathbf{w}_{u,v}(t) = \mathbf{v}_u(t) - \mathbf{v}_v(t). \quad (3.46)$$

若 $\mathbf{r}_{u,v}(t)$ 非零，则相对位置方向可表示为

$$\mathbf{n}_{u,v}(t) = \frac{\mathbf{r}_{u,v}(t)}{\|\mathbf{r}_{u,v}(t)\|_2}. \quad (3.47)$$

设无人机对 (u, v) 在相对位置方向上的接近速度为

$$v_{u,v}(t) = [-\mathbf{n}_{u,v}^T(t)\mathbf{w}_{u,v}(t)]^+, \quad (3.48)$$

其中 $[x]^+ = \max\{x, 0\}$ 。当 $v_{u,v}(t) > 0$ 时，两架无人机沿相对位置方向相互接近；当 $v_{u,v}(t) = 0$ 时，两架无人机在该方向上不存在接近趋势。为了避免仅满足当前安全距离但缺少后续制动空间，本文将相对接近速度对应的制动距离纳入安全裕度。设 A_{safe} 表示无人机对沿相对位置方向的保守相对制动能力。本文根据最大加速度定义

$$A_{\text{safe}} = \rho_{\text{safe}} \cdot 2a_{\text{max}}, \quad 0 < \rho_{\text{safe}} \leq 1, \quad (3.49)$$

其中 ρ_{safe} 为安全保守系数。由此，无人机对 (u, v) 的制动安全裕度可表示为

$$m_{u,v}(t) = \|\mathbf{r}_{u,v}(t)\|_2 - d_{\text{safe}} - \frac{v_{u,v}^2(t)}{2A_{\text{safe}}}. \quad (3.50)$$

当 $m_{u,v}(t) \geq 0$ 时，表示当前相对距离在考虑制动需求后仍具有安全裕度；当 $m_{u,v}(t) < 0$ 时，表示仅依靠当前相对运动状态可能无法保持安全距离，需要对候选加速度进行修正。

在安全修正时，需要评估修正加速度作用后的相对运动状态。给定最终执行加速度 $\hat{\mathbf{a}}_u(t)$ 和 $\hat{\mathbf{a}}_v(t)$ ，无人机对 (u, v) 的相对加速度为

$$\hat{\mathbf{a}}_{u,v}(t) = \hat{\mathbf{a}}_u(t) - \hat{\mathbf{a}}_v(t). \quad (3.51)$$

根据离散时间运动模型，下一时隙的相对速度可表示为

$$\mathbf{w}_{u,v}^+(t) = \mathbf{w}_{u,v}(t) + \tau_0 \hat{\mathbf{a}}_{u,v}(t). \quad (3.52)$$

相应地，沿当前相对位置方向的下一步接近速度为

$$v_{u,v}^+(t) = [-\mathbf{n}_{u,v}^T(t)\mathbf{w}_{u,v}^+(t)]^+. \quad (3.53)$$

同时，修正加速度会影响下一时隙的相对位置。本文沿当前相对位置方向描述下一步相对距离变化，定义

$$\ell_{u,v}^+(t) = \mathbf{n}_{u,v}^T(t) (\mathbf{r}_{u,v}(t) + \tau_0 \mathbf{w}_{u,v}(t) + \tau_0^2 \hat{\mathbf{a}}_{u,v}(t)). \quad (3.54)$$

其中， $\ell_{u,v}^+(t)$ 表示无人机对在当前相对位置方向上的下一步径向间隔。由此，修正后的

制动安全约束可写为

$$\ell_{u,v}^+(t) - d_{\text{safe}} - \frac{(v_{u,v}^+(t))^2}{2A_{\text{safe}}} \geq 0, \quad \forall u, v \in \mathcal{U}, u < v. \quad (3.55)$$

该约束要求无人机对在执行修正动作后不仅下一步保持安全间隔，还需要保留与相对接近速度相匹配的制动空间。

基于上述制动安全约束，可以将安全修正写成一个二次规划安全修正问题（QP shield）^[45,46]。其目标是在满足运动约束和安全约束的条件下，尽量减小最终执行加速度与候选加速度之间的偏差：

$$\begin{aligned} \min_{\{\hat{\mathbf{a}}_u(t)\}_{u \in \mathcal{U}}} \quad & \sum_{u \in \mathcal{U}} \|\hat{\mathbf{a}}_u(t) - \tilde{\mathbf{a}}_u(t)\|_2^2 \\ \text{s.t.} \quad & \|\hat{\mathbf{a}}_u(t)\|_2 \leq a_{\text{max}}, \quad \forall u \in \mathcal{U}, \\ & \|\mathbf{v}_u(t) + \tau_0 \hat{\mathbf{a}}_u(t)\|_2 \leq v_{\text{max}}, \quad \forall u \in \mathcal{U}, \\ & \ell_{u,v}^+(t) - d_{\text{safe}} - \frac{(v_{u,v}^+(t))^2}{2A_{\text{safe}}} \geq 0, \quad \forall u, v \in \mathcal{U}, u < v. \end{aligned} \quad (3.56)$$

需要指出的是，安全修正机制的安全保证依赖于当前状态是否仍具有可控安全裕度。当无人机对相对接近速度过大、剩余间隔不足，或多组无人机安全约束之间发生冲突时，即使系统尚未发生碰撞，也可能已经不存在同时满足运动约束和制动安全约束的修正动作。在这种情况下，二次规划安全修正问题可能不可行，安全修正层只能在运动约束范围内给出尽可能接近安全要求的动作，而不能保证完全避免安全距离违反。

若初始状态属于由系统动力学、运动约束和制动安全约束共同决定的递推可行安全集，且动力学模型准确、约束求解无数值失效、执行动作与求解结果一致，则二次规划安全修正层可以在离散时间模型下逐时隙保持可行性，并递推保持无人机间安全距离约束。

为降低直接求解 QP shield 的计算开销，本文采用对制动安全约束逐对投影的近似修正方式。该方法沿用 QP shield 中减小动作修正幅度和满足安全约束的设计目标，但不在每个时隙同时求解全部无人机对约束，而是对违反制动安全约束的无人机对依次进行局部修正。

定义修正后无人机对 (u, v) 的下一步制动安全裕度为

$$M_{u,v}^+(t) = \ell_{u,v}^+(t) - d_{\text{safe}} - \frac{(v_{u,v}^+(t))^2}{2A_{\text{safe}}}. \quad (3.57)$$

若 $M_{u,v}^+(t) < 0$ ，则说明该无人机对违反制动安全约束。设第 q 次修正迭代中的执行加

速度为 $\hat{\mathbf{a}}_u^{(q)}(t)$ ，初始值为

$$\hat{\mathbf{a}}_u^{(0)}(t) = \tilde{\mathbf{a}}_u(t). \quad (3.58)$$

对于违反约束的无人机对 (u, v) ，沿当前相对位置方向施加方向相反的修正：

$$\hat{\mathbf{a}}_u^{(q+1)}(t) = \hat{\mathbf{a}}_u^{(q)}(t) + \delta_{u,v}^{(q)}(t) \mathbf{n}_{u,v}(t), \quad (3.59)$$

$$\hat{\mathbf{a}}_v^{(q+1)}(t) = \hat{\mathbf{a}}_v^{(q)}(t) - \delta_{u,v}^{(q)}(t) \mathbf{n}_{u,v}(t). \quad (3.60)$$

该修正方向能够增大两架无人机在当前相对位置方向上的径向间隔，并降低相对接近速度，对应于单个制动安全约束的局部投影方向。

修正幅度由当前制动安全裕度到可行边界之间的差值确定。根据 $\ell_{u,v}^+(t)$ 和 $v_{u,v}^+(t)$ 关于修正幅度的局部线性化关系，本文将修正幅度设为

$$\delta_{u,v}^{(q)}(t) = \frac{[-M_{u,v}^+(t)]^+}{2\tau_0^2 + \frac{2\tau_0 v_{u,v}^+(t)}{A_{\text{safe}}}}. \quad (3.61)$$

其中，分子 $[-M_{u,v}^+(t)]^+$ 表示当 $M_{u,v}^+(t) < 0$ 时，当前制动安全裕度恢复到可行边界 $M_{u,v}^+(t) = 0$ 所需弥补的差值；分母表示沿 $\mathbf{n}_{u,v}(t)$ 方向进行相反修正时，单位修正幅度带来的安全裕度变化。

每次局部修正后，将无人机加速度重新投影到最大加速度和最大速度约束对应的可行范围内。经过有限次逐对修正后，得到最终执行加速度 $\hat{\mathbf{a}}_u(t)$ 。与 QP shield 相比，该近似方法避免了每个时隙调用通用优化求解器，但由于其采用逐对局部修正和有限次迭代，不能保证得到全局最小偏差解，也不能在所有多无人机相互影响场景下给出相同的形式化安全保证。

安全修正层不仅用于生成满足约束的执行动作，还刻画了策略输出动作与安全动作之间的偏差。定义无人机 u 在时隙 t 的安全修正量为

$$\Delta \mathbf{a}_u(t) = \hat{\mathbf{a}}_u(t) - \tilde{\mathbf{a}}_u(t). \quad (3.62)$$

当 $\|\Delta \mathbf{a}_u(t)\|_2$ 较大时，说明策略输出对应的候选加速度与安全约束要求存在明显偏离。该修正量反映了候选加速度与安全执行加速度之间的差异，也为后续构造运动控制辅助监督信号提供依据。

3.6 队列感知策略优化方法

前述结构化 Actor-Critic 网络和约束感知动作处理机制给出了策略动作的生成与修正方式，但策略能否学习到有效调度行为还取决于优化目标的设计。在无人机-卫星协

同任务调度场景中,系统目标不仅包括提高任务接入和回传吞吐,还需要抑制多级队列积压并减少任务丢弃。本节围绕任务流动效率和队列稳定性构造队列感知奖励,利用安全修正量构造运动控制辅助监督信号,并结合 MAPPO 策略优化目标对 Actor-Critic 网络进行更新。

3.6.1 队列感知奖励构造

队列感知奖励用于引导策略降低任务在系统中的持续等待时间代价^[6]。在时隙 t , 当前动作会影响用户接入量、无人机回传量、卫星处理量、各层队列状态以及任务丢弃量。为了使奖励不仅关注瞬时吞吐,还能反映任务积压位置的差异,本文为不同节点上的队列任务估计单位 bit 的后续服务时间代价。设 $\mu_k^g(t)$ 、 $\mu_u^u(t)$ 和 $\mu_\ell^s(t)$ 分别表示地面用户 k 、无人机 u 和卫星 ℓ 的单时隙可服务任务量估计,其量纲为 bit/slot。该估计用于刻画任务通过对应节点继续传输或处理的能力。当节点可服务任务量较低时,单位 bit 任务对应的预计服务时间较长;当节点可服务任务量较高时,单位 bit 任务对应的预计服务时间较短。在实现中,可对服务量估计进行平滑处理,以降低瞬时链路波动对奖励尺度的影响。同时,为避免服务量接近零时倒数项过大,本文引入数值截断常数 $\epsilon_\mu > 0$,该常数仅用于限制奖励尺度,并不表示节点具有额外的物理服务能力。

卫星侧任务只需继续完成卫星计算处理,因此卫星 ℓ 的单位 bit 后续服务时间代价定义为

$$c_\ell^s(t) = \frac{1}{\max\{\mu_\ell^s(t), \epsilon_\mu\}}. \quad (3.63)$$

无人机队列中的任务需要继续经过无人机到卫星回传以及卫星侧处理。设 $\mathcal{L}_u^{\text{sel}}(t)$ 表示无人机 u 当前时隙选中的回传卫星集合。回传后的卫星侧平均后续代价定义为

$$\bar{c}_u^s(t) = \begin{cases} \frac{1}{|\mathcal{L}_u^{\text{sel}}(t)|} \sum_{\ell \in \mathcal{L}_u^{\text{sel}}(t)} c_\ell^s(t), & |\mathcal{L}_u^{\text{sel}}(t)| > 0, \\ \frac{1}{L} \sum_{\ell \in \mathcal{L}} c_\ell^s(t), & |\mathcal{L}_u^{\text{sel}}(t)| = 0. \end{cases} \quad (3.64)$$

则无人机 u 的单位 bit 后续服务时间代价可写为

$$c_u^u(t) = \frac{1}{\max\{\mu_u^u(t), \epsilon_\mu\}} + \bar{c}_u^s(t). \quad (3.65)$$

地面用户队列中的任务需要先上传至关联无人机,并继续经过无人机回传和卫星处理。设 $\alpha_k(t)$ 表示地面用户 k 在时隙 t 关联的无人机编号,则地面用户 k 的单位 bit 后续服务时间代价定义为

$$c_k^g(t) = \frac{1}{\max\{\mu_k^g(t), \epsilon_\mu\}} + c_{\alpha_k(t)}^u(t). \quad (3.66)$$

由上述定义可知, $c_k^g(t)$ 、 $c_u^u(t)$ 和 $c_\ell^s(t)$ 均具有 slot/bit 的量纲, 表示单位 bit 任务从对应节点继续完成后续传输和处理所需的预计时隙数。

基于单位 bit 后续服务时间代价, 可以将各层队列长度折算为队列时间负载。记地面用户、无人机和卫星队列在更新后分别为 $Q_k^g(t+1)$ 、 $Q_u^u(t+1)$ 和 $Q_\ell^s(t+1)$, 则时隙 t 执行动作并完成队列更新后的系统队列时间负载定义为

$$W(t+1) = \sum_{k \in \mathcal{K}} c_k^g(t) Q_k^g(t+1) + \sum_{u \in \mathcal{U}} c_u^u(t) Q_u^u(t+1) + \sum_{\ell \in \mathcal{L}} c_\ell^s(t) Q_\ell^s(t+1). \quad (3.67)$$

当队列溢出导致任务丢弃时, 丢弃任务同样按照其所在节点的单位 bit 后续服务时间代价折算为时间负载损失, 记为 $W^{\text{drop}}(t)$ 。

在多无人机场景中, 安全约束违反可能导致回合提前结束。若直接采用负的队列时间负载作为奖励, 回合持续时间越长, 累计回报中累积的负项也越多, 容易使较早结束的轨迹在数值上占优。为缓解这一问题, 本文将队列时间负载转换为正值奖励:

$$r_q(t) = \frac{1}{1 + \log(1 + W(t+1) + W^{\text{drop}}(t))}. \quad (3.68)$$

当队列时间负载和丢弃造成的时间负载损失较小时, $r_q(t)$ 取值较大; 当任务积压或丢弃增加时, $r_q(t)$ 取值降低。因此, 策略需要在保持回合持续运行的同时降低队列时间负载, 才能获得较高累计回报。

上述 $r_q(t)$ 作为环境返回的团队奖励, 用于评价当前联合动作对任务积压和任务丢弃的影响。由于 $W(t+1)$ 同时包含地面用户、无人机和卫星队列, $W^{\text{drop}}(t)$ 则刻画溢出任务造成的时间负载损失, 因此该奖励能够将多级队列状态和任务丢弃情况统一到同一训练目标中。

3.6.2 安全修正辅助监督

在 3.5 节中, 约束感知动作处理机制将 Actor 输出的候选加速度 $\tilde{\mathbf{a}}_u(t)$ 修正为最终执行加速度 $\hat{\mathbf{a}}_u(t)$ 。当两者差异较小时, 说明策略输出的运动动作已经基本满足运动约束和安全约束; 当两者差异较大时, 说明当前候选动作需要依赖安全修正层进行明显调整。如果 Actor 长期输出需要大幅修正的加速度, 环境中的实际运动将主要由安全修正层决定, 策略网络难以准确学习自身运动动作对后续状态和奖励的影响。因此, 本文将安全修正量作为辅助监督信号, 用于刻画发生安全修正时策略运动动作与安全可执行动作之间的偏差, 并引导 Actor 在相似状态下输出更接近安全可执行动作的候选加速度。

记无人机 u 在时隙 t 的安全修正量为

$$\Delta \mathbf{a}_u(t) = \hat{\mathbf{a}}_u(t) - \tilde{\mathbf{a}}_u(t). \quad (3.69)$$

其中, $\tilde{\mathbf{a}}_u(t)$ 为 Actor 输出的候选加速度, $\hat{\mathbf{a}}_u(t)$ 为经过安全修正后的执行加速度。当 $\Delta \mathbf{a}_u(t) = \mathbf{0}$ 时, 说明候选加速度在当前状态下未触发有效安全修正; 当 $\Delta \mathbf{a}_u(t) \neq \mathbf{0}$ 时, 说明安全修正层对该无人机的运动动作进行了调整。因此, 本文仅对发生有效安全修正的样本启用辅助监督。考虑数值计算误差, 设 $\varepsilon_a > 0$ 为判定容差, 定义安全辅助监督标记为

$$m_u^{\text{safe}}(t) = \mathbb{I}(\|\Delta \mathbf{a}_u(t)\|_2 > \varepsilon_a). \quad (3.70)$$

在实际训练中, 为了与 Actor 输出动作的取值范围保持一致, 加速度监督目标采用归一化形式。设 $a_{\max}$ 为最大加速度, Actor 在观测 $o_u(t)$ 下输出的归一化加速度分布均值为 $\mu_u^a(o_u(t)) \in [-1, 1]^2$ 。安全修正后的执行加速度对应的归一化目标为

$$\mathbf{y}_u^{\text{safe}}(t) = \frac{\hat{\mathbf{a}}_u(t)}{a_{\max}}. \quad (3.71)$$

对于发生有效安全修正的样本, 安全辅助监督使 Actor 输出的加速度分布均值接近上述归一化目标。若当前训练批次中存在满足 $m_u^{\text{safe}}(t) = 1$ 的样本, 则安全辅助监督损失定义为

$$\mathcal{L}_{\text{safe}} = \frac{\sum_t \sum_{u \in \mathcal{U}} m_u^{\text{safe}}(t) \|\mu_u^a(o_u(t)) - \mathbf{y}_u^{\text{safe}}(t)\|_2^2}{\sum_t \sum_{u \in \mathcal{U}} m_u^{\text{safe}}(t)}. \quad (3.72)$$

若当前批次中不存在发生有效安全修正的样本, 则令 $\mathcal{L}_{\text{safe}} = 0$ 。

安全辅助监督只作用于运动控制阶段的 Actor 更新。设 $\lambda_{\text{safe}} \geq 0$ 为辅助监督权重。在后续 MAPPO 更新中, 该项作为运动控制阶段 Actor 损失的附加项使用; 完整的策略损失、熵正则项和安全辅助监督项将在下一小节统一给出。通过引入 $\mathcal{L}_{\text{safe}}$, 运动阶段的策略更新能够利用安全修正层给出的动作修正结果, 从而提高发生安全修正样本上的运动动作学习针对性。

3.6.3 MAPPO 策略优化目标

基于前文构建的结构化策略网络和队列感知奖励, 本文采用 MAPPO 对 Actor-Critic 网络进行训练^[9]。在训练阶段, 分阶段 Critic 利用全局状态估计对应阶段的价值; 在执行阶段, 各无人机仅依据自身局部观测和当前调度周期状态生成动作。其中, 运动控制动作和卫星回传选择动作按时隙产生, 接入带宽分配动作只在接入带宽调度周期起点产生新的策略样本。由于本文的联合动作由多个无人机和多个动作阶段共同组成, 策略更新时需要分别记录运动动作、卫星选择动作和带宽分配动作对应的对数概率, 并

基于同一批采样轨迹计算优势函数和策略目标。

记动作阶段集合为 $\mathcal{P} = \{\text{move}, \text{sat}, \text{bw}\}$ ，分别对应运动控制、卫星回传选择和接入带宽分配。

设环境在时隙 t 返回的团队奖励为 r_t ，本文取 $r_t = r_q(t)$ ，其中 $r_q(t)$ 为 3.6.1 节定义的队列感知奖励。记阶段 m 的集中式 Critic 对全局状态 s_t 的价值估计为 $V_\varphi^m(s_t)$ ，其中 $m \in \mathcal{P}$ ， φ 表示 Critic 网络参数。阶段 Critic 拟合的对象为当前策略 π 下从状态 s_t 出发的折扣累计奖励期望：

$$V_\pi^m(s_t) = \mathbb{E}_\pi \left[\sum_{i=t}^{T-1} \gamma^{i-t} r_i \mid s_t \right]. \quad (3.73)$$

在普通基于广义优势估计（Generalized Advantage Estimation, GAE）的 Critic 训练中，价值函数目标通常写为

$$\hat{R}_t^{m,\text{GAE}} = V_{\bar{\varphi}}^m(s_t) + \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}^m, \quad (3.74)$$

其中

$$\delta_i^m = r_i + \gamma V_{\bar{\varphi}}^m(s_{i+1}) - V_{\bar{\varphi}}^m(s_i). \quad (3.75)$$

这里 $\bar{\varphi}$ 表示构造训练目标时使用的 Critic 参数。由上式可见， $\hat{R}_t^{m,\text{GAE}}$ 不只由采样奖励决定，还显式依赖 Critic 对当前状态和后继状态的估计。在训练初期，若 $V_{\bar{\varphi}}^m$ 尚未形成稳定价值尺度，则 δ_i^m 和 $\hat{R}_t^{m,\text{GAE}}$ 都会受到价值估计误差影响，使 Critic 的监督目标不够稳定。

为减少早期价值目标对 Critic 自身估计的依赖，本文在 Critic 训练阶段采用有限时域蒙特卡洛回报作为监督目标：

$$\hat{R}_t^{m,\text{MC}} = \sum_{i=t}^{T-1} \gamma^{i-t} r_i. \quad (3.76)$$

由阶段价值函数定义可得

$$\mathbb{E}_\pi \left[\hat{R}_t^{m,\text{MC}} \mid s_t \right] = V_\pi^m(s_t). \quad (3.77)$$

这说明在固定当前策略 π 的条件下， $\hat{R}_t^{m,\text{MC}}$ 的条件期望与阶段价值函数 $V_\pi^m(s_t)$ 一致。虽然单条蒙特卡洛回报会受到后续随机任务到达、链路变化和其他智能体动作的影响，但它不依赖 Critic 自身的自举估计，因此能够作为 Critic 训练阶段的累计回报监督目标。

在每轮采样后，本文先使用 $\hat{R}_t^{m,\text{MC}}$ 训练阶段 Critic。第一轮训练时，Critic 尚未形成稳定价值估计，因此采用更多训练轮次进行初始拟合；后续训练中，Critic 使用较少

轮次跟踪策略变化。阶段 m 的价值函数损失为

$$\mathcal{L}_V^m = \mathbb{E}_t \left[\left(V_\varphi^m(s_t) - \hat{R}_t^{m,MC} \right)^2 \right], \quad m \in \mathcal{P}. \quad (3.78)$$

Critic 更新完成后，如果直接采用蒙特卡洛优势

$$\hat{A}_t^{m,MC} = \hat{R}_t^{m,MC} - V_\varphi^m(s_t) \quad (3.79)$$

进行 Actor 更新，则后续多个时隙中的随机任务到达、链路变化和其他智能体动作都会直接进入策略梯度，导致优势估计方差较大。相反，如果只采用一步时序差分残差

$$\delta_t^m = r_t + \gamma V_\varphi^m(s_{t+1}) - V_\varphi^m(s_t), \quad (3.80)$$

则优势估计更依赖短期奖励和价值函数自举，难以充分反映动作对后续队列演化的影响。为此，本文采用 GAE 对多步时序差分残差进行加权累积^[47]：

$$\hat{A}_t^m = \sum_{l=0}^{T-t-1} (\gamma \lambda)^l \delta_{t+l}^m. \quad (3.81)$$

其中， γ 为折扣因子， λ 为 GAE 参数。当 λ 接近 1 时，优势估计更接近多步回报减去价值基准；当 λ 较小时，优势估计更偏向短步长时序差分形式。由此，本文使用蒙特卡洛回报训练 Critic，以建立较稳定的累计回报尺度；再使用训练后的 Critic 计算 GAE 优势，用于 Actor 的 PPO 裁剪目标。

对于阶段 $m \in \mathcal{P}$ ，记该阶段联合动作为 $\mathbf{a}_t^m$ ，对应策略为 π_θ^m 。其中， $\mathbf{o}_t^m$ 表示阶段 m 的局部观测集合。采样轨迹时的旧策略参数记为 θ_{old} 。策略梯度可由似然比恒等式 $\nabla_\theta p_\theta(\tau) = p_\theta(\tau) \nabla_\theta \log p_\theta(\tau)$ 得到。在基于旧策略采样得到的轨迹上更新当前策略时，需要比较当前策略与旧策略对同一已采样动作的概率。PPO 通过新旧策略概率比值限制单次更新幅度^[48]。本文以阶段动作的对数概率之差计算该比值：

$$\rho_t^m(\theta) = \exp \left(\log \pi_\theta^m(\mathbf{a}_t^m | \mathbf{o}_t^m) - \log \pi_{\theta_{\text{old}}}^m(\mathbf{a}_t^m | \mathbf{o}_t^m) \right). \quad (3.82)$$

基于阶段策略概率比值，阶段 m 的裁剪策略损失定义为

$$\mathcal{L}_{\text{PPO}}^m = -\mathbb{E}_t \left[\min \left(\rho_t^m(\theta) \hat{A}_t^m, \text{clip} \left(\rho_t^m(\theta), 1 - \epsilon_{\text{clip}}, 1 + \epsilon_{\text{clip}} \right) \hat{A}_t^m \right) \right], \quad m \in \mathcal{P}. \quad (3.83)$$

其中， ϵ_{clip} 为 PPO 裁剪系数。该目标在优势函数为正时限制策略概率过快增大，在优势函数为负时限制策略概率过快减小，从而提高策略更新的稳定性。

为保持策略探索能力，Actor 更新中引入熵正则项。记阶段 m 的策略熵为 $\mathcal{H}^m(\pi_\theta)$ ，则卫星选择和带宽分配阶段的 Actor 损失为

$$\mathcal{L}_{\text{actor}}^m = \mathcal{L}_{\text{PPO}}^m - \beta_m \mathcal{H}^m(\pi_\theta), \quad m \in \{\text{sat}, \text{bw}\}. \quad (3.84)$$

运动控制阶段在 PPO 策略损失和熵正则项之外，进一步加入 3.6.2 节定义的安全辅助监督损失：

$$\mathcal{L}_{\text{actor}}^{\text{move}} = \mathcal{L}_{\text{PPO}}^{\text{move}} - \beta_{\text{move}} \mathcal{H}^{\text{move}}(\pi_{\theta}) + \lambda_{\text{safe}} \mathcal{L}_{\text{safe}}. \quad (3.85)$$

其中， β_m 为阶段 m 的熵权重， λ_{safe} 为安全辅助监督权重。

训练过程中，运动控制阶段和卫星选择阶段在每个时隙均产生动作样本；接入带宽分配阶段只在接入带宽调度周期起点产生新的动作样本。对于周期内后续时隙，环境仍然记录奖励、服务量和队列变化，但这些时隙不产生新的带宽动作对数概率，也不作为带宽 Actor 的独立策略更新样本。带宽阶段的价值目标和优势估计从完整逐时隙回报链中，在周期起点位置取出对应项。这样既保留周期内奖励对带宽动作的反馈作用，也使带宽阶段的策略更新与实际动作生成时刻保持一致。这种阶段化更新方式与 3.3 节中的分阶段 Actor-Critic 结构保持一致，能够分别处理连续运动动作、离散卫星选择动作和连续带宽分配动作的概率建模差异。各阶段优势估计均基于队列感知奖励计算，但策略比值、熵项、价值函数损失以及辅助监督项按照对应动作阶段分别构造。

3.6.4 集中式训练与分布式执行机制

本文训练与执行过程遵循 CTDE 框架。集中式训练阶段保存全局状态、局部观测、阶段动作、团队奖励和旧策略对数概率等信息，用于更新集中式 Critic 和共享 Actor；分布式执行阶段，各无人机通过共享 Actor，根据自身局部观测生成可执行动作。

训练阶段采样得到的轨迹被整理为按动作阶段划分的训练样本。运动控制和卫星选择阶段按时隙保存动作样本；接入带宽分配阶段按接入带宽调度周期保存周期起点样本。对于每个阶段，样本中保存局部观测、执行动作、团队奖励、旧策略对数概率以及对应的全局状态。Actor 更新使用对应阶段的局部观测和动作计算新旧策略概率比值；Critic 更新则使用全局状态拟合阶段价值函数目标。对于接入带宽分配阶段，周期内后续时隙的奖励和队列变化仍进入逐时隙回报链，但策略概率比值只在周期起点样本上计算，从而使带宽阶段训练样本与实际带宽动作生成时刻保持一致，并保留周期内任务流动结果对该动作的反馈。

执行阶段不再更新网络参数，也不使用 Critic 参与决策。在执行阶段的每个时隙，各无人机通过共享 Actor，根据自身局部观测生成运动控制动作和卫星回传选择动作；若该时隙位于接入带宽调度周期起点，根据用户-无人机位置关系确定接入关联，并通过共享 Actor 根据局部观测生成接入带宽分配动作；若该时隙位于周期内后续位置，则沿用该周期起点处的接入关系和带宽比例。随后，各类动作按照 3.5 节中的约束感知动作处理方式转换为可执行动作。其中，卫星回传选择需经过可行卫星集合和选择数量

约束处理；接入带宽分配需经过有效用户集合、非负性和总带宽约束处理；运动控制动作需经过最大加速度、最大速度、任务区域边界和安全距离约束处理。由于 Actor 的输入仅为局部观测，执行阶段不需要获取完整全局状态或计算集中式价值函数。

该机制兼顾了训练阶段的协同学习和执行阶段的分布式部署需求。在多智能体训练过程中，单个无人机的观测和奖励会受到其他无人机动作的影响；同时，其他无人机的策略也会随训练更新而变化，使单个智能体面对的状态转移和奖励关系呈现非平稳性。集中式 Critic 在训练时利用全局状态评价团队状态，可以为 Actor 更新提供更稳定的价值估计。执行时，各无人机不需要共享完整状态或等待集中式价值评估结果，只需利用共享 Actor 网络和自身局部观测完成动作生成，从而降低在线决策过程中的通信和计算开销。

3.7 本章小结

本章面向第二章建立的无人机-卫星协同任务调度模型，设计基于结构化多智能体强化学习的调度算法。该算法把无人机局部观测划分为自身状态、候选用户、可见卫星和邻近无人机四类输入，并在训练阶段构造用于集中式价值估计的全局状态表示。在此基础上，本文构建参数共享的分阶段 Actor-Critic 网络：Actor 按照运动控制、卫星回传选择和接入带宽分配的阶段顺序组织动作生成过程，其中运动控制和卫星回传选择按时隙生成，接入带宽分配按调度周期生成并在周期内执行；Critic 则在集中式训练阶段对不同动作阶段进行价值估计。

围绕上述分阶段决策过程，本章进一步定义连续-离散混合动作空间，并设计约束感知动作处理机制，使卫星选择、带宽分配和运动控制动作满足对应可行性约束。针对多无人机安全距离约束，本文给出基于安全修正的运动动作处理方式，并利用修正前后的加速度差构造运动控制辅助监督信号。在策略优化方面，本章构造队列感知奖励，并采用分阶段 MAPPO 目标对 Actor-Critic 网络进行训练。训练过程采用集中式训练、分布式执行机制，在集中式训练阶段利用全局状态进行价值估计，在执行阶段则仅依赖各无人机局部观测生成动作。

第四章 无人机-卫星协同任务调度算法仿真实验与性能分析

4.1 引言

前文围绕无人机-卫星协同任务调度问题建立了系统模型，并设计了基于结构化多智能体强化学习的协同调度算法。系统模型围绕网络组成、通信回传、任务处理和多级队列演化对运行过程进行刻画；算法部分则把无人机运动控制、卫星回传选择和接入带宽分配作为连续-离散混合动作来描述，并从结构化观测编码、分阶段 Actor-Critic 网络、约束感知动作处理机制以及队列感知奖励构造等方面，给出面向该调度问题的多智能体强化学习方法。本章在上述模型与算法基础上搭建仿真实验环境，并观察所提方法在动态任务到达、卫星可见性变化和多无人机协同决策条件下的调度效果。

对无人机-卫星协同任务调度进行实验评估时，不能只看单一吞吐指标。在该系统中，地面用户产生的任务需要依次经过用户接入、无人机缓存与回传、卫星侧处理等环节，其中任一环节服务能力不足，都会引起队列积压或任务丢弃。同时，无人机运动动作会改变用户接入条件、卫星回传条件和无人机间安全关系，调度效果还需要结合运动安全与约束处理情况进行分析。据此，本章从任务处理能力、队列稳定性、任务丢弃情况、链路吞吐和安全约束处理等方面综合评价算法性能。

本章实验分析按照基础设置、评价口径和结果讨论的顺序展开。仿真实验设置部分列出场景、任务到达、通信计算以及训练过程中的主要参数，用于说明实验环境和变量取值；对比方法与评价指标部分说明不同调度策略如何进行比较，并给出任务处理、队列积压、任务丢弃、吞吐和安全约束等评价指标；性能分析部分结合训练曲线、调度结果、安全约束处理和消融实验，讨论不同设计对系统性能产生的影响。上述内容均围绕前文已经建立的动作、队列、链路和安全约束展开，为评价无人机-卫星协同任务调度算法提供实验依据。

本章后续内容安排如下。第 4.2 节说明仿真实验设置，涉及场景参数、任务队列参数、通信计算参数和训练参数；第 4.3 节说明对比方法与评价指标；第 4.4 节分析算法训练过程中的收敛表现；第 4.5 节比较不同方法在任务处理、队列积压和吞吐等方面的调度结果；第 4.6 节分析运动安全与约束处理效果；第 4.7 节借助消融实验讨论关键模块对性能的影响；第 4.8 节对本章内容进行总结。

4.2 仿真实验设置

为验证所提结构化多智能体强化学习调度算法的有效性，本文构建无人机-卫星协同任务调度仿真环境。仿真环境按照第二章建立的系统模型运行，在离散时隙内更新地面用户任务到达、无人机运动状态、卫星可见关系、接入链路传输、回传链路传输、卫星侧任务处理以及多级队列状态。算法训练与评估均在该环境中进行，各类对比方法使用相同的场景参数、任务负载和通信计算参数，以保证性能比较具有一致的实验基础。

本节从仿真场景与网络参数、任务到达与队列参数、通信计算与运动参数以及训练参数四个方面介绍实验设置。仿真场景与网络参数用于确定地面用户、无人机和低轨卫星的空间关系；任务到达与队列参数决定系统负载强度和任务积压特征；通信、计算与运动参数决定任务在接入链路、回传链路和卫星处理环节中的服务能力；训练参数则用于说明强化学习算法的优化过程和网络更新设置。

4.2.1 仿真场景与网络参数

本文仿真场景包含地面用户、无人机和低轨卫星三类节点，任务区域采用二维正方形区域表示，系统运行过程按离散时隙推进。地面用户在任务区域内以聚类形式分布，无人机在区域内开展移动接入与卫星回传调度，低轨卫星按照 Walker 星座模型生成空间位置并随时间更新^[49]。本节列出场景规模、时间参数和节点空间分布参数，用于说明后续仿真实验所采用的基本网络环境。

表 4.1 仿真场景规模与时间参数设置

参数	取值
任务区域大小	1500 m × 1500 m
时隙长度	1 s
单回合时隙数	250
地面用户数量	20
无人机数量	3
低轨卫星数量	144
Walker 星座轨道面数	6
Walker 星座倾角	53°
卫星轨道高度	500 km
无人机飞行高度	100 m
最小仰角门限	5°

单回合时隙数设置为 250。在该时长内，无人机通常可以经历由初始随机位置向用户聚集区域靠近的移动过程，以及到达主要服务区域后围绕局部用户分布和队列状态进行位置微调的调度过程。因此，该设置能够覆盖无人机从初始部署到相对稳定服务

状态的主要动态变化，便于观察移动接入、卫星回传选择和队列演化之间的相互影响。

表 4.2 节点空间分布参数设置

参数	取值
参考纬度	39.9042°
参考经度	116.4074°
地面用户聚类数量	3
聚类中心最小间距	700 m
用户簇内标准差	80 m

其中，参考经纬度用于确定卫星星座相对于任务区域的观测参考位置。地面用户在任务区域内呈聚集分布，通过聚类数量、聚类中心最小间距和簇内标准差控制用户空间分布的集中程度。无人机初始水平位置在任务区域内随机生成，并在初始化阶段保证无人机之间满足安全距离约束，以避免初始状态直接引入碰撞或安全约束违反。

4.2.2 任务到达与队列参数

在上述网络场景基础上，地面用户按照离散时隙持续产生计算任务。为体现任务负载在时间维度和用户维度上的不均衡性，本文采用随机任务到达模型，并引入基于用户子集的热点流量机制。任务到达后进入地面用户队列，再根据无人机接入决策上传至无人机队列，并经由卫星回传链路进入卫星队列等待处理。本节给出任务到达、热点流量和多级队列容量等参数设置，用于说明实验中的任务负载和队列约束条件。

表 4.3 任务到达与热点流量参数设置

参数	取值
平均任务到达率	2.0×10^6 bit/slot
单个热点用户子集规模上限	10
热点流量倍率	20
热点平均持续时长	20 个时隙
热点平均关闭时长	1 个时隙

任务到达过程采用泊松随机到达模型。为刻画用户需求在时间维度和用户维度上的不均衡性，仿真中预先构造若干候选热点用户子集，并在每个时隙根据热点开启和关闭状态确定当前激活的热点子集。当某一热点子集处于激活状态时，该子集内用户的任务到达强度相对提高，同时通过平均到达率保持处理避免系统总输入负载被简单放大。该设置主要用于模拟局部用户需求突增对无人机接入调度和多级队列演化的影响。

上述队列容量按照等效时隙数进行折算。其中，地面用户队列容量对应 24 个时隙的参考任务量，无人机队列以及卫星队列容量分别对应 60 个时隙的参考任务量。这种

表 4.4 多级队列容量参数设置

参数	取值
单个地面用户队列容量	$4.8 \times 10^7 \text{ bit}$
单架无人机队列容量	$8.0 \times 10^8 \text{ bit}$
单颗卫星队列容量	$8.0 \times 10^8 \text{ bit}$

设置使地面用户侧队列对接入不足更敏感，同时为无人机缓存和卫星侧等待处理保留更大缓冲空间。实验中三层队列初始值均设为 0，使队列积压和任务丢弃主要由后续任务到达、链路传输、卫星处理和调度决策共同决定。当任一层队列超过对应容量时，超出部分按任务丢弃处理。

4.2.3 通信、计算与运动参数

通信、计算与运动参数决定了任务在系统中的实际服务能力和无人机可执行动作范围。其中，接入链路参数影响地面用户上传到无人机的速率，回传链路参数影响无人机将缓存任务转发到低轨卫星的能力，卫星计算参数决定卫星侧任务处理速度，无人机运动参数则约束无人机在连续时隙中的位置更新和安全距离保持。本节给出上述参数设置，用于说明仿真实验中的链路服务能力、计算处理能力和运动约束条件。

无人机接入带宽表示单架无人机可用于服务其关联地面用户的接入带宽资源，并由带宽分配动作在关联用户之间进行划分。卫星回传带宽表示单条无人机-卫星回传链路可用的带宽资源。接入链路采用第二章所述概率 LoS/NLoS 模型和 Rician 遍历谱效率模型^[36,37]，其中 LoS 概率参数和 LoS/NLoS 附加损耗按照典型城市环境设置，并考虑不同无人机接入链路之间的同频干扰。回传链路采用自由空间路径损耗模型，并结合北京地区参考位置下的大气损耗、ITU-R P.618/P.838 雨衰模型和多普勒影响计算链路速率^[38-40,50]。

无人机运动参数用于限制连续运动动作的可执行范围。最大速度和最大加速度分别约束无人机在单个时隙内的速度幅值和速度变化幅度，安全距离用于判断无人机之间是否发生安全约束违反。实验中无人机初始速度设为 0 m/s，使不同调度策略在相同初始运动状态下进行比较。

4.2.4 训练参数设置

在完成仿真环境参数设置后，需要进一步给出多智能体强化学习算法的训练参数。本文采用第三章所述结构化 Actor-Critic 网络和 MAPPO 更新方法进行策略优化^[9]，训练过程中各无人机共享策略网络参数。在动作生成方面，接入关联和接入带宽分配按照 $K_{bw} = 5$ 的调度周期生成，周期内后续时隙沿用周期起点处的接入关系和带宽比例；

表 4.5 通信与计算参数设置

参数	取值
地面用户发射功率	0.18 W
无人机发射功率	2.0 W
无人机发射天线增益	30 dB
卫星接收天线增益	35 dB
无人机接入带宽	2.0 MHz
卫星回传带宽	10.0 MHz
接入链路载波频率	2.0 GHz
回传链路载波频率	30.0 GHz
噪声功率谱密度	4.0×10^{-21} W/Hz
接入链路噪声系数	5 dB
回传链路噪声系数	3 dB
典型城市环境 LoS 概率参数	$a = 9.61, b = 0.16$
LoS/NLoS 附加损耗	1 dB/20 dB
Rician 因子	10 dB
大气损耗基准值	0.8 dB
降雨率	25 mm/h
雨高	5 km
雨衰时间超越概率	0.5%
极化倾角	45°
最大多普勒频移门限	4000 Hz
卫星计算频率	5.0×10^9 cycle/s
单 bit 计算量	100 cycle/bit

表 4.6 无人机运动与安全参数设置

参数	取值
最大飞行速度	30 m/s
最大加速度	5 m/s^2
安全距离	20 m

运动控制和卫星回传选择仍按时隙生成。在参数更新方面，Critic 先基于有限时域蒙特卡洛回报进行监督训练，再使用训练后的价值函数计算 GAE 优势。此外，训练过程中引入 KL 约束提前停止和学习率衰减机制，用于限制单次策略更新幅度并提高训练稳定性。本节列出上述训练流程中涉及的主要超参数设置^[47,48]。

表 4.7 强化学习训练参数设置

参数	取值
并行环境数	64
单回合时隙数	250
训练更新次数	300
接入带宽调度周期 K_{bw}	5
折扣因子 γ	0.995
GAE 参数 λ	0.95
运动 Actor 学习率	1.0×10^{-4}
卫星选择 Actor 学习率	3.0×10^{-4}
接入带宽 Actor 学习率	3.0×10^{-4}
Critic 初始训练学习率	1.0×10^{-3}
Critic 常规训练学习率	3.0×10^{-4}
PPO 裁剪系数	0.2
梯度裁剪阈值	0.5
Actor 更新轮数	5
Actor 小批量数量	1
Critic 初始训练轮数	20
Critic 常规训练轮数	5
Critic 小批量数量	8
KL 目标阈值	0.02
学习率衰减系数	0.5
安全辅助监督系数	0.1

训练时采用 64 个并行环境采样，每个环境的采样轨迹长度为 250 个时隙，共进行 300 次参数更新。接入关联和接入带宽分配每 5 个时隙重新生成一次，运动控制和卫星回传选择按时隙生成。折扣因子取 $\gamma = 0.995$ 。在折扣回报中， n 步后的奖励权重为 γ^n ，其特征时间尺度约为 $1/(1 - \gamma) = 200$ 个时隙；当 $n = 250$ 时，折扣权重仍有 $0.995^{250} \approx 0.286$ 。因此，该设置能够在单回合内保留较长时间范围内的队列演化和任务处理反馈。

GAE 参数取 $\lambda = 0.95$ 。该参数用于控制优势估计中实际采样奖励与价值函数自举（bootstrap）之间的取舍。当 λ 较小时，优势估计更接近一步时序差分（Temporal Difference, TD）形式，对价值函数估计依赖更强；当 λ 接近 1 时，优势估计更接近蒙特卡洛（Monte Carlo）回报，对后续实际奖励依赖更强。本文取 $\lambda = 0.95$ ，使优势估计能够利用较长时间范围内的实际奖励信息，同时保留价值函数自举对估计方差的抑制

作用。

三类 Actor 使用不同学习率。运动控制动作直接影响无人机位置和安全约束，本文将运动 Actor 学习率设为 1.0×10^{-4} ，以减小连续运动策略更新中的震荡；卫星选择 Actor 和接入带宽 Actor 学习率均设为 3.0×10^{-4} 。Critic 使用有限时域蒙特卡洛回报作为监督目标。在首轮更新时，价值函数尚未形成稳定的累计回报尺度，因此使用 1.0×10^{-3} 的学习率和 20 轮训练进行初始拟合；后续更新中，Critic 已具备基本价值估计能力，因此使用 3.0×10^{-4} 的学习率和 5 轮训练跟踪策略变化。Critic 每轮训练划分为 8 个小批量，Actor 每轮更新使用当前采样批次中的全部样本。PPO 裁剪系数取 0.2，对应将新旧策略概率比值限制在 $[0.8, 1.2]$ 的主要范围内。梯度裁剪阈值取 0.5，用于限制多阶段动作和热点任务负载下可能出现的梯度突增。安全辅助监督系数取 0.1，使安全修正样本对运动策略产生辅助约束，同时保持队列感知奖励仍是策略优化的主要驱动。Actor 更新过程中设置 KL 目标阈值为 0.02。训练实现中以 1.5 倍目标 KL 作为提前停止阈值，即当阶段 Actor 更新后的近似 KL 散度超过 0.03 时，提前结束该阶段当前轮 Actor 更新，以避免新策略相对采样策略偏离过大。动态学习率衰减同时参考近似 KL 散度和 PPO 裁剪比例：当近似 KL 散度超过 0.03 或裁剪比例超过 0.3 并持续出现时，对应阶段的 Actor 学习率按照 0.5 的系数衰减。该处理用于限制多阶段 Actor 在训练过程中的策略变化幅度，提高联合训练稳定性。

4.3 对比方法与评价指标

在完成仿真实验参数设置后，需要进一步明确参与比较的调度方法和性能评价指标。本文在相同网络场景、任务到达过程、通信计算参数和无人机运动约束下评估不同调度策略，以保证实验结果能够反映算法决策机制本身的差异。对比方法用于说明本文方法相对于随机策略和启发式策略的性能变化，评价指标则从任务处理、队列积压、任务丢弃、链路吞吐和运动安全等方面刻画系统运行效果。

4.3.1 对比方法设置

为说明所提方法在协同调度中的作用，本文从基准规则、队列感知规则和李雅普诺夫队列方法三个角度设置对比对象。基准规则不依赖学习模型或复杂状态判断，主要用于给出静止、随机、均匀分配等简单决策下的参考性能。队列感知规则根据用户需求、链路条件、卫星队列和用户空间分布等信息生成动作，用于反映显式规则设计在协同调度问题中的效果，其中运动控制进一步包含面向用户簇位置和面向队列负载的两类规则。李雅普诺夫队列方法以队列稳定性为主要出发点^[6]，用于比较基于队列漂移思想的调度方法与强化学习策略在长期任务处理和队列控制上的差异。

具体对比方法如表 4.8 所示。表中分别给出各方法在无人机运动控制、卫星回传选择和接入带宽分配三个动作阶段采用的决策方式。对于包含学习策略的方法，训练和测试均采用相同的场景参数与评价指标；对于规则方法，仅替换动作生成方式，不改变环境模型、任务到达过程和队列更新规则。这样可以将性能差异归因于调度决策机制本身。

表 4.8 对比方法设置

方法名称	运动控制	卫星回传选择	接入带宽分配
本文方法	结构化策略网络	结构化策略网络	结构化策略网络
静止基准	保持静止	可见卫星均匀选择	有效用户均匀分配
随机基准	随机运动	可见卫星随机选择	有效用户随机分配
链路优先规则	保持静止	优先选择链路质量较好的卫星	优先分配给链路质量较好的用户
需求优先规则	保持静止	优先选择队列积压较小的卫星	优先分配给任务需求较大的用户
簇中心运动规则	面向用户簇中心移动	队列感知规则	队列感知规则
队列感知规则	队列感知运动规则	队列感知规则	队列感知规则
李雅普诺夫队列方法	李雅普诺夫队列规则	李雅普诺夫队列规则	李雅普诺夫队列规则

李雅普诺夫队列方法是一类以队列稳定性为出发点的即时调度方法。该方法根据当前队列状态构造李雅普诺夫函数，并在每个时隙选择使队列漂移上界较小的调度动作。落实到本文场景中，接入带宽分配倾向于服务队列压力较高且当前接入链路条件较好的地面用户；卫星回传选择倾向于把无人机侧积压任务转发到排队压力较低、回传链路条件较好的可见卫星；无人机运动则根据用户侧任务压力调整服务位置，使无人机更靠近当前更需要服务的区域。该方法不依赖策略训练，用于比较队列稳定性导向的传统调度方法与本文学习型协同调度方法之间的差异。

表 4.8 中的队列感知规则在不同动作阶段使用的信息不同。在运动控制、卫星回传选择和接入带宽分配三个阶段中，该规则分别结合当前队列状态与对应阶段能够观测到的位置信息或链路条件生成动作。对于运动控制，队列感知规则根据用户待处理任务和用户位置确定无人机移动方向，使无人机向任务需求较高的区域靠近；对于卫星回传选择，队列感知规则综合可见卫星链路质量和卫星侧队列状态，选择更有利于任务回传与后续处理的卫星；对于接入带宽分配，队列感知规则根据用户待上传任务和接入链路条件分配带宽。簇中心运动规则主要利用用户空间分布信息确定无人机移动方向，不随瞬时队列状态变化直接调整目标。各规则方法的动作生成均按照相同的可行性约束进行处理，包括卫星可见性约束、接入带宽非负与归一化约束以及无人机运动安全约束；因此，对比方法之间的差异主要来自动作决策逻辑，而不是约束处理方式。

4.3.2 评价指标定义

为全面评价不同调度方法的系统性能,本文从任务处理、队列积压、任务丢弃、链路吞吐和运动安全五个方面定义评价指标。任务处理指标用于反映系统在测试回合内完成任务上传、回传和卫星侧处理的能力;队列积压指标用于刻画任务在地面用户、无人机和卫星队列中的滞留程度;任务丢弃指标用于衡量队列容量受限条件下未能保留的任务量;链路吞吐指标用于分析接入链路和卫星回传链路的传输效率;运动安全指标用于评价无人机运动过程中对安全距离约束的满足情况。测试回合的最大长度为 T ,若回合因无人机间距小于安全距离而提前终止,则按照该回合的实际运行时长统计相关任务量和队列量;最终结果根据实验需要对多个随机种子或多个测试回合取平均。

设测试回合长度为 T ,时隙索引为 $t = 0, 1, \dots, T-1$ 。为简化表示,以下先以未提前终止的测试回合为例给出指标定义;对于提前终止的回合,相应求和上限由 T 替换为实际运行时长 T_i^{run} 。记 $A_k(t)$ 为用户 k 在时隙 t 新到达的任务量, $D_k^{\text{g,u}}(t)$ 为用户 k 在该时隙成功上传至无人机的任务量, $D_u^{\text{u,s}}(t)$ 为无人机 u 成功回传至卫星侧的任务量, $D_\ell^{\text{proc}}(t)$ 为卫星 ℓ 完成处理的任务量。测试回合内的总任务到达量定义为

$$D^{\text{arr}} = \sum_{t=0}^{T-1} \sum_{k \in \mathcal{K}} A_k(t). \quad (4.1)$$

总上传任务量定义为

$$D^{\text{g,u}} = \sum_{t=0}^{T-1} \sum_{k \in \mathcal{K}} D_k^{\text{g,u}}(t). \quad (4.2)$$

总回传任务量定义为

$$D^{\text{u,s}} = \sum_{t=0}^{T-1} \sum_{u \in \mathcal{U}} D_u^{\text{u,s}}(t). \quad (4.3)$$

总处理任务量定义为

$$D^{\text{proc}} = \sum_{t=0}^{T-1} \sum_{\ell \in \mathcal{L}} D_\ell^{\text{proc}}(t). \quad (4.4)$$

在此基础上,任务处理比例定义为

$$\eta^{\text{proc}} = \frac{D^{\text{proc}}}{D^{\text{arr}} + \epsilon}, \quad (4.5)$$

其中 ϵ 为避免分母为零的极小正常数。该指标反映测试回合内进入系统的任务最终在卫星侧完成处理的比例。

记 $Q_k^{\text{g}}(t)$ 、 $Q_u^{\text{u}}(t)$ 和 $Q_\ell^{\text{s}}(t)$ 分别表示地面用户 k 、无人机 u 和卫星 ℓ 的队列积压量。按照第二章的队列更新形式,时隙 t 更新结束后的队列状态记为 $Q_k^{\text{g}}(t+1)$ 、 $Q_u^{\text{u}}(t+1)$ 和

$Q_\ell^s(t+1)$ 。地面用户侧平均队列积压定义为

$$\bar{Q}^g = \frac{1}{T|\mathcal{K}|} \sum_{t=0}^{T-1} \sum_{k \in \mathcal{K}} Q_k^g(t+1). \quad (4.6)$$

无人机侧平均队列积压定义为

$$\bar{Q}^u = \frac{1}{T|\mathcal{U}|} \sum_{t=0}^{T-1} \sum_{u \in \mathcal{U}} Q_u^u(t+1). \quad (4.7)$$

卫星侧平均队列积压定义为

$$\bar{Q}^s = \frac{1}{T|\mathcal{L}|} \sum_{t=0}^{T-1} \sum_{\ell \in \mathcal{L}} Q_\ell^s(t+1). \quad (4.8)$$

系统平均队列积压定义为

$$\bar{Q}^{\text{tot}} = \frac{1}{T} \sum_{t=0}^{T-1} \left(\sum_{k \in \mathcal{K}} Q_k^g(t+1) + \sum_{u \in \mathcal{U}} Q_u^u(t+1) + \sum_{\ell \in \mathcal{L}} Q_\ell^s(t+1) \right). \quad (4.9)$$

此外，为与第三章队列感知奖励中的队列时间负载定义保持一致，本文统计平均队列时间负载。设 $W(t+1)$ 为第三章定义的系统队列时间负载，则平均队列时间负载定义为

$$\bar{W} = \frac{1}{T} \sum_{t=0}^{T-1} W(t+1). \quad (4.10)$$

上述指标用于观察任务在不同层级队列中的滞留情况。队列积压和队列时间负载越低，说明调度方法越能够及时完成接入、回传和卫星侧处理。

记 $D_k^{\text{drop},g}(t)$ 、 $D_u^{\text{drop},u}(t)$ 和 $D_\ell^{\text{drop},s}(t)$ 分别为时隙 t 队列更新过程中地面用户 k 、无人机 u 和卫星 ℓ 因队列容量限制而丢弃的任务量。测试回合内地面用户侧丢弃任务量定义为

$$D_{\text{drop}}^g = \sum_{t=0}^{T-1} \sum_{k \in \mathcal{K}} D_k^{\text{drop},g}(t). \quad (4.11)$$

无人机侧丢弃任务量定义为

$$D_{\text{drop}}^u = \sum_{t=0}^{T-1} \sum_{u \in \mathcal{U}} D_u^{\text{drop},u}(t). \quad (4.12)$$

卫星侧丢弃任务量定义为

$$D_{\text{drop}}^s = \sum_{t=0}^{T-1} \sum_{\ell \in \mathcal{L}} D_\ell^{\text{drop},s}(t). \quad (4.13)$$

总丢弃任务量定义为

$$D_{\text{drop}}^{\text{tot}} = D_{\text{drop}}^{\text{g}} + D_{\text{drop}}^{\text{u}} + D_{\text{drop}}^{\text{s}}. \quad (4.14)$$

任务丢弃率定义为

$$\eta^{\text{drop}} = \frac{D_{\text{drop}}^{\text{tot}}}{D^{\text{arr}} + \epsilon}. \quad (4.15)$$

分层丢弃量用于判断队列溢出主要发生的位置，总丢弃率用于衡量系统在队列容量受限条件下未能保留的任务比例。在相同任务到达强度下，较低的任务丢弃率说明调度方法能够更有效地缓解队列溢出。

链路吞吐指标用于衡量接入链路和卫星回传链路在测试回合内的平均传输能力。前文定义的 $D^{\text{g,u}}$ 和 $D^{\text{u,s}}$ 分别表示测试回合内累计上传任务量和累计回传任务量。由于不同实验均采用相同的最大回合长度和时隙长度，本文进一步将其换算为单位时间内的平均吞吐量。平均接入吞吐量定义为

$$R^{\text{g,u}} = \frac{D^{\text{g,u}}}{T\tau_0}. \quad (4.16)$$

平均回传吞吐量定义为

$$R^{\text{u,s}} = \frac{D^{\text{u,s}}}{T\tau_0}. \quad (4.17)$$

其中 τ_0 为单个时隙长度。接入吞吐量反映地面用户任务进入无人机侧队列的效率，回传吞吐量反映无人机队列向卫星侧转移任务的效率。通过同时比较两类吞吐量，可以判断不同调度方法的性能瓶颈主要出现在地面接入阶段还是卫星回传阶段。

运动安全指标用于评价无人机运动过程中对安全距离约束的满足情况。由于本文实验中一旦发生无人机间安全距离违反，当前测试回合即提前终止，因此运动安全评价以碰撞终止事件和安全运行时长为主。设第 i 个测试回合的实际运行时长为 T_i^{run} ，若该回合未发生碰撞，则 $T_i^{\text{run}} = T$ ；若发生碰撞，则 $T_i^{\text{run}} < T$ 。记 C_i 为碰撞终止指示变量，当第 i 个测试回合因无人机间距小于 d_{safe} 而提前终止时， $C_i = 1$ ，否则 $C_i = 0$ 。对于 N_{test} 个测试回合，碰撞终止率定义为

$$\eta^{\text{col}} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} C_i. \quad (4.18)$$

平均安全运行时长定义为

$$\bar{T}^{\text{run}} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} T_i^{\text{run}}. \quad (4.19)$$

碰撞终止率越低、平均安全运行时长越接近 T ，说明调度方法越能够在测试过程中维持安全飞行。

上述指标从任务流动过程和无人机运动过程两个方面评价调度方法。其中，任务处理比例、任务丢弃率和平均队列积压用于衡量系统服务能力；接入吞吐量 and 回传吞吐量用于分析任务传输瓶颈；碰撞终止率和平均安全运行时长用于评价运动安全性。实验分析围绕这些指标对不同调度方法进行对比。

4.4 算法收敛性能分析

本节从训练过程角度分析所提算法的收敛性能。与第 4.3.2 节中的测试评价指标不同，训练收敛分析关注策略在参数更新过程中是否逐渐形成稳定的调度行为。由于本文奖励函数围绕队列时间负载构造，仅观察训练奖励不足以完整说明策略学习效果；因此，本节同时关注平均回合奖励、任务处理与丢弃趋势以及运动安全指标。通过这些曲线可以判断策略是否在训练过程中逐步提高任务服务能力，并观察策略学习过程中无人机运动安全性的变化。




图 4.1 训练过程平均回合奖励变化曲线

图 4.1 给出了训练过程中平均回合奖励的变化情况。横轴为策略更新轮次，纵轴为单个测试回合内各时隙奖励的累计值。本文的回合奖励由队列时间负载和任务丢弃代价构成，能够反映策略在任务接入、卫星回传和队列控制方面的综合表现。随着训练进行，平均回合奖励整体提高，说明策略逐步形成了用户接入、卫星回传和无人机运动之间的协同调度能力。

仅从奖励曲线难以判断策略性能提升是否对应于真实任务服务能力的改善。图 4.2 进一步给出了训练过程中的任务处理比例和任务丢弃率变化。其中，任务处理比例表示测试回合内成功完成卫星侧处理的任务量占任务到达量的比例；任务丢弃率表示因




图 4.2 训练过程任务处理比例与任务丢弃率变化曲线

队列容量限制而被丢弃的任务量占任务到达量的比例。训练早期，任务处理比例较低，任务丢弃率较高，说明无人机运动控制、卫星回传选择和接入带宽分配尚未形成稳定配合。随着训练推进，任务处理比例整体上升，任务丢弃率明显下降，表明策略逐步改善了任务上传、回传和卫星侧处理之间的衔接关系。上述结果表明，奖励提升与任务服务能力改善具有一致趋势。




图 4.3 训练过程碰撞率变化曲线

无人机运动控制会同时影响链路服务能力和飞行安全性，训练过程还需要结合碰撞情况进行观察。图 4.3 给出了训练过程碰撞率变化曲线。碰撞率定义为训练评估回合

中发生碰撞终止的回合数占总评估回合数的比例，其中碰撞终止由无人机间距低于安全距离触发。为便于观察低数值区域的变化，图中纵轴按 10^{-4} 进行缩放显示。训练过程中，碰撞率整体保持在较低水平，并在训练后期接近 0。这说明在安全修正机制和安全辅助监督共同作用下，策略训练过程能够维持较好的无人机运动安全性。

4.5 任务调度性能对比

完成算法收敛性能分析后，本节在测试阶段比较所提方法与各类对比方法的任务调度性能。与上一节关注训练过程变化不同，本节基于训练完成后的固定策略，在相同仿真场景、相同任务到达过程和相同随机种子下统计评估结果，用于比较不同调度方法在最终执行阶段的系统性能。

无人机-卫星协同任务调度的性能不仅取决于最终处理任务量，还与任务在不同层级队列中的滞留情况以及接入、回传链路的传输能力有关。因此，本节从任务处理与丢弃性能、多级队列积压性能以及接入与回传吞吐性能三个方面展开分析。运动安全相关结果将在下一节单独讨论。

4.5.1 任务处理与丢弃性能

任务处理比例和任务丢弃率分别反映系统完成任务服务和避免队列溢出的能力。在相同任务到达过程下，较高的任务处理比例说明调度方法能够将更多任务推进至卫星侧完成处理；较低的任务丢弃率则说明方法能够更好地缓解用户队列、无人机队列和卫星队列中的容量受限问题。图 4.4 给出了不同方法在测试阶段的任务处理比例和任务丢弃率对比。

图 4.4 中，本文方法的任务处理比例为 0.920，高于李雅普诺夫队列方法的 0.914 和簇中心运动规则的 0.893。基础规则方法的任务处理比例均低于 0.49，说明缺少协同运动和队列调度时，较多任务难以及时完成卫星侧处理。在任务丢弃率方面，本文方法为 0.063，与李雅普诺夫队列方法的 0.061 接近，低于簇中心运动规则的 0.079。该结果说明本文方法在提高任务处理比例的同时，仍能保持较低的队列溢出损失。

在规则型方法中，簇中心运动规则和李雅普诺夫队列方法构成两个较强参照。簇中心运动规则通过运动控制使无人机靠近用户热点，接入带宽和卫星选择仍结合当前队列与链路信息生成，因此能够明显改善任务完成情况。但该方法的飞行决策主要由用户空间分布决定，没有把无人机侧积压和回传压力直接纳入运动控制过程，任务进入无人机后仍可能形成滞留。李雅普诺夫队列方法根据当前队列压力组织任务上传和回传，能够有效降低任务丢弃；不过该类即时规则主要依据当前队列和链路状态进行决策，对多时隙运动影响和后续卫星可见关系变化的利用有限。相比之下，本文方法




图 4.4 不同方法的任务处理比例与任务丢弃率对比

在训练中同时学习运动控制、卫星回传选择和接入带宽分配，使三类动作围绕长期队列反馈形成配合，从而在任务完成和队列溢出控制之间取得更好的综合效果。队列感知规则虽然在部分时隙能够服务高负载用户，但测试中存在较高碰撞终止率，因此其任务处理与丢弃结果还需要结合运动安全指标分析。

4.5.2 多级队列积压性能

多级队列积压反映任务在系统不同处理环节中的滞留情况。与任务处理比例和任务丢弃率相比，队列积压能够进一步说明调度方法是否在接入、回传和卫星处理之间形成匹配。当地面用户队列较高时，说明用户产生的任务难以及时上传至无人机；当无人机队列较高时，说明接入任务进入无人机后未能及时回传至卫星；卫星侧队列则反映任务回传到卫星后的短时等待情况，其数值需要结合任务处理比例和回传吞吐共同分析。图 4.5 给出了不同方法在测试阶段的多级平均队列积压对比。

图 4.5 显示，本文方法的地面用户平均队列为 8.83 Mbit，低于簇中心运动规则的 11.46 Mbit 和李雅普诺夫队列方法的 10.71 Mbit；无人机平均队列为 1.56 Mbit，明显低于簇中心运动规则的 7.54 Mbit 和李雅普诺夫队列方法的 8.24 Mbit。这说明本文方法不只是提高最终完成任务的比例，还减少了任务在用户侧等待上传和在无人机侧等待回传的时间。相比之下，静止基准、链路优先规则和需求优先规则在地面用户队列上存在明显积压，说明这些方法难以根据任务空间分布和队列状态调整接入服务位置。

李雅普诺夫队列方法能够降低地面用户侧积压，说明队列压力驱动的即时调度对用户上传具有较强作用。但是，该方法的无人机侧队列较高，表明任务进入无人机后，




图 4.5 不同方法的多级平均队列积压对比

回传选择和运动位置之间仍存在不匹配。簇中心运动规则能够改善用户接入，但无人机侧队列积压同样较高，说明仅让无人机靠近用户热点并不能保证任务及时进入卫星处理环节。在当前实验参数下，卫星侧处理能力能够及时消化回传任务，因此图中卫星队列为 0，队列差异主要体现在地面用户侧和无人机侧。综合图 4.4 的任务处理与丢弃结果，本文方法能够在保持较高任务处理比例的同时降低前两层队列积压。

为进一步分析无人机侧任务滞留的分布情况，本文统计无人机队列时间负载的尾部积压和不均衡程度。根据第二章和第三章中的队列时间负载定义，无人机 u 在时隙 t 队列更新后的队列时间负载可写为

$$W_u^u(t+1) = c_u^u(t)Q_u^u(t+1). \quad (4.20)$$

其中， $Q_u^u(t+1)$ 为无人机队列长度， $c_u^u(t)$ 为单位任务对应的后续服务时间代价，因此 $W_u^u(t+1)$ 的单位为时隙，表示无人机侧当前积压任务折算后的时间负载。设第 e 个测试回合长度为 T_e ，则无人机 u 的回合平均队列时间负载为

$$\bar{W}_{e,u}^u = \frac{1}{T_e} \sum_{t=0}^{T_e-1} W_{e,u}^u(t+1). \quad (4.21)$$

在 E 个测试回合上，无人机侧最大平均队列时间负载定义为

$$W_{\max}^u = \frac{1}{E} \sum_{e=1}^E \max_{u \in \mathcal{U}} \bar{W}_{e,u}^u, \quad (4.22)$$

无人机侧队列不均衡程度定义为

$$\Delta W^u = \frac{1}{E} \sum_{e=1}^E \left(\max_{u \in \mathcal{U}} \bar{W}_{e,u}^u - \min_{u \in \mathcal{U}} \bar{W}_{e,u}^u \right). \quad (4.23)$$

此外，本文对 $\{\max_{u \in \mathcal{U}} \bar{W}_{e,u}^u\}_{e=1}^E$ 统计 90% 分位数，用于刻画测试回合中的无人机侧尾部队列积压。图 4.6 给出了相关对比结果。




图 4.6 不同方法的无人机侧队列尾部积压与不均衡对比

图 4.6 进一步说明了无人机侧队列差异。本文方法在三个无人机侧队列时间负载指标上均低于簇中心运动规则和李雅普诺夫队列方法。本文方法的最大平均队列时间负载为 0.32 个时隙，簇中心运动规则和李雅普诺夫队列方法分别为 1.55 个时隙和 1.99 个时隙；队列不均衡程度为 0.32 个时隙，低于后两者的 1.54 个时隙和 1.98 个时隙。在尾部积压方面，本文方法的最大队列时间负载 90% 分位为 0.67 个时隙，而簇中心运动规则和李雅普诺夫队列方法分别为 4.25 个时隙和 5.46 个时隙。这些结果说明，本文方法不仅降低了无人机侧平均队列压力，也减少了不同无人机之间的负载不均衡和尾部积压。从平均回合奖励看，本文方法为 67.03，高于李雅普诺夫队列方法的 48.08 和簇中心运动规则的 46.67。这说明所提策略能够更充分地疏导无人机侧中继队列，上述奖励差异主要来自无人机侧队列时间负载降低，而不是单一任务处理比例指标的变化。

4.5.3 接入与回传吞吐性能

接入吞吐和回传吞吐用于进一步分析任务在通信链路中的流动情况。前文结果已经表明，不同方法的队列差异主要体现在地面用户队列和无人机队列上。因此，仅观

察最终任务处理比例和平均队列积压还不足以说明任务在接入链路和回传链路之间是否形成匹配。若接入吞吐较高而回传吞吐不足，任务会在无人机侧形成积压；若回传吞吐较高但接入吞吐不足，则说明无人机未能充分接收地面用户任务。因此，接入吞吐和回传吞吐的对比能够进一步说明调度方法是否在用户接入和卫星回传之间形成连续的任务流动过程。图 4.7 给出了不同方法在测试阶段的归一化接入吞吐和归一化回传吞吐对比。




图 4.7 不同方法的归一化接入吞吐与回传吞吐对比

图 4.7 显示，本文方法的归一化接入吞吐和归一化回传吞吐分别为 0.923 和 0.920，二者数值接近且均为最高。李雅普诺夫队列方法的两项指标分别为 0.920 和 0.914，簇中心运动规则的两项指标分别为 0.902 和 0.893，均低于本文方法。该结果说明，本文方法不仅能够使无人机接收更多地面用户任务，还能够将进入无人机队列的任务继续通过卫星链路回传，接入和回传两个环节之间的衔接更加充分。

结合前文队列结果可知，吞吐指标主要反映任务在接入链路和回传链路上的传输量，还需要结合无人机侧队列进一步判断任务是否在中继环节形成积压。李雅普诺夫队列方法的两项吞吐指标接近本文方法，但其无人机侧最大平均队列时间负载和尾部队列积压仍高于本文方法，说明即时队列规则能够提升任务传输量，但对不同无人机之间的中继负载分布调节不足。簇中心运动规则能够改善用户接入和任务回传，但无人机侧尾部队列积压仍较明显。相比之下，本文方法在保持较高接入吞吐和回传吞吐的同时，降低了无人机侧队列不均衡程度和尾部积压，说明所提策略能够更好地协调任务接入、卫星回传和无人机侧任务分布。

4.6 运动安全与约束处理效果分析

前文从任务处理、队列积压和链路吞吐角度分析了不同方法的调度性能。不过，无人机运动控制同时决定地面用户接入条件、卫星回传几何关系和多无人机之间的空间距离。如果调度方法为了接近高负载用户区域而频繁缩小无人机间距，即使能够获得较高任务传输量，也可能因碰撞终止而无法稳定完成整个测试回合。在本文场景中，若任意两架无人机之间的距离低于安全距离阈值，则认为发生碰撞并终止当前测试回合。因此，本节从碰撞终止率和平均安全运行时长两个方面分析不同方法的运动安全表现，用于判断调度策略在提升任务服务能力的同时是否能够维持稳定运行。




图 4.8 不同方法的碰撞终止率与平均安全运行时长对比

图 4.8 显示，本文方法在测试阶段碰撞终止率为 0，平均安全运行时长为 250 个时隙，能够覆盖完整测试回合。除随机基准和队列感知规则外，其他对比方法同样未发生碰撞终止。随机基准的碰撞终止率为 31.25%，平均安全运行时长为 214.2 个时隙；队列感知规则的碰撞终止率达到 71.88%，平均安全运行时长仅为 148.8 个时隙。随机基准缺少明确运动目标，容易在多无人机同时移动时产生安全距离违反。队列感知规则主要依据队列负载和用户位置确定无人机运动方向，多架无人机可能同时向高负载区域靠近，从而增加无人机间距过小的风险。相比之下，本文方法在动作执行前引入运动安全约束处理，并在训练中利用安全辅助监督降低候选运动动作对安全修正层的依赖，因此能够在保持任务调度性能的同时维持完整回合内的运动安全。

为进一步直观展示所提方法的运动调度结果，本文选取一个完整测试回合绘制无人机水平运动轨迹，如图 4.9 所示。图中圆点表示地面用户位置，空心圆表示无人机初始位置，三角形表示无人机终止位置，曲线表示无人机运动轨迹。图 4.9 中，三架无人

机从不同初始位置出发，运动轨迹分别指向左侧、右上侧和右侧用户簇附近。在回合后期，无人机终止位置保持分散，没有全部集中到同一用户热点区域。这说明策略在接近高任务需求区域的同时，仍保留了多无人机之间的空间分工。结合图 4.8 的碰撞终止率结果可知，本文方法能够在完成任务调度的同时保持稳定的运动行为。




图 4.9 典型评估回合中的无人机运动轨迹

4.7 消融实验分析

在完成不同调度方法的总体性能比较后，本节进一步分析所提方法中关键设计对实验结果的影响。消融实验分为两组：一组围绕运动控制、接入带宽分配和卫星回传选择三个动作头展开，比较规则补齐参考、仅学习单类动作头和完整三动作头方法的性能差异，用于观察不同动作决策对任务处理、队列时间负载、接入吞吐和回传吞吐的作用；另一组围绕安全辅助监督展开，比较开启和关闭该监督信号时安全修正介入率和测试阶段调度性能的差异，用于说明安全辅助监督对运动控制策略学习和任务调度结果的影响。

4.7.1 动作头消融实验设置

动作头消融实验围绕三类动作决策展开。规则补齐参考方法由三类规则动作组成：运动控制采用簇中心运动规则，接入带宽分配和卫星回传选择采用队列感知规则，作为不依赖学习动作头的对照；完整三动作头方法由策略网络同时输出三类动作，用于表示本文方法的完整动作决策形式。在此基础上，本文分别构造仅学习运动控制、仅学习接入带宽分配和仅学习卫星回传选择三组消融方法。对于仅学习单类动作头的方法，当前动作头由策略网络输出，其余两类动作由规则方法补齐，并在相同可行性约束下执行。这样可以在保持基本执行流程一致的前提下，观察单类学习动作对整体调度性能的影响。

表 4.9 动作头消融实验设置

方法	运动控制	接入带宽分配	卫星回传选择
规则补齐参考	规则	规则	规则
仅学习运动控制	学习	规则	规则
仅学习接入带宽分配	规则	学习	规则
仅学习卫星回传选择	规则	规则	学习
完整三动作头	学习	学习	学习

其中，“学习”表示对应动作由策略网络输出，“规则”表示对应动作由上述规则组合中的相应规则给出。

4.7.2 动作头消融结果分析




图 4.10 动作头消融实验结果

图 4.10 给出了不同动作头组合下的队列时间负载、任务处理比例、归一化接入吞吐和归一化回传吞吐。为突出不同动作头组合之间的差异，图中各指标纵轴按照对应数值范围进行截取。图中，队列时间负载越低表示系统中未完成任务对应的等待压力越小，任务处理比例、归一化接入吞吐和归一化回传吞吐越高则表示任务流动效率越高。

完整三动作头方法的队列时间负载为 4.531 个时隙，低于规则补齐参考方法的 6.294 个时隙；任务处理比例、归一化接入吞吐和归一化回传吞吐分别为 0.920、0.923 和 0.920，均高于其他动作头组合。五组动作头消融实验均未发生碰撞终止，因此该组实验中的差异主要来自任务调度过程本身。

从单动作头结果来看，仅学习运动控制时，任务处理比例提升较为明显，说明无人机位置调整对用户接入和后续任务流动具有基础作用。但是，该方法的队列时间负载仍高于完整三动作头方法，表明仅改进无人机运动还不足以同时处理接入带宽分配和卫星回传选择。仅学习接入带宽分配能够显著降低队列时间负载，说明带宽动作会直接影响地面用户任务向无人机侧上传的过程。仅学习卫星回传选择则能够提高归一化回传吞吐，表明卫星选择动作会影响无人机侧任务向卫星侧转移的过程。但在其他动作仍由规则生成的情况下，整体任务处理效果仍受到接入和运动决策的限制。

完整三动作头方法同时学习运动控制、接入带宽分配和卫星回传选择，在队列时间负载、任务处理比例、接入吞吐和回传吞吐上均取得最好结果。这说明三类动作分别影响无人机服务位置、用户上传服务和卫星回传服务，任一动作单独学习时仍会受到其他规则动作的限制。三类动作联合学习后，策略能够在无人机移动、用户接入和卫星回传之间形成统一决策，从而改善完整任务流动链路。

4.7.3 安全辅助监督消融分析

为分析安全辅助监督对运动控制策略学习的影响，本文在相同训练配置下对开启和关闭安全辅助监督的情况进行对比。两种设置均保留安全修正层，区别在于 Actor 更新时是否引入由安全修正动作构造的辅助监督项。该组实验用于观察安全辅助监督是否能够使策略输出更接近安全可执行动作，以及这种差异是否会进一步影响任务调度性能。

图 4.11 给出了两种设置下训练过程中的安全修正介入率。安全修正介入率指训练采样过程中候选运动动作经过安全修正层后发生有效修正的样本比例，用于反映 Actor 原始运动动作对安全修正机制的依赖程度。在关闭安全辅助监督的训练中，安全修正介入率最高达到 0.540；在开启安全辅助监督的训练中，该指标最高为 0.279。在最后 100 次更新中，开启和关闭安全辅助监督对应的平均介入率分别为 0.0325 和 0.0408。这说明安全辅助监督能够降低训练过程中候选运动动作被安全修正层改写的频率，使运动控制策略输出更接近安全可执行动作。

为进一步观察安全辅助监督对最终调度效果的影响，本文在相同测试场景、相同任务到达过程和相同随机种子下对两种方法进行评估。图 4.12 给出了两种设置在测试阶段的调度性能。两种设置均未发生碰撞终止，平均回合长度均为 250 个时隙。这说




图 4.11 安全辅助监督对训练过程安全修正介入率的影响

明在当前安全修正层下二者都能完成完整测试回合。在任务调度指标上，开启安全辅助监督时平均回合奖励为 67.03，高于关闭安全辅助监督时的 57.66；任务处理比例为 0.920，高于关闭时的 0.891；任务丢弃率为 0.063，低于关闭时的 0.068。在队列指标上，开启安全辅助监督时系统平均队列时间负载和无人机侧平均队列时间负载分别为 4.53 和 0.11 个时隙，低于关闭时的 6.66 和 1.84 个时隙。




图 4.12 安全辅助监督对测试阶段调度性能的影响

上述结果表明，安全辅助监督的作用不只体现在碰撞终止率上。在本组测试中，两种设置均能完成完整回合，但开启安全辅助监督后，候选运动动作在训练过程中被安全修正层改写的频率更低。这使 Actor 输出动作、环境实际执行动作和采样反馈之间的对应关系更加稳定，从而降低安全修正层频繁介入对策略更新造成的干扰。测试阶段任务处理比例、任务丢弃率和队列时间负载的差异也说明，更稳定的运动控制学习能够进一步影响整体调度效果。

4.8 本章小结

本章围绕无人机-卫星协同任务调度问题开展仿真实验，在第二章系统模型和第三章算法设计的基础上，构建了包含地面用户、无人机和低轨卫星的实验场景。实验设置覆盖用户热点流量、无人机运动、卫星可见关系变化、接入与回传链路传输以及三层队列演化过程，并给出了训练参数、对比方法和评价指标。在上述实验配置基础上，本章进一步开展了训练收敛、方法对比、运动安全和消融实验分析。

实验结果表明，本文方法在队列时间负载、任务处理比例、任务丢弃率、链路吞吐和运动安全等指标上取得了较好的综合表现。相比基础规则、启发式规则和李雅普诺夫队列方法，本文方法能够在保持较高任务处理比例和较低任务丢弃率的同时，降低系统队列时间负载，并维持完整测试回合内的安全运行。这说明所提方法能够利用多无人机协同决策能力，更有效地协调无人机运动控制、地面用户接入带宽分配和卫星回传选择之间的关系，在改善任务流动过程的同时满足无人机运动安全要求。

消融实验进一步说明所提方法中关键设计的作用。动作头消融结果表明，仅学习运动控制、接入带宽分配或卫星回传选择中的单类动作，能够改善对应环节的部分指标，但难以同时降低队列时间负载并提升接入吞吐、回传吞吐和任务处理比例。完整三动作头联合学习能够更好地协调任务接入、无人机中继和卫星回传过程。安全辅助监督消融结果表明，在危险状态下引入安全修正动作对候选运动动作的辅助监督，有助于运动控制策略学习更接近安全约束的动作输出，并使策略在测试阶段取得更好的任务处理和队列控制效果。

第五章 总结与展望

本章对全文研究工作进行归纳，总结无人机-卫星协同任务调度建模、结构化多智能体强化学习算法设计以及仿真实验分析得到的主要认识，并结合当前模型和实验范围说明后续可继续深入的研究方向。

5.1 全文工作总结

本文研究无人机-卫星协同任务调度问题，重点关注地面用户任务在“地面用户-无人机-低轨卫星”三层网络中的接入、回传、排队和处理过程。在该问题中，地面用户任务随机到达，无人机位置不断变化，低轨卫星可见关系随时间更新，多架无人机的动作还会相互影响。围绕这些特性，本文从系统建模、算法设计和仿真实验三个层面开展研究，把无人机运动控制、卫星回传选择和接入带宽分配放入同一多智能体决策过程中进行分析。

在系统建模方面，本文建立无人机-卫星协同任务调度场景模型。模型中明确了地面用户、无人机和低轨卫星三类节点的作用，描述任务从地面用户上传到无人机、再由无人机回传至低轨卫星并完成处理的流转过程。围绕任务流动，本文建立空地接入链路、星机回传链路、卫星计算处理和多级队列演化模型，并给出无人机运动约束、卫星可见性约束和安全距离约束。在此基础上，本文将三层网络中的协同调度问题形式化为多无人机协同决策问题，为算法设计提供状态、动作、约束和优化目标定义。

在算法设计方面，本文提出基于结构化多智能体强化学习的协同任务调度方法。该方法选用集中式训练、分布式执行框架，使各无人机在执行阶段依据自身局部观测生成动作，并在训练阶段借助全局状态信息进行价值评估和策略更新。针对局部观测中同时包含自身状态、候选用户、可见卫星和邻近无人机等异构信息的特点，本文设计结构化观测编码方式和参数共享的分阶段 Actor-Critic 网络。针对运动控制、卫星回传选择和接入带宽分配在动作类型、更新频率和约束形式上的差异，本文将运动控制和卫星回传选择设置为逐时隙动作，将接入关联和接入带宽分配设置为按调度周期生成并在周期内执行的比例动作。在训练过程中，本文先利用有限时域蒙特卡洛回报训练 Critic，再使用训练后的 Critic 计算 GAE 优势并更新 Actor，同时结合约束感知动作处理机制、队列感知奖励和安全辅助监督，形成面向无人机-卫星协同任务调度的策略优化方法。

在仿真实验方面，本文构建包含地面用户聚类分布、热点任务到达、低轨卫星时

变可见关系和多级队列演化的实验场景，并从任务处理、任务丢弃、队列积压、链路吞吐和运动安全等方面定义评价指标。通过与基准规则、队列感知规则和李雅普诺夫队列方法进行比较，本文分析所提方法在动态任务调度场景中的综合表现。同时，本文开展动作头消融实验和安全辅助监督对比实验，进一步观察不同动作阶段和安全辅助机制对算法表现的影响。

5.2 主要研究结论

本文的主要研究结论体现在训练收敛、任务调度性能、运动安全表现和消融实验结果四个方面。总体来看，无人机-卫星协同任务调度不能只依赖固定规则或单一局部指标进行决策，因为无人机位置、用户任务需求、卫星可见关系、链路服务能力和多级队列状态之间存在持续影响。结构化多智能体强化学习方法在统一策略中处理运动控制、卫星回传选择和接入带宽分配，能够更好地协调任务流动效率、队列积压和无人机运动安全之间的关系。

训练过程结果表明，基于队列感知奖励构造的策略能够逐步学习较稳定的协同调度行为。随着训练推进，平均回合奖励整体提升，任务处理比例逐渐提高并在后期保持在较高水平，任务丢弃率整体下降。同时，训练过程中的碰撞率整体下降，说明约束感知动作处理和安全辅助监督能够在策略优化过程中抑制危险运动行为。这表明所提方法不仅改善了任务服务结果，也在训练阶段逐步形成了较稳定的无人机运动控制方式。

测试阶段结果表明，本文方法在任务处理比例、任务丢弃率、队列积压和链路吞吐等指标上取得较好的综合表现。与静止基准、随机基准、链路优先规则和需求优先规则相比，本文方法能够更充分地运用无人机移动能力、接入带宽资源和卫星回传链路，使任务上传、回传和卫星侧处理之间的衔接更加顺畅。与簇中心运动规则、队列感知规则和李雅普诺夫队列方法相比，本文方法在保持较高任务处理比例的同时，进一步降低队列时间负载和无人机侧队列积压，并保持较低任务丢弃率。这说明仅依赖用户空间分布、队列状态或局部链路指标的规则方法，难以适应卫星可见关系、链路状态和多级队列随时间变化带来的联合调度需求。

运动安全结果表明，无人机运动控制对协同任务调度性能具有重要影响。本文方法在测试阶段未发生碰撞终止，平均安全运行时长达到完整测试回合长度，说明所提策略在改善任务调度性能的同时能够维持无人机之间的安全距离约束。相比之下，随机基准存在一定碰撞终止风险；队列感知规则虽然改善了部分任务处理和队列指标，但由于多架无人机容易同时向高负载区域靠近，在测试中出现较高碰撞终止率。因此，任务调度性能和运动安全性需要结合分析，仅依据任务处理或队列指标判断方法优劣并不充分。

消融实验结果进一步说明，运动控制、接入带宽分配和卫星回传选择三类动作之间具有明显协同关系。仅学习单类动作头时，部分指标能够得到改善，但难以同时兼顾队列时间负载、任务处理比例、接入吞吐和回传吞吐。完整三动作头方法取得最低队列时间负载，并在任务处理比例、接入吞吐和回传吞吐上取得更好结果，说明将三类动作放在统一策略中联合学习更有利于改善任务流动过程。安全辅助监督实验结果表明，在保留安全修正层的条件下，关闭该监督信号时训练中期安全修正介入率明显升高，说明 Actor 输出的候选运动动作更频繁地需要由安全修正层进行调整；开启安全辅助监督后，安全修正介入率峰值降低，并在训练后期维持在较低水平。在相同测试场景下，开启安全辅助监督时任务处理比例、任务丢弃率和队列时间负载等指标也取得更好结果。这说明由安全修正动作提供的辅助监督信息，能够引导运动动作头输出更接近安全可执行结果的候选动作，并为协同任务调度提供更稳定的运动控制基础。

5.3 未来研究方向

围绕无人机-卫星协同任务调度问题，本文已经从系统建模、算法设计和仿真实验分析三个方面开展研究。面向更复杂的空天地协同网络应用，后续研究仍可从业务模型扩展、跨场景泛化部署以及安全鲁棒决策三个方面继续深入。

5.3.1 差异化业务与任务依赖建模

当前任务模型主要围绕随机到达的数据任务、队列积压和卫星侧处理过程展开。在更复杂的空天地协同网络中，地面用户可能同时产生感知数据回传、视频分析、应急通信、目标识别和控制指令等多类业务。不同业务在时延、可靠性、任务优先级和办理流程方面具有不同要求，后续研究需要进一步引入差异化业务模型，使调度策略能够根据任务类型和服务质量需求调整接入、回传和处理决策。

此外，实际任务之间可能存在依赖关系。例如，部分任务需要先完成数据预处理，再执行目标识别或状态估计；部分任务需要多个节点协同完成不同处理阶段。后续研究可将任务依赖关系表示为任务链或任务图，并在队列状态之外引入任务阶段、任务截止时间和依赖完成状态等信息。在这种模型下，调度策略不仅需要降低单个队列的积压，还需要关注任务链整体完成时间和关键任务的服务可靠性。

5.3.2 跨场景泛化与在线自适应部署

本文实验在固定规模的用户、无人机和低轨卫星场景下进行，后续研究需要进一步关注策略在不同网络规模和环境条件下的泛化能力。当用户数量、无人机数量、卫星轨道参数、任务到达强度或链路传播条件发生变化时，原有策略会面临观测分布和

动作可行集合变化。因此，后续可通过场景随机化、参数共享结构改进和跨规模训练等方式，提升策略在不同拓扑和负载条件下的适应能力。

在实际部署中，空天地网络还具有长期动态变化特征。用户热点区域、卫星可见窗口、天气条件和任务负载都可能随时间变化，使离线训练得到的策略难以始终保持稳定性能。后续研究可结合在线微调、迁移学习和持续学习机制，使策略在有限交互代价下适配新的任务区域和网络状态。同时，还需要关注模型推理时延、通信开销和边缘设备计算资源限制，使多智能体策略能够满足实际无人机平台的部署要求。

5.3.3 面向工程部署的安全约束与鲁棒决策

无人机-卫星协同任务调度不仅要提高任务处理效率，还要在复杂环境中保持可靠运行。后续研究可进一步考虑链路中断、卫星短时不可用、无人机定位误差、节点失效、突发业务到达、热点用户切换和异常任务流量等扰动因素，分析调度策略在非理想观测和非理想执行条件下的性能变化。在此基础上，可结合鲁棒优化、风险敏感决策和异常检测方法，增强策略对突发状态变化的适应能力。

运动安全约束也是工程部署中的关键问题。本文已在动作处理阶段引入安全约束修正机制，后续研究可进一步研究具有更强理论保证的安全控制方法，并将其与多智能体策略训练过程更紧密地结合。此外，对于应急救援、灾害监测等高可靠场景，调度系统还需要具备一定可解释性，能够说明无人机移动、卫星选择和带宽分配动作的主要依据，从而提升智能调度策略在实际系统中的可验证性和可信度。

参考文献

- [1] Nan Cheng, Jingchao He, Zhisheng Yin *et al.* “6G Service-Oriented Space-Air-Ground Integrated Network: A Survey” [J]. *Chinese Journal of Aeronautics*, **2022**, 35(9): 1–18.
- [2] Yong Zeng, Rui Zhang and Teng Joon Lim. “Wireless Communications with Unmanned Aerial Vehicles: Opportunities and Challenges” [J]. *IEEE Communications Magazine*, **2016**, 54(5): 36–42.
- [3] Hongxia Zhang, Shiyu Xi, Hongzhao Jiang *et al.* “Resource Allocation and Offloading Strategy for UAV-Assisted LEO Satellite Edge Computing” [J]. *Drones*, **2023**, 7(6): 383.
- [4] Yue Xiao, Ziqiang Ye, Mingming Wu *et al.* “Space-Air-Ground Integrated Wireless Networks for 6G: Basics, Key Technologies, and Future Trends” [J]. *IEEE Journal on Selected Areas in Communications*, **2024**, 42(12): 3327–3354.
- [5] Zhishu Shen, Jiong Jin, Cheng Tan *et al.* “A Survey of Next-Generation Computing Technologies in Space-Air-Ground Integrated Networks” [J]. *ACM Computing Surveys*, **2023**, 56(1): 1–40.
- [6] Michael J. Neely. *Stochastic Network Optimization with Application to Communication and Queueing Systems* [M]. San Rafael, CA: Morgan & Claypool Publishers, **2010**.
- [7] Liang Liu, Wuping Mao, Wenwei Li *et al.* “Edge Computing Offloading Strategy for Space-Air-Ground Integrated Network Based on Game Theory” [J]. *Computer Networks*, **2024**, 243: 110331.
- [8] Ryan Lowe, Yi Wu, Aviv Tamar *et al.* “Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments” [C]. In: *Advances in Neural Information Processing Systems*. **2017**.
- [9] Chao Yu, Akash Velu, Eugene Vinitzky *et al.* “The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games” [C]. In: *Advances in Neural Information Processing Systems*. **2022**.
- [10] Hai Li, Jinyang Yu, Lili Cao *et al.* “Multi-Agent Reinforcement Learning Based Computation Offloading and Resource Allocation for LEO Satellite Edge Computing Networks” [J]. *Computer Communications*, **2024**, 222: 268–276.
- [11] Peiying Zhang, Shengpeng Chen, Xiangguo Zheng *et al.* “UAV Communication in Space-Air-Ground Integrated Networks (SAGINs): Technologies, Applications, and Challenges” [J]. *Drones*, **2025**, 9(2): 108.
- [12] Shaoxiong Guo, Li Zhou, Shijie Liang *et al.* “Connectivity-Enhanced 3D Deployment Algorithm for Multiple UAVs in Space-Air-Ground Integrated Network” [J]. *Aerospace*, **2024**, 11(12): 969.
- [13] Yuanyuan Hao, Zhengyu Song, Zhong Zheng *et al.* “Joint Communication, Computing, and Caching Resource Allocation in LEO Satellite MEC Networks” [J]. *IEEE Access*, **2023**, 11: 6708–6716.
- [14] Hao Hao, Changqiao Xu, Wei Zhang *et al.* “Joint Task Offloading, Resource Allocation, and Trajectory Design for Multi-UAV Cooperative Edge Computing With Task Priority” [J]. *IEEE Transactions on Mobile Computing*, **2024**, 23(9): 8649–8663.
- [15] Tao Ju, Linjuan Li, Shuai Liu *et al.* “A Multi-UAV Assisted Task Offloading and Path Optimization for Mobile Edge Computing via Multi-Agent Deep Reinforcement Learning” [J]. *Journal of Network and Computer Applications*, **2024**, 229: 103919.

- [16] Zhuwei Wang, Wenjing Zhao, Pengyu Hu *et al.* “UAV-Assisted Mobile Edge Computing: Dynamic Trajectory Design and Resource Allocation” [J]. *Sensors*, **2024**, 24(12): 3948.
- [17] Xu Yang, Hai Fang, Yuan Gao *et al.* “Computation Offloading and Resource Allocation Based on P-DQN in LEO Satellite Edge Networks” [J]. *Sensors*, **2023**, 23(24): 9885.
- [18] Danilo Magliarisi, Emiliano Casalicchio and Vincenzo Salvatore. “Orbit-Aware Task Scheduling in Satellite Edge Computing” [J]. *Cluster Computing*, **2025**, 28: 1013.
- [19] Yunbo Qu, Tingting Zhang, Yuan Feng *et al.* “Computation Offloading and Resource Allocation for E2E Tasks in Satellite Edge Computing Networks” [J]. *Space: Science & Technology*, **2024**: 0144.
- [20] Jian Zhou, Qi Yang, Lu Zhao *et al.* “Mobility-Aware Computation Offloading in Satellite Edge Computing Networks” [J]. *IEEE Transactions on Mobile Computing*, **2024**, 23(10): 9135–9149.
- [21] Bo Xie, Haixia Cui, Ivan Wang Hei Ho *et al.* “Computation Offloading and Resource Allocation in LEO Satellite-Terrestrial Integrated Networks With System State Delay” [J]. *IEEE Transactions on Mobile Computing*, **2025**, 24(3): 1372–1385.
- [22] Qingqing Tang, Zesong Fei, Bin Li *et al.* “Stochastic Computation Offloading for LEO Satellite Edge Computing Networks: A Learning-Based Approach” [J]. *IEEE Internet of Things Journal*, **2024**, 11(4): 5638–5652.
- [23] Jeonghwan Kim and Jeongho Kwak. “DCOOL: Dynamic Computation Offloading and Resource Allocation for LEO Satellite-Assisted Edge Computing in a Ground-Space Integrated Framework” [J]. *ICT Express*, **2024**, 10(6): 1212–1219.
- [24] Yifei Hu, Wenbin Gong and Fangming Zhou. “A Lyapunov-Optimized Dynamic Task Offloading Strategy for Satellite Edge Computing” [J]. *Applied Sciences*, **2023**, 13(7): 4281.
- [25] Haijun Liao, Zhenyu Zhou, Xiongwen Zhao *et al.* “Learning-Based Queue-Aware Task Offloading and Resource Allocation for Space-Air-Ground-Integrated Power IoT” [J]. *IEEE Internet of Things Journal*, **2021**, 8(7): 5250–5263.
- [26] Xin He, Yuanzhi Ni and Hongfeng Tao. “Lyapunov-Based Queue Stability Optimization for Task Offloading in UAV-Assisted VEC” [J]. *Pervasive and Mobile Computing*, **2026**, 115: 102126.
- [27] Zhe Ji, Sheng Wu and Chunxiao Jiang. “Cooperative Multi-Agent Deep Reinforcement Learning for Computation Offloading in Digital Twin Satellite Edge Networks” [J]. *IEEE Journal on Selected Areas in Communications*, **2023**, 41(11): 3414–3429.
- [28] Jian Wu, Min Jia, Ningtao Zhang *et al.* “Multi-Agent Deep Reinforcement Learning-Based Computation Offloading in LEO Satellite Edge Computing System” [J]. *IEEE Communications Letters*, **2024**, 28(10): 2352–2356.
- [29] Xuan Huang, Xu Xia, Zhibo Wang *et al.* “Joint Drone Access and LEO Satellite Backhaul for a Space-Air-Ground Integrated Network: A Multi-Agent Deep Reinforcement Learning-Based Approach” [J]. *Drones*, **2024**, 8(6): 218.
- [30] Feixiang Li, Kai Qu, Mingzhe Liu *et al.* “Collaborative Computation Offloading and Resource Management in Space-Air-Ground Integrated Networking: A Deep Reinforcement Learning Approach” [J]. *Electronics*, **2024**, 13(10): 1804.

- [31] Dang Van Huynh, Saeed R. Khosravirad, Simon L. Cotton *et al.* “Multiagent Reinforcement Learning for Optimal Resource Allocation in Space-Air-Ground Integrated Networks” [J]. *IEEE Internet of Things Journal*, **2026**, 13(3): 3618–3629.
- [32] Shenzhan Xu, Rongke Liu, Hangyu Zhang *et al.* “Heterogeneous Resource Allocation in Space-Air-Ground-Integrated Networks: A Multi-Agent Deep Deterministic Policy Gradient Approach” [J]. *IEEE Internet of Things Journal*, **2025**.
- [33] Ming Cheng, Canlin Zhu, Min Lin *et al.* “A MAPPO Based Scheme for Joint Resource Allocation in UAV Assisted MEC Networks” [C]. In: *2024 IEEE/CIC International Conference on Communications in China*. **2024**: 42–47.
- [34] Jiajing Ling, Moritz Lukas Schuler, Akshat Kumar *et al.* “Knowledge Compilation for Constrained Combinatorial Action Spaces in Reinforcement Learning” [C]. In: *Proceedings of the 22nd International Conference on Autonomous Agents and Multiagent Systems*. **2023**: 860–868.
- [35] Hong Chen, Dan Huang, Chenggang Wang *et al.* “Collision-Free Path Planning for Multiple Drones Based on Safe Reinforcement Learning” [J]. *Drones*, **2024**, 8(9): 481.
- [36] Akram Al-Hourani, Sithamparanathan Kandeepan and Simon Lardner. “Optimal LAP Altitude for Maximum Coverage” [J]. *IEEE Wireless Communications Letters*, **2014**, 3(6): 569–572.
- [37] Marvin K. Simon and Mohamed-Slim Alouini. *Digital Communication over Fading Channels* [M]. 2nd ed. Hoboken, NJ: Wiley-Interscience, **2005**.
- [38] 3GPP. *Study on New Radio (NR) to Support Non-Terrestrial Networks* [R]. **2019**.
- [39] ITU-R. *Attenuation by Atmospheric Gases and Related Effects* [R]. 2022-08.
- [40] ITU-R. *Propagation Data and Prediction Methods Required for the Design of Earth-Space Telecommunication Systems* [R]. 2023-08.
- [41] Frans A. Oliehoek and Christopher Amato. *A Concise Introduction to Decentralized POMDPs* [M]. Cham: Springer, **2016**.
- [42] Manzil Zaheer, Satwik Kottur, Siamak Ravanbakhsh *et al.* “Deep Sets” [C]. In: *Advances in Neural Information Processing Systems*. **2017**.
- [43] Yuan Tian, Minghao Han, Chetan S. Kulkarni *et al.* “A Prescriptive Dirichlet Power Allocation Policy with Deep Reinforcement Learning” [J]. *Reliability Engineering & System Safety*, **2022**, 224: 108529.
- [44] Shengyi Huang and Santiago Ontañón. “A Closer Look at Invalid Action Masking in Policy Gradient Algorithms” [C]. In: *The International FLAIRS Conference Proceedings*. **2022**.
- [45] Aaron D. Ames, Xiangru Xu, Jessy W. Grizzle *et al.* “Control Barrier Function Based Quadratic Programs for Safety Critical Systems” [J]. *IEEE Transactions on Automatic Control*, **2017**, 62(8): 3861–3876.
- [46] Gal Dalal, Krishnamurthy Dvijotham, Matej Vecerik *et al.* “Safe Exploration in Continuous Action Spaces” [J]. *arXiv preprint arXiv:1801.08757*, **2018**.
- [47] John Schulman, Philipp Moritz, Sergey Levine *et al.* “High-Dimensional Continuous Control Using Generalized Advantage Estimation” [C]. In: *International Conference on Learning Representations*. **2016**.

- [48] John Schulman, Filip Wolski, Prafulla Dhariwal *et al.* “*Proximal Policy Optimization Algorithms*” [J]. *arXiv preprint arXiv:1707.06347*, **2017**.
- [49] John G. Walker. “*Satellite Constellations*” [J]. *Journal of the British Interplanetary Society*, 1984-12, 37(12): 559–572.
- [50] ITU-R. *Specific Attenuation Model for Rain for Use in Prediction Methods* [R]. 2005-03.

致谢

时光匆匆，转眼间在北京大学的硕士学习生活即将结束。回顾这三年，从课程学习到科研训练，从论文选题到最终成文，我得到了许多老师、同学、朋友和家人的帮助与支持。值此论文完成之际，谨向所有关心、指导和鼓励过我的人致以最诚挚的感谢。

首先，衷心感谢我的硕士生导师冯梅萍老师。冯老师在我的研究生学习和论文工作中给予了悉心指导和宝贵建议，帮助我在课题研究和论文完成过程中不断改进与完善。老师严谨的治学态度、深厚的学术积累和认真负责的工作作风，使我受益良多。

衷心感谢吕国成老师在课题研究和论文写作过程中给予的耐心指导。吕老师在研究思路、技术细节和实验分析等方面给予了我许多具体而细致的帮助，帮助我逐步厘清问题、完善方法并推进论文工作。老师严谨务实的科研态度也对我产生了重要影响。

衷心感谢高诗简老师在论文研究期间给予的指导和启发。高老师在学术思考、研究方法和未来发展等方面与我进行了多次深入交流，使我对自己的研究工作和后续学习方向有了更加清晰的认识。

感谢北京大学为我提供了良好的学习环境和成长平台。三年的学习生活让我在专业知识、科研能力和独立思考能力等方面都得到了锻炼和提升。感谢学院各位老师课程学习、科研训练和日常事务中给予的帮助，也感谢同门、同学和朋友们在学习生活中的陪伴、交流与支持。与你们共同度过的时光，是我硕士阶段珍贵而难忘记忆。

最后，感谢我的家人一直以来的理解、鼓励和支持。你们的包容与陪伴是我安心学习和不断前行的重要力量。未来我将带着这段经历赋予我的收获与勇气，继续努力前行。

北京大学学位论文原创性声明和使用授权说明

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

论文作者签名： 日期： 年 月 日

学位论文使用授权说明

（必须装订在提交学校图书馆的印刷本）

本人完全了解北京大学关于收集、保存、使用学位论文的规定，即：

- 按照学校要求提交学位论文的印刷本和电子版本；
- 学校有权保存学位论文的印刷本和电子版，并提供目录检索与阅览服务，在校园网上提供服务；
- 学校可以采用影印、缩印、数字化或其它复制手段保存论文；
- 因某种特殊原因须要延迟发布学位论文电子版，授权学校 ☐ 一年 / ☐ 两年 / ☐ 三年以后，在校园网上全文发布。

（保密论文在解密后遵守此规定）

论文作者签名： 导师签名： 日期： 年 月 日